

UNIVERSITÉ DE MONTPELLIER

Impact de la suppression de variables dans un modèle de tarification automobile

Beatriz NOVAIS FERNANDES & Anissa SAIDANI

M1 - MBFA - Actuariat - Avril 2026

Encadrant : M. Jules Sadefo Kamdem

"All models are wrong, but some are useful."

— Georges E. P. Box,
one of the great statistical minds of the 20th century.

Remerciement

Nous tenons d'abord à remercier M. Jules Sadefo Kamdem pour son accompagnement rigoureux et bienveillant qu'il nous a apporté tout au long de ce projet. Ses enseignements ont été fondamentaux pour la réalisation de ce travail. Sa disponibilité, ses conseils et sa pédagogie nous ont permis d'aborder avec confiance des méthodes statistiques que nous découvrions.

Nous tenons aussi à exprimer notre gratitude à l'ensemble du corps enseignant pour le temps qu'ils nous ont accordé, ainsi que pour leurs expériences et connaissances nécessaires à la compréhension des enjeux de la tarification en assurance non-vie.

Nos remerciements vont aussi à nos camarades de promotion pour les échanges constructifs et le soutien mutuel qui ont rendu ce travail plus stimulant.

Résumé

Ce mémoire analyse l'impact de la suppression du genre dans les modèles de tarification en assurance automobile, suite à l'entrée en vigueur de la Gender Directive le 21 décembre 2012. L'énoncé du problème repose sur l'obligation pour les assureurs d'adopter une tarification dite "unisexe", interdisant l'usage du genre même s'il constitue un facteur de risque statistiquement significatif. L'objectif de l'étude est d'évaluer la perte d'information induite par cette contrainte réglementaire à partir d'un portefeuille réel de plus de 100 000 contrats. La recherche répond à la question suivante : **Quel est l'impact de cette suppression sur la précision discriminante du modèle et comment se traduit-elle par une redistribution des primes au sein du portefeuille ?**

La revue de littérature souligne le conflit entre l'égalité des primes moyennes et l'estimation précise du risque individuel, tout en identifiant un phénomène de "discrimination indirecte" via des variables corrélées au genre. Pour explorer ce sujet, la modélisation repose sur une approche fréquence-sévérité utilisant deux familles de modèles : le Modèle Linéaire Généralisé (GLM), référence classique, et le Modèle Additif Généralisé (GAM). L'analyse compare des versions genrées et unisexes de ces modèles pour mesurer la capacité des algorithmes plus flexibles à absorber la perte d'information.

L'analyse descriptive établit que le genre est une variable singulière, quasi indépendante des autres prédicteurs comme la profession ou le véhicule. Les résultats démontrent que sa suppression entraîne une dégradation significative de la qualité prédictive, principalement concentrée sur la fréquence des sinistres. Sur le plan tarifaire, le passage à l'unisexe génère une redistribution massive : les femmes subissent une hausse de prime d'environ 30 %, tandis que les hommes bénéficient d'une baisse d'environ 12 %. En conclusion, si le recours au modèle GAM améliore la précision globale, il ne compense pas la perte d'information structurelle liée au retrait du genre.

Ces découvertes mettent en lumière un mécanisme de subvention croisée où les assurés les moins risqués financent la réduction accordée aux profils plus accidentogènes. Cette redistribution ne conduit toutefois pas nécessairement à un phénomène d'antisélection au sens strict dans un cadre réglementé où la contrainte unisexe s'impose à l'ensemble du marché. Elle engendre plutôt une perte d'efficacité tarifaire et une distorsion de la mutualisation, susceptibles d'affecter l'équilibre économique des portefeuilles. Dans ce contexte, les assureurs sont incités à ajuster leur segmentation via d'autres variables ou à développer des approches alternatives, notamment fondées sur des données comportementales issues de la télématique.

Mots-clés : tarification actuarielle, Gender Directive, GLM, GAM, antisélection, fréquence de sinistres, assurance automobile.

Abstract

This thesis analyzes the impact of removing gender from motor insurance pricing models following the entry into force of the Gender Directive on December 21, 2012. The problem statement is based on the obligation for insurers to adopt "unisex" pricing, prohibiting the use of gender even when it constitutes a statistically significant risk factor. The objective of the study is to evaluate the loss of information induced by this regulatory constraint using a real portfolio of more than 100,000 contracts. The research answers the following question : **What is the impact of this removal on the model's discriminatory precision and how does it translate into a redistribution of premiums within the portfolio ?**

The literature review highlights the conflict between the equality of average premiums and the precise estimation of individual risk, while identifying a phenomenon of "indirect discrimination" via variables correlated with gender. To explore this subject, the modeling is based on a frequency-severity approach using two families of models : the Generalized Linear Model (GLM), the classic reference, and the Generalized Additive Model (GAM). The analysis compares gendered and unisex versions of these models to measure the ability of more flexible algorithms to absorb the loss of information.

The descriptive analysis establishes that gender is a unique variable, quasi-independent of other predictors such as occupation or vehicle. The results demonstrate that its removal leads to a significant degradation of predictive quality, mainly concentrated on claim frequency. In terms of pricing, the shift to unisex pricing generates a massive redistribution : women suffer a premium increase of approximately 30 %, while men benefit from a decrease of approximately 12 %. In conclusion, while the use of the GAM model improves overall precision, it does not compensate for the structural information loss linked to the removal of gender.

These findings highlight a cross-subsidy mechanism in which lower-risk policyholders implicitly finance premium reductions granted to higher-risk profiles. However, this redistribution does not necessarily lead to adverse selection in the strict sense, as the unisex pricing constraint applies uniformly across the entire market. Rather, it results in a loss of pricing efficiency and a distortion of risk pooling, which may affect the economic balance of insurance portfolios. In this context, insurers are incentivized to refine their segmentation through alternative variables or to develop new approaches, particularly those based on behavioral data derived from telematics.

Keywords : actuarial pricing, Gender Directive, GLM, GAM, adverse selection, claims frequency, motor insurance.

Sommaire

1 Introduction et fondements théoriques **6**
1.1 Introduction 6
1.2 Revue de littérature 10

2 Méthodologie et Analyse des données **14**
2.1 Méthodologie 14
2.2 Analyse descriptive des données 19

3 Modélisation actuarielle et impacts tarifaires **34**
3.1 Création des modèles 34
3.2 Optimisation des modèles et comparaison 43
3.3 Impact tarifaire de la suppression du genre 51
3.4 Évaluation du pouvoir discriminant des modèles : coefficient de Gini et Lift chart 53

4 Enjeux stratégiques et Conclusion **57**
4.1 Enjeux stratégiques et recommandations 57
4.2 Conclusion 60

Bibliographie **63**
Annexes 65
Table des matières 78

Chapitre 1

Introduction et fondements théoriques

1.1 Introduction

L'assurance automobile : protéger contre l'imprévisible

Conduire, c'est accepter une part d'imprévisible. Chaque jour, des millions de conducteurs prennent la route sans savoir si ce trajet sera comme tous les autres. Et pourtant, quelque part, quelqu'un fait le pari que tout se passera bien, ou plutôt, quelqu'un *chiffre* la probabilité que quelque chose se passe mal. Ce quelqu'un, c'est l'actuaire.

L'assurance automobile repose sur un principe simple mais puissant : la **mutualisation des risques**. Seul, un conducteur ne pourrait pas absorber le coût d'un accident grave valant plusieurs milliers, voire dizaines et même centaines de milliers d'euros. Mais si des milliers de conducteurs mettent en commun une petite cotisation régulière, l'assureur dispose d'un fond suffisant pour indemniser ceux qui, parmi eux, seront impliqués dans un sinistre. L'assurance, c'est donc la solidarité organisée face au hasard.

Mais pour que cette solidarité soit *juste*, la cotisation de chaque assuré, sa **prime**, doit refléter le risque qu'il représente réellement pour la collectivité. Un conducteur qui n'a jamais eu d'accident ne devrait pas payer autant qu'un conducteur chroniquement imprudent. C'est là qu'intervient la **tarification actuarielle** : l'art de quantifier le risque individuel pour fixer une prime équitable.

Concrètement, l'actuaire modélise deux grandeurs distinctes. D'une part, la **fréquence** en se posant la question : combien de fois, en moyenne, un assuré ayant ce profil va-t-il déclarer un sinistre sur une année ? D'autre part, la **sévérité** : si un sinistre survient, quel en sera le coût moyen ? Le produit de ces deux estimations donne la **prime pure**, c'est-à-dire le montant théorique que l'assuré devrait verser pour couvrir exactement son risque espéré.

Pour estimer ces quantités, les actuaires utilisent la **segmentation** : ils divisent le portefeuille d'assurés en groupes homogènes selon des critères observables comme l'âge, la zone géographique, le type de véhicule ou l'historique de sinistres, et estiment les paramètres de risque propres à chaque groupe. L'idée est simple : deux assurés ayant le même profil devraient, en moyenne, coûter pareil à l'assureur.

Le genre : une variable actuarielle historiquement robuste

Parmi les critères de segmentation traditionnellement utilisés par les assureurs, le genre du conducteur a longtemps occupé une place de premier plan. Et pour cause, les données accumulées sur des décennies montrent des écarts de sinistralité considérables entre hommes et femmes.

En France, les chiffres de la sécurité routière sont sans appel. Selon les données du Ministère de l'Intérieur, Sécurité routière les hommes représentent **77% des tués sur la route** et **84% des conducteurs présumés responsables d'accidents mortels**. Un homme a statistiquement **5 fois plus de risques d'être auteur d'un accident mortel qu'une femme**, à temps de déplacement équivalent. Cette suraccidentalité masculine est constante quelle que soit la tranche d'âge, même si elle est particulièrement marquée chez les jeunes adultes : entre 18 et 34 ans, on dénombre **803 hommes tués** contre seulement **159 femmes**.

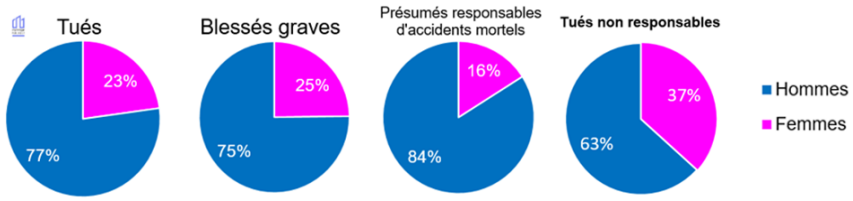


Figure 1.1 – Accidentalité routière en 2024

Source : Sécurité routière (2025)

Ces différences ne s'expliquent pas par une quelconque aptitude naturelle, mais par des comportements de conduite distincts. Selon les données de l'Observatoire national interministériel de la sécurité routière (ONISR) pour 2023, la vitesse excessive est impliquée dans 31% des accidents mortels masculins contre 18% des féminins ; l'alcool dans 24% contre 13%. Plus généralement, une étude du CEREMA portant sur 27 ans de statistiques judiciaires révèle que les hommes ont **3,4 fois plus de risques de provoquer un accident** que les femmes.

Pour l'assureur, ces données constituent une justification statistique solide : facturer davantage un jeune homme qu'une jeune femme au profil similaire repose sur un risque en *moyenne* objectivement plus élevé. Ce principe, fondement de la tarification actuarielle, porte le nom d'équité statistique : chacun paie à la hauteur du coût moyen que représente son groupe pour la mutualité.

Mais cette logique, cohérente à l'échelle collective, se heurte à une limite fondamentale à l'échelle individuelle. Un jeune homme prudent, sans antécédent sinistral, se voit appliquer une surprime liée à son genre plutôt qu'à son comportement réel. Pour lui, la classification statistique constitue une discrimination individuelle : il supporte le coût d'un risque de groupe qu'il ne génère pas personnellement. C'est précisément cette tension entre équité collective et équité individuelle que l'arrêt « Test-Achats » a entendu trancher.

La rupture réglementaire : l'arrêt « Test-Achats »

Cette théorie a été profondément impactée par le droit européen. Le 1er mars 2011, la Cour de Justice de l'Union Européenne (CJUE), par son arrêt dit « Test-Achats », a invalidé la dérogation permettant aux assureurs d'utiliser le genre comme variable tarifaire. Cette décision, transposée dans la « Gender Directive » (2004/113/CE), est entrée en vigueur le 21 décembre 2012. Elle impose désormais une tarification « unisexe » : un homme et une femme au profil identique doivent se voir proposer la même prime, quelles que soient les différences statistiques de sinistralité entre les deux groupes.

Le législateur a ainsi fait prévaloir le principe social d'égalité de traitement sur le principe actuariel d'équité statistique. Ce choix, légitime sur le plan des valeurs, crée néanmoins un défi technique considérable pour les assureurs : comment tarifer correctement un risque lorsqu'on s'interdit d'utiliser l'une de ses variables les plus prédictives ?

Problématique

La suppression du genre dans les modèles de tarification en assurance n'est pas sans conséquence : elle peut entraîner une baisse de la précision des prédictions, modifier la répartition des primes entre assurés et soulever des enjeux. Dans ce contexte, ce mémoire cherche à répondre à la question suivante :

Quel est l'impact de la suppression du genre sur la précision discriminante du modèle, et comment se traduit-elle sur la redistribution des primes au sein du portefeuille ?

Pour y répondre, nous nous appuyons sur la base de données `pg15training`, issue d'un portefeuille réel de plus de 100 000 contrats d'assurance automobile de particuliers, mise à disposition par Charpentier à l'occasion du Pricing Game 2015 organisé par l'Institut des Actuaires français. Observé avant l'entrée en vigueur de la Gender Directive, ce jeu de données contient le genre des assurés, ce qui nous permet de construire un modèle de référence genré, puis de simuler rigoureusement l'impact de sa suppression.

Dans ce cadre, notre analyse s'articule autour de plusieurs hypothèses empiriquement testables. Premièrement, nous posons l'hypothèse que le **genre constitue une variable explicative significative du risque automobile**, et que sa suppression entraîne une dégradation mesurable de la qualité prédictive des modèles de tarification. Deuxièmement, nous supposons que le recours à des modèles plus flexibles, en particulier les modèles additifs généralisés (GAM), permet de capter une partie de l'information perdue et d'atténuer cette dégradation, sans toutefois la compenser intégralement. Enfin, nous faisons l'hypothèse que la suppression du genre induit une **redistribution non neutre des primes au sein du portefeuille**, susceptible de modifier sa structure de risque et de générer des effets économiques indirects. Ces hypothèses guideront l'ensemble de notre démarche empirique, depuis la construction des modèles jusqu'à l'interprétation des résultats.

Plan

Notre étude s'articule autour de quatre axes. Nous débutons par une **revue de littérature**, qui permet de situer les enjeux théoriques et réglementaires liés à la tarification non-discriminatoire, ainsi que le positionnement de notre travail dans ce cadre.

Nous présentons ensuite la **méthodologie statistique**, en détaillant les modèles GLM et GAM ainsi que leurs fondements mathématiques.

Le troisième axe constitue le cœur empirique de l'étude : il repose d'abord sur une **analyse descriptive** du portefeuille, puis sur la **construction et la comparaison des modèles** genré et unisexe, accompagnées d'une évaluation précise des transferts de primes induits.

Enfin, nous abordons les **enjeux stratégiques** associés à la tarification moderne et formulons les recommandations qui en découlent.

1.2 Revue de littérature

Dans le cadre de l'analyse de l'impact de la Gender Directive sur la tarification automobile, il est fondamental d'examiner la littérature scientifique et technique portant sur les fondements statistiques de la tarification, les contraintes réglementaires anti-discrimination, les mécanismes d'antisélection, et les méthodes de modélisation alternatives disponibles. Cette démarche est indispensable pour comprendre à la fois les outils actuariels classiques sur lesquels repose notre étude et les enjeux spécifiques liés à la suppression d'une variable tarifaire aussi structurante que le genre.

1.2.1 Fondements statistiques de la tarification non-vie

Le cadre théorique des Modèles Linéaires Généralisés (GLM) repose sur les travaux de McCullagh et Nelder, 1989, dont l'ouvrage Generalized Linear Models (Second Edition) constitue une référence méthodologique centrale de la tarification moderne. Les auteurs y formalisent une classe de modèles unifiée, permettant de traiter des variables réponses de distributions exponentielles variées : Poisson, Gamma, Binomiale Négative, via une fonction de lien adaptée. En assurance non-vie, cette flexibilité est décisive : elle permet de modéliser conjointement la fréquence des sinistres, dont la distribution est souvent surdispersée, et leur sévérité, dont la distribution est continue et asymètrique. L'ouvrage de McCullagh et Nelder, 1989 constitue la base sur laquelle repose notre démarche de modélisation.

Dans le prolongement de ce cadre général,Denuit et al., 2007, dans leur ouvrage Actuarial Modelling of Claim Counts, proposent une application systématique des GLM aux problématiques spécifiques de la tarification en assurance automobile. Ils y détaillent notamment la gestion de l'exposition, le choix entre loi de Poisson et loi Binomiale Négative selon le degré de surdispersion observé, et l'interprétation des coefficients en termes de facteurs multiplicatifs de risque. Notre étude s'appuie sur ces recommandations, aussi bien dans le traitement de l'exposition via un offset que dans la procédure de sélection de la loi de probabilité pour la fréquence. Leur traitement du système bonus-malus est également mobilisé pour justifier l'intégration du CRM comme variable explicative centrale.

Le Modèle Additif Généralisé (GAM), introduit par Hastie et Tibshirani et développé dans leur ouvrage de 1990, constitue l'extension du GLM lorsque l'hypothèse de linéarité des effets s'avère restrictive. Ces travaux fournissent le cadre permettant de remplacer les effets linéaires par des fonctions de lissage estimées à partir de données. Si les auteurs ont initialement introduit la validation croisée généralisée (GCV) pour la séléction du paramètre de lissage, nous privilégions dans cette étude la méthode du Maximum de Vraisemblance Restreint (REML). Ce choix se justifie par la taille importante de notre échantillon car il offre une estimation plus stable et robuste des paramètres de lissage tout en limitant le risque de sur-ajustement. Ils justifient également le recours au degrés de liberté effectifs comme indicateur de la non-linéarité de chaque relation estimée, un outil important dans notre analyse comparative des modèles genré et unisexe.

1.2.2 Les données d'Arthur Charpentier

L'ouvrage Computational Actuarial Science with R de Charpentier représente une contribution majeure à l'actuariat moderne en rendant accessibles, à travers des implémentations en R et des jeux de données réels, l'ensemble des méthodes quantitatives

utilisées en tarification, provisionnement et gestion des risques. C'est dans ce cadre que l'auteur met à disposition les jeux de données `pg15training` et `pg15pricing`, constitués à l'occasion du Pricing Game organisé par l'Institut des Actuaires français en 2015. Le jeu `pg15training` contient 100 021 polices de responsabilité civile automobile de particuliers observées au plus sur un an, destinées à l'entraînement des modèles, tandis que `pg15pricing` regroupe 36 311 polices de la même garantie pour lesquelles une prime doit être calculée. Chaque observation comprend les caractéristiques du souscripteur et du véhicule assuré. Il convient de noter que, pour des raisons de confidentialité, la signification de la plupart des modalités des variables catégorielles n'est pas communiquée.

Le choix de ces données pour notre étude n'est pas anodin. La présence du genre comme variable explicative dans le jeu `pg15training` est précisément ce qui nous permet de construire un modèle différencié servant de référence, puis de simuler rigoureusement les effets de sa suppression réglementaire. Charpentier s'est lui-même intéressé dans ses travaux aux questions d'équité en assurance et à la discrimination indirecte, c'est-à-dire au risque que des variables a priori neutres captent mécaniquement l'information du genre lorsque celui-ci est retiré du modèle. Cette préoccupation constitue l'un des fils directeurs de notre analyse empirique, et justifie notamment le recours au V de Cramer pour mesurer le degré d'indépendance entre le genre et les autres prédicteurs disponibles.

1.2.3 Réglementation anti-discrimination et fairness tarifaire

L'article de Xin et Huang, 2023, publié dans le North American Actuarial Journal, propose une formalisation des différents régimes réglementaires possibles (interdiction de la discrimination directe ou indirecte) et leur associe des critères mathématiques précis de fairness actuarielle. Ils montrent que ces critères sont en conflit : il est généralement impossible d'assurer simultanément l'égalité des primes moyennes entre genres et une estimation précise du risque individuel. Ce cadre conceptuel est directement mobilisé dans notre étude pour interpréter les transferts de primes observés entre modèle genré et unisexe, et afin d'évaluer dans quelle mesure nos modèles respectent les différents critères d'équité formalisés par les auteurs..

Xin et Huang, 2023 identifient également le phénomène de discrimination indirecte : lorsque le genre est retiré du modèle, des variables qui lui sont corrélées voient leurs coefficients se modifier pour capter partiellement l'information perdue. Ce mécanisme, que nous qualifions d'effet report, constitue l'une des hypothèses que notre analyse cherche à tester empiriquement.

D'autres travaux ont abordé la question de l'équité tarifaire dans une perspective comparative entre marchés européens. Ainsi, Schmeiser, 2014, dans une étude publiée dans le Geneva Papers on Risk and Insurance, ont analysé les effets anticipés de la Gender Directive sur les marchés d'assurance vie et automobile dans plusieurs pays européens. Leurs simulations montrent que l'ampleur de transferts de primes dépend fortement de la structure démographique du portefeuille et du degré de différenciation tarifaire préexistant. Ces travaux fournissent un point de comparaison utile pour situer les ordres de grandeur que nous observons dans notre propre portefeuille, et soulignent l'importance de ne pas généraliser les conclusions d'une étude à l'ensemble du marché européen sans tenir compte de la composition spécifique de chaque portefeuille.

1.2.4 Antisélection et équilibre du portefeuille

Le mécanisme d'antiséléction en assurance est formalisé par Rothschild et Stiglitz, 1976, dans un article publié dans le Quarterly Journal of Economics. Les auteurs y montrent que sur un marché d'assurance en information asymétrique, où les assurés connaissent leur niveau de risque mieux que l'assureur, un équilibre concurrentiel stable n'existe pas nécessairement. Toute contrainte forçant la mutualisation de risques hétérogènes dans un tarif uniforme crée mécaniquement une incitation pour les bons risques à quitter le marché ou à souscrire moins de couverture, dégradant progressivement la composition du portefeuille.

Ces conclusions ont été étendues par Fagart et Kambia-Chopin, 2003, dans un document de travail du CREST, à un contexte combinant sélection adverse et aléa moral. Les auteurs y montrent que, même lorsque l'effort de prévention de l'assuré constitue une information privée non observable par l'assureur, les propriétés fondamentales de l'équilibre concurrentiel décrites par Rothschild et Stiglitz demeurent robustes : les bons risques obtiennent une couverture réduite tandis que les mauvais risques conservent leur contrat d'aléa moral.

Ce double cadre théorique est essentiel pour notre problématique : la Gender Directive impose une telle mutualisation, en interdisant la différenciation tarifaire entre deux groupes de risque statistiquement différents. Les travaux de Rothschild et Stiglitz, 1976 et Fagart et Kambia-Chopin, 2003 fournissent ainsi le fondement théorique à partir duquel nous interprétons les risques dynamiques induits par le passage à un tarif unisexe, en particulier dans un contexte où la loi Hamon, Assemblée nationale, 2014 facilite la résiliation des contrats et renforce la mobilité des assurés entre portefeuilles.

1.2.5 Genre et distribution des sinistres

Pernagallo, Punzo et Torrisi, 2023, dans un article publié dans Scientific Reports, conduisent une analyse statistique approfondie de l'effet du genre sur la sinistralité automobile à partir de deux jeux de données actuarielles indépendants. Leur contribution principale pour notre sujet est de montrer que les différences entre conductrices et conducteurs ne se limitent pas à la seule moyenne des sinistres mais concernent également la dispersion et l'asymétrie de la distribution. Deux assurés de genres différents peuvent ainsi présenter la même espérance de sinistres et des profils de risque pourtant sensiblement distincts, une nuance que les modèles classiques ne captent pas.

Cette observation est directement pertinente pour notre étude, car elle suggère que la perte induite par la suppression du genre dans un modèle tarifaire est potentiellement plus difficile à compenser que ce que laissent penser les seuls indicateurs de précision moyenne, comme l'AIC. Elle justifie également l'intérêt de tester des modèles plus flexibles, capables de modéliser des aspects plus riches de la distribution des sinistres, pour évaluer dans quelle mesure ils parviennent à récupérer une partie de l'information perdue avec le genre. L'article de Pernagallo, Punzo et Torrisi, 2023 sert ainsi de point d'appui pour contextualiser et interpréter les différences de performance que nous observons entre nos modèles.

1.2.6 Vers une tarification comportementale

Une piste de dépassement des contraintes réglementaires liées à la suppression de variables sociodémographiques réside dans le développement de la tarification basée sur l'usage. Boucher, Côté et Guillén, 2017, dans un article publié dans Insurance : Mathematics and Economics, montrent que les données télématiques (kilométrage, plages horaires de conduite, comportements de freinage et d'accélération) permettent de construire des prédicteurs de risque individuels dont le pouvoir discriminant est comparable, voire supérieur, à celui des variables sociodémographiques classiques. Dans la mesure où ces données captent directement le comportement de conduite, elles sont par construction moins exposées aux critiques de discrimination indirecte.

Ces travaux sont mobilisés dans notre étude non comme des solutions directement testées, mais comme des pistes permettant de dépasser certaines limites identifiées. Ils contribuent à éclairer les recommandations formulées en conclusion, en montrant que la tension entre précision actuarielle et contraintes réglementaires n'est pas nécessairement irréconciliable. Une tarification individualisée, fondée sur le comportement réel plutôt que sur des caractéristiques sociodémographiques, constitue une voie d'évolution pertinente et bien plus équitable.

1.2.7 Synthèse et positionnement de l'étude

Ensemble, ces travaux permettent de situer la contribution de notre étude au sein de la littérature existante. Sur le plan méthodologique, nous nous inscrivons dans la continuité de McCullagh et Nelder, 1989 et Denuit et al., 2007 en appliquant le cadre GLM/GAM à une problématique de tarification contrainte. Sur le plan réglementaire, nous prolongeons Xin et Huang, 2023 en produisant une analyse empirique des mécanismes qu'ils formalisent théoriquement, sur un portefeuille européen réel. Sur le plan des mécanismes économiques, nous mobilisons le cadre de Rothschild et Stiglitz, 1976 pour interpréter les risques dynamiques induits par la contrainte unisexe.

Notre étude se distingue de la littérature existante sur deux points. D'une part, elle propose une comparaison systématique entre GLM et GAM dans le contexte spécifique de la suppression d'une variable réglementaire interdite. D'autre part, elle émet trois dimensions : perte d'information statistique, redistribution tarifaire et risque d'antisélection, dans un cadre d'analyse unifié appliqué à un portefeuille réel.

Chapitre 2

Méthodologie et Analyse des données

2.1 Méthodologie

Vue d'ensemble

Avant de plonger dans les modèles, il est utile de se poser une question simple : qu'est-ce qu'on cherche à prédire exactement ?

En assurance automobile, l'assureur ne sait pas à l'avance si un assuré va avoir un accident, ni combien cet accident va coûter. Ce qu'il peut faire, en revanche, c'est **estimer une espérance**, c'est-à-dire que sur un grand nombre d'assurés ayant le même profil, il cherche à déterminer quel sera le coût moyen à anticiper par contrat.

Pour cela, on décompose le problème en deux sous-questions distinctes, selon l'approche dite *frequency-severity* :

— **La fréquence** $\hat{\lambda}$: quelle est la probabilité que cet assuré déclare au moins un sinistre dans l'année ? Plus précisément, combien de sinistres va-t-il déclarer en moyenne ?

— **La sévérité** $\hat{\mu}$: si un sinistre survient, quel en sera le coût moyen ?

La prime pure, c'est-à-dire la prime idéale qui couvrirait exactement le risque espéré sans marge ni frais, est alors le produit de ces deux estimations :

$$\text{Prime Pure} = \hat{\lambda} \times \hat{\mu}$$

Cette décomposition est préférable à la modélisation directe du coût total des sinistres, car elle permet de traiter séparément deux phénomènes de nature très différente : la propension à avoir un accident et la gravité de cet accident. Comme nous le verrons, le genre influence bien davantage la fréquence que la sévérité, ce que la décomposition permet précisément de mettre en évidence.

Pour mener cette modélisation, nous avons retenu deux approches complémentaires : le **GLM** et le **GAM**. Le GLM constitue notre référence classique ; le GAM en est une extension plus souple, capable de détecter des effets non linéaires que le premier ne peut pas capter. En les comparant, nous pourrons évaluer si la sophistication du modèle permet de compenser partiellement la perte d'information causée par le retrait du genre.

2.1.1 Le GLM : le modèle de référence actuariel

Principe général

Le Modèle Linéaire Généralisé (GLM), formalisé par Nelder et Wedderburn, 1972, est depuis plus de cinquante ans le modèle de tarification de référence en assurance non-vie. Son principe de base est le suivant : on suppose que la prime d'un assuré s'obtient en appliquant successivement des coefficients multiplicateurs à une prime de base, un coefficient par variable explicative.

Par exemple, la prime d'un jeune conducteur malussé vivant en région parisienne pourrait s'écrire :

$$\text{Prime} = \text{Prime de base} \times \underbrace{1{,}8}_{\text{jeune âge}} \times \underbrace{1{,}4}_{\text{malus}} \times \underbrace{1{,}2}_{\text{urbain}}$$

Cette structure est ce qu'on appelle un modèle multiplicatif. Elle est obtenue mathématiquement en appliquant une fonction de lien logarithmique à la variable à prédire, ce qui transforme le produit en une somme, beaucoup plus facile à estimer :

$$\log(\mu_i) = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip}$$

où μ_i est la valeur prédite pour l'assuré i et les β_j sont les coefficients estimés par le modèle. Chaque e^{β_j} correspond au coefficient multiplicateur associé à la variable j.

Pourquoi ne pas utiliser une régression linéaire classique ?

On pourrait se demander pourquoi ne pas simplement utiliser une régression linéaire ordinaire pour prédire la fréquence ou le coût des sinistres. La réponse est double.

D'une part, les données de sinistres ne se distribuent pas selon une loi Normale : le nombre de sinistres est un entier positif (souvent 0), et le coût d'un sinistre est une valeur **strictement positive** très asymétrique. Une régression linéaire produirait des prédictions négatives, ce qui n'a aucun sens.

D'autre part, la variance des données de sinistres n'est pas constante : elle augmente généralement avec la moyenne. Le GLM prend en compte cette réalité en choisissant une **loi de probabilité adaptée** à la nature de la variable à expliquer.

Choix des lois : fréquence et sévérité

Le choix de la loi est une étape cruciale de la modélisation. Deux lois sont classiquement envisagées pour la fréquence, et une pour la sévérité. Le Tableau 2.1 présente leurs propriétés et leur domaine d'application.

TABLE 2.1 – Lois de probabilité utilisées en tarification automobile

Loi	**Usage**	**Propriétés**	**Hypothèse clé**
Poisson	Fréquence	Définie sur $\mathbb{N}$, $\mathbb{E}(Y) = \text{Var}(Y) = \mu$	Équidispersion : la variance est égale à la moyenne
Binomiale Négative	Fréquence	Définie sur $\mathbb{N}$, $\text{Var}(Y) = \mu + \frac{\mu^2}{\theta}$	Surdispersion : la variance peut excéder la moyenne (paramètre θ)
Gamma	Sévérité	Définie sur $\mathbb{R}^+$, asymétrie à droite	Coûts strictement positifs avec une queue de distribution étendue

En pratique, la loi de Poisson est souvent le point de départ naturel pour la fréquence, mais elle impose une contrainte forte : la variance doit être égale à la moyenne (**équidispersion**). Or, les données réelles de sinistres présentent souvent une variance supérieure à la moyenne, phénomène appelé **surdispersion**. Dans ce cas, la loi Binomiale Négative est préférable : elle introduit un paramètre supplémentaire θ qui absorbe cet excès de variabilité.

Pour la sévérité, la loi **Gamma** s'impose naturellement : elle est définie sur les réels strictement positifs, ce qui garantit des prédictions de coût toujours positives, et elle accommode l'asymétrie à droite caractéristique des distributions de coûts en assurance.

Intégration de l'exposition

Tous les assurés de notre base ne sont pas observés sur la même durée : certains ont souscrit leur contrat en cours d'année, d'autres ont résilié avant la fin. Il serait donc injuste de comparer directement le nombre de sinistres d'un assuré exposé 3 mois à celui d'un assuré exposé 12 mois.

Pour corriger ce biais, on intègre au modèle un **offset**, c'est-à-dire un terme fixe non estimé qui ramène la variable expliquée à une fréquence annuelle :

$$\log(\lambda_i) = \log(d_i) + \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$$

où $d_i = \texttt{Exppdays}_i/365$ est la durée d'exposition de l'assuré i en années. On modélise ainsi une **fréquence annualisée**, comparable d'un assuré à l'autre indépendamment de sa durée de présence dans le portefeuille.

Estimation et évaluation du modèle

Les coefficients $\boldsymbol{\beta}$ sont estimés par la méthode du **maximum de vraisemblance** : on cherche les valeurs qui rendent les données observées les plus probables possible étant donné le modèle. C'est une procédure itérative, résolue numériquement.

Pour comparer différentes spécifications et évaluer l'impact de la suppression du genre, nous utilisons principalement le **critère d'information d'Akaike (AIC)** :

$$\text{AIC} = -2\,\ell(\hat{\boldsymbol{\beta}}) + 2p$$

où $\ell(\hat{\boldsymbol{\beta}})$ est la log-vraisemblance maximisée et p le nombre de paramètres. Le premier terme récompense l'ajustement aux données ; le second pénalise la complexité pour éviter le surapprentissage. **Un AIC plus faible signifie un meilleur modèle.** Lorsque deux modèles sont emboîtés (l'un est un cas particulier de l'autre), on peut également utiliser le **test du rapport de vraisemblance (LRT)** pour tester formellement si la différence d'ajustement est statistiquement significative.

2.1.2 Le GAM : quand le GLM ne suffit plus

La limite du GLM : la linéarité imposée

Le GLM suppose que la relation entre chaque variable explicative et le logarithme de la variable à prédire est **strictement linéaire**. En d'autres termes, il suppose qu'une année de plus dans l'âge du conducteur a toujours exactement le même effet sur la fréquence, qu'il ait 20 ans ou 60 ans.

Cette hypothèse est souvent trop restrictive. En pratique, la sinistralité évolue de façon non linéaire avec l'âge : très élevée chez les très jeunes conducteurs, elle décroît rapidement jusqu'à 35 ans, se stabilise, puis remonte légèrement chez les conducteurs très âgés. Le GLM ne peut capter ce profil qu'en découpant artificiellement l'âge en classes, une solution imparfaite qui perd de l'information.

Principe du GAM

Le Modèle Additif Généralisé (GAM), introduit par Hastie et Tibshirani, 1986, répond à ce problème en remplaçant les effets linéaires par des **fonctions souples**, appelées *splines de lissage*, estimées librement à partir des données :

$$g(\mu_i) = \beta_0 + f_1(x_{i1}) + f_2(x_{i2}) + \cdots + f_p(x_{ip})$$

Chaque fonction f_j est estimée automatiquement sans qu'on ait besoin de spécifier sa forme à l'avance. Concrètement, une spline est une courbe lisse construite en raccordant des polynômes par morceaux, un peu comme une ligne flexible qui s'adapte aux données plutôt que de les forcer dans un cadre rigide.

Un paramètre de lissage contrôle la souplesse de chaque courbe. S'il est trop faible, la courbe est presque linéaire et on perd la flexibilité du GAM. S'il est trop élevé, la courbe colle trop aux données et risque de sur-apprendre. Ce paramètre est sélectionné automatiquement par la méthode du **maximum de vraisemblance restreint** (REML), qui permet une estimation plus stable et limite le risque de sur-ajustement.

Mesurer la non-linéarité : les degrés de liberté effectifs

Pour quantifier le degré de non-linéarité de chaque variable, le GAM produit des **degrés de liberté effectifs** (edf). Leur interprétation est intuitive :

— edf ≈ 1 : la relation est quasi linéaire, le GAM converge vers le GLM pour cette variable.

— edf > 1 : la relation est non linéaire. Plus l'edf est élevé, plus la forme de la courbe est complexe.

Ce diagnostic est précieux dans notre contexte : si, après suppression du genre, les edf des autres variables augmentent significativement, cela signalerait un **effet de report**, c'est-à-dire que les variables restantes courbent leur trajectoire pour absorber l'information perdue du genre.

Avantages et limites

Le GAM présente deux avantages majeurs par rapport au GLM. D'une part, il améliore la précision prédictive en capturant des effets que le GLM lisse artificiellement. D'autre part, il reste relativement **interprétable** : on peut représenter graphiquement l'effet estimé de chaque variable, ce qui permet une lecture intuitive des résultats, un avantage important dans le contexte réglementaire de la tarification où l'assureur doit pouvoir justifier ses choix tarifaires.

Sa principale limite est qu'il suppose toujours que les effets des variables sont **additifs** : il ne modélise pas naturellement les interactions entre variables. Dans notre cas, cette limite est secondaire puisque c'est précisément le genre que l'on supprime.

Rôle dans notre étude

Le GAM sera estimé en parallèle du GLM, dans ses versions genrée et unisexe, pour les deux composantes de la prime pure. La comparaison des critères d'informations (AIC et BIC) entre les deux modèles permettra de répondre à notre question centrale : la flexibilité du GAM permet-elle de mieux absorber la perte d'information liée à la suppression du genre ?

2.2 Analyse descriptive des données

Avant de construire les moindres modèles, il est indispensable de bien connaître les données sur lesquelles on travaille. Cette étape n'est pas une simple formalité : c'est elle qui permet de comprendre la structure du portefeuille, d'identifier les variables les plus pertinentes et de formuler des hypothèses sur les relations entre les caractéristiques des assurés et leur comportement sinistral. C'est aussi à ce stade que l'on peut commencer à mesurer empiriquement le rôle du genre, avant même d'estimer le moindre modèle.

2.2.1 Présentation des données et des variables

La base de données utilisée dans cette étude est la base `pg15training`, issue du portefeuille d'un assureur automobile européen et mise à disposition par Charpentier à l'occasion du Pricing Game 2015 organisé par l'Institut des Actuaires français. Elle contient **100 021 contrats** de responsabilité civile automobile de particuliers, observés sur les années **2009 et 2010**, soit avant l'entrée en vigueur de la Gender Directive en décembre 2012, nous permettant d'inclure la variable genre.

Chaque ligne correspond à un contrat individuel décrit par 20 variables, que l'on peut regrouper en quatre catégories : les identifiants et variables temporelles, les caractéristiques du conducteur, les caractéristiques du véhicule, et les variables de sinistralité observée. Il convient de noter que, pour des raisons de confidentialité, la signification de la plupart des modalités des variables catégorielles n'est pas communiquée par l'assureur.

Le Tableau 2.2 présente une description synthétique de l'ensemble des variables disponibles.

TABLE 2.2 – Description des variables de la base pg15training

Variable	Type	Description
Identifiants et variables temporelles		
`PolNum`	Entier	Numéro identifiant unique
`CalYear`	Entier	Année d'observation (2009–2010)
`Exppdays`	Entier	Durée d'exposition en jours (de 1 à 365)
`Poldur`	Entier	Ancienneté en années (de 0 à 15)
Caractéristiques du conducteur		
`Gender`	Facteur (2)	Genre du conducteur : *Female* ou *Male*
`Age`	Entier	Âge du conducteur en années (de 18 à 75)
`Occupation`	Facteur (5)	Catégorie socioprofessionnelle
`Bonus`	Entier	Score de Bonus-Malus (de -50 à 150)
`Adind`	Binaire	Indicateur d'assurance additionnelle (0 = non, 1 = oui)
Caractéristiques du véhicule		
`Type`	Facteur (6)	Type de véhicule, de A à F
`Category`	Facteur (3)	Catégorie : *Small*, *Medium*, *Large*
`Group1`	Entier	Groupe tarifaire du véhicule
`Group2`	Facteur (10)	Groupe secondaire de classification
`SubGroup2`	Facteur (471)	Sous-groupe de classification
`Value`	Entier	Valeur estimée du véhicule en euros
Caractéristiques géographiques		
`Density`	Numérique	Densité de population de la zone de résidence (hab./km^2)
Variables de sinistralité observée		
`Numtppd`	Entier	Nombre de sinistres matériels causés à des tiers
`Numtpbi`	Entier	Nombre de sinistres corporels causés à des tiers
`Indtppd`	Numérique	Coût total (en euros) des sinistres matériels
`Indtpbi`	Numérique	Coût total (en euros) des sinistres corporels

Notre étude se concentre sur les **sinistres matériels causés à des tiers** (`Numtppd`, `Indtppd`), qui constituent la composante la plus volumineuse et la plus modélisable du risque automobile. Les sinistres corporels (`Numtpbi`), nettement moins fréquents, ne feront pas l'objet d'une modélisation séparée : leur faible volume réduirait la robustesse statistique des estimations.

La durée d'exposition de chaque contrat est fournie en jours via `Exppdays`. Nous la convertissons en années (`expo_an` = `Exppdays`/365) pour le calcul des fréquences annualisées.

Une fois l'exposition annualisée, il convient de traiter la variable `Bonus`, qui constitue la mémoire du risque individuel dans le portefeuille. Dans la base `pg15training`, cette variable est initialement exprimée sur une échelle allant de -50 (bonus maximal) à +150 (malus important). Afin de s'aligner sur les standards de tarification actuarielle et de faciliter l'interprétation des futurs coefficients du modèle, nous transformons ce score en un **Coefficient de Réduction-Majoration (CRM)** selon la formule suivante :

$$CRM = 1 + \frac{Bonus}{100}$$

Cette transformation produit un facteur multiplicatif compris entre 0,5 et 2,5. Un CRM de 0,7 indique ainsi une réduction de 30%, tandis qu'un CRM de 1,5 traduit une majoration de 50%. Il est important de noter que cette transformation est neutre sur le plan de la modélisation : elle n'affecte ni la performance prédictive ni la qualité de l'ajustement. Son rôle est purement pédagogique, visant à améliorer l' **interprétabilité** des résultats en convertissant un score abstrait en une grandeur commerciale standardisée, directement compatible avec la fonction de lien logarithmique de nos modèles GLM et GAM.

Les variables `SubGroup2` et `Group2`, bien que présentes dans la base, ne seront pas intégrées dans nos modèles en raison de leur très grande granularité (471 modalités pour `SubGroup2`), qui poserait des problèmes d'estimation et d'interprétabilité.

2.2.2 Statistiques descriptives

Composition du portefeuille par genre

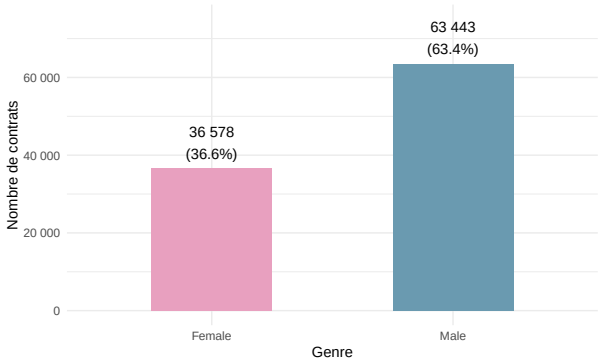


FIGURE 2.1 – Répartition du portefeuille par genre

Le portefeuille se compose à **63,4 % d'hommes** (63 443 contrats) et à **36,6 % de femmes** (36 578 contrats), comme l'illustre la Figure 2.1. Cette surreprésentation masculine, courante dans les portefeuilles automobiles, est un premier élément de contexte essentiel : tout transfert de prime entre genres sera mécaniquement asymétrique. La charge redistribuée sera supportée par un nombre plus restreint de femmes, ce qui amplifiera leur hausse individuelle dans le modèle unisexe.

Variables quantitatives

Le Tableau 2.3 présente les principales statistiques descriptives des variables numériques.

TABLE 2.3 – Statistiques descriptives des variables numériques

Variable	Min.	Q1	Médiane	Moyenne	Max.
Âge (ans)	18	30	40	41,12	75
Bonus-Malus (score)	−50	−40	−30	−6,92	150
CRM	0,50	0,60	0,70	0,93	2,50
Ancienneté (ans)	0	1	4	5,47	15
Valeur du véhicule (€)	1 000	8 380	14 610	16 455	49 995
Densité (hab./km²)	14	51	94	117	297

Ces statistiques dessinent le portrait d'un portefeuille représentatif d'une clientèle automobile. L'assuré médian est un conducteur de **40 ans**, avec un CRM de 0,70, ce qui indique un historique sinistral peu chargé et donc un profil de bon conducteur. Son contrat est en cours depuis 4 ans et son véhicule est valorisé à environ 14 600 euros, cohérent avec un parc automobile de milieu de gamme.

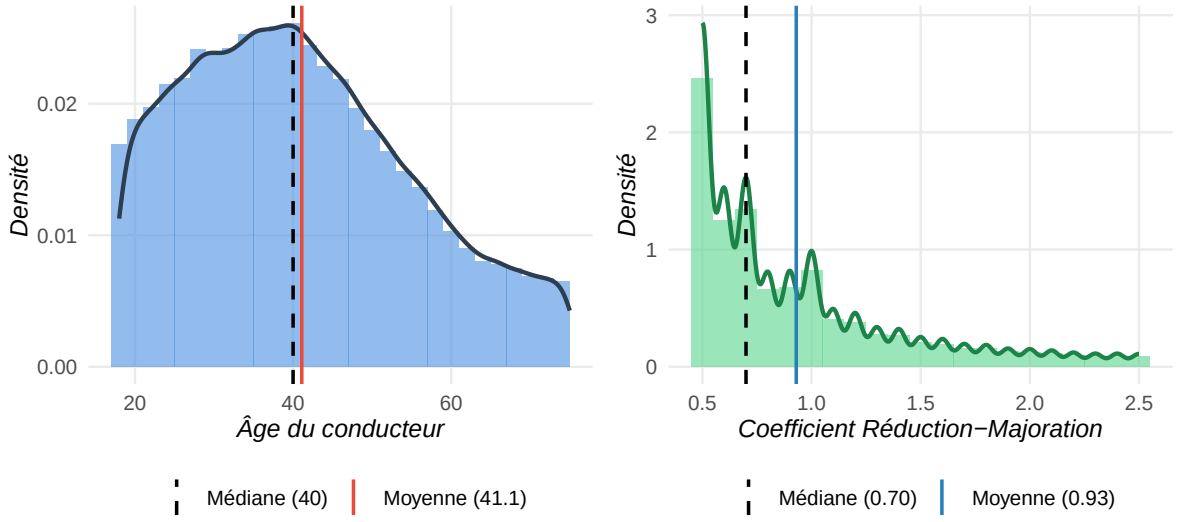


FIGURE 2.2 – Analyse des distributions continues du portefeuille (Âge et CRM)

La distribution de l'âge présente une légère asymétrie à droite, avec une moyenne légèrement supérieure à la médiane, traduisant la présence d'un segment de conducteurs seniors dans le portefeuille. La variable CRM, quant à elle, présente une distribution très asymétrique : avec une médiane de 0,70 et une moyenne de 0,93, la majorité des assurés bénéficient d'un bonus significatif, mais une minorité de conducteurs très malussés (jusqu'à 2,50) tire fortement la moyenne vers le haut. C'est précisément cette queue de distribution qui concentre l'essentiel de la sinistralité du portefeuille, comme nous le verrons dans les sections suivantes.

Variables qualitatives

Le Tableau 2.4 détaille la répartition des principales variables catégorielles.

TABLE 2.4 – Répartition des variables catégorielles

Variable	Modalité	Part (%)
Type de véhicule	A	27,8
	B	22,1
	C	13,9
	D	19,6
	E	11,2
	F	5,5
Catégorie	Large	35,1
	Medium	36,6
	Small	28,2
Profession	Employé	31,1
	Au foyer	20,0
	Retraité	13,2
	Indépendant	20,4
	Sans emploi	15,3

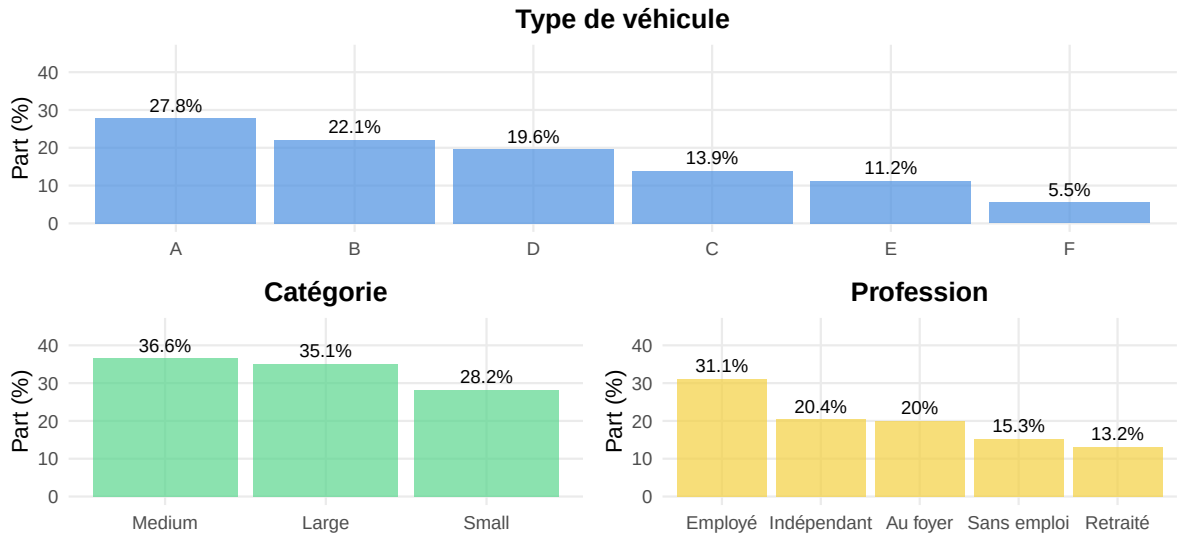


FIGURE 2.3 – Structure du portefeuille par variables catégorielles

La répartition par type de véhicule et par catégorie est relativement équilibrée, sans surconcentration excessive sur une modalité particulière. Du côté des professions, les employés constituent le groupe le plus représenté (31,1 %), suivis des indépendants (20,4 %) et des personnes au foyer (20 %). Cette diversité socioprofessionnelle garantit que les estimations ne seront pas tirées par un groupe en particulier.

Structure démographique par genre

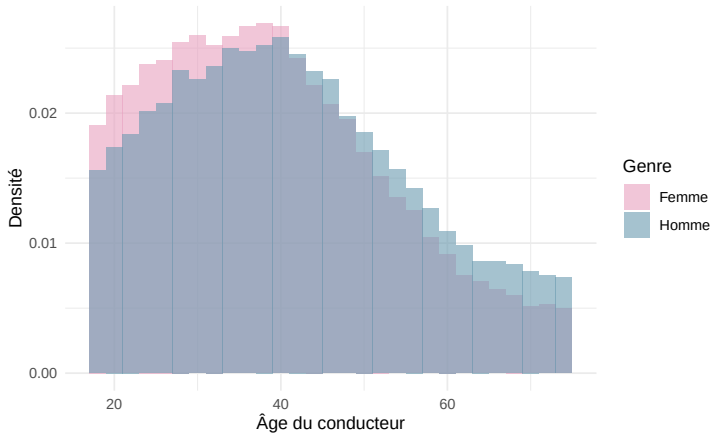


FIGURE 2.4 – Distribution de l'âge par genre

La Figure 2.4 révèle une différence structurelle importante entre les deux groupes. Les femmes sont **surreprésentées dans les tranches d'âge jeunes**, notamment entre 18 et 40 ans, tandis que la distribution masculine est légèrement plus étalée vers les âges intermédiaires. Ce constat nuance l'analyse de la sinistralité par genre : malgré une présence plus forte des femmes chez les jeunes conducteurs, leur fréquence de sinistres reste inférieure à celle des hommes dans toutes les tranches d'âge, comme nous le verrons dans le chapitre suivant. Cela renforce l'idée que le genre capte une information propre, indépendante de la structure d'âge du portefeuille, et que sa suppression constitue une perte d'information qui ne peut pas être entièrement compensée par l'âge seul.

2.2.3 Analyse de la sinistralité globale

Le Tableau 2.5 présente les statistiques globales de sinistralités de nos données.

TABLE 2.5 – Statistiques globales de sinistralité

Indicateur	**Valeur**
Nombre de contrats	100 021
Exposition totale (en années)	89 769
Nombre de sinistres matériels (TPPD)	14 748
Nombre de sinistres corporels (TPBI)	4 680
Fréquence globale TPPD	0,1643

La fréquence globale de sinistres matériels est calculée en rapportant le nombre total de sinistres déclarés à l'exposition totale du portefeuille :

$$\hat{\lambda}_{\text{global}} = \frac{\sum_i \text{Numtppd}_i}{\sum_i \text{expo_an}_i} = \frac{14\,748}{89\,769} = 0{,}1643$$

Ce résultat signifie qu'en moyenne, environ **16,4 assurés sur 100** déclarent un sinistre matériel par an. On notera que l'exposition totale est inférieure au nombre de contrats, confirmant une durée d'observation variable par assuré. L'intégration d'un *offset* dans nos modélisations est donc impérative pour neutraliser ce biais d'exposition.

Structure de la distribution et surdispersion

Au-delà de la moyenne globale, l'analyse de la distribution du nombre de sinistres par contrat (Figure 2.5) révèle une structure de données typique de l'assurance non-vie, dite à *« zéro-inflation »*.

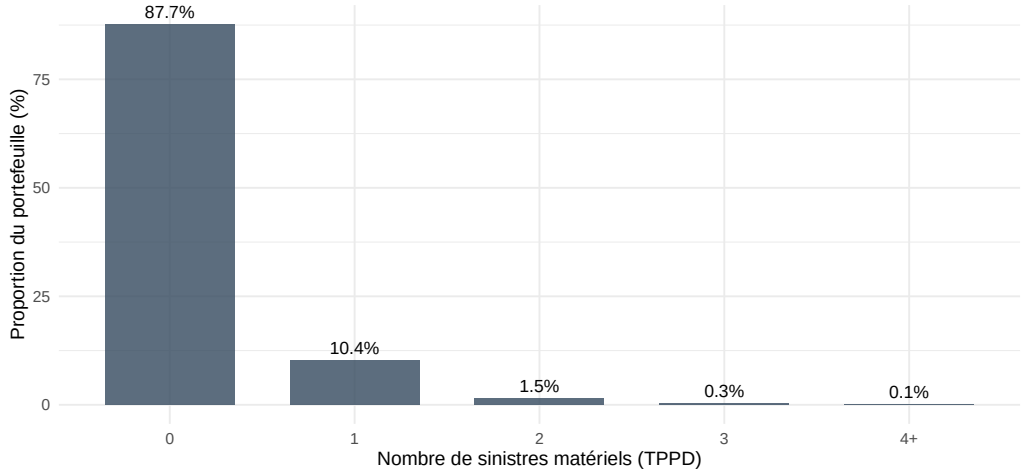


FIGURE 2.5 – Distribution des sinistres matériels.

La grande majorité du portefeuille ($87,7\,\%$) n'a déclaré aucun sinistre sur la période. Toutefois, une minorité de contrats ($1,9\,\%$) présente une sinistralité multiple (2 sinistres ou plus), ce qui impacte significativement la variance du portefeuille.

Pour valider le choix de la loi de probabilité que nous allons utiliser, nous avons calculé les moments empiriques de la distribution :

— **Moyenne empirique ($\hat{\mathbb{E}}$)** : $0,1474$
— **Variance empirique ($\hat{\mathbb{V}}$)** : $0,1909$
— **Ratio de dispersion ($\hat{\mathbb{V}}/\hat{\mathbb{E}}$)** : $1,29$

Ce ratio supérieur à 1 démontre une **surdispersion** statistiquement significative. L'hypothèse d'équidispersion ($\mathbb{V} = \mathbb{E}$) requise par la loi de Poisson (généralement utilisée dans les modèles de fréquence) est ici rejetée. Ce constat justifie mathématiquement le recours à la loi **Binomiale Négative** pour la modélisation de la fréquence, afin de mieux capturer l'hétérogénéité des risques au sein du portefeuille.

2.2.4 Le rôle du genre : une preuve empirique

Le portefeuille étudié, observé entre 2009 et 2010, offre une opportunité d'analyser l'impact réel du genre sur la sinistralité dans des conditions de marché libres. Le Tableau 2.6 synthétise les indicateurs de sinistralité par genre.

TABLE 2.6 – Indicateurs de sinistralité TPPD selon le genre

Genre	Exposition	Nb sinistres	Fréquence	Coût moyen
Femme	32 816	4 521	0,1378	685,89
Homme	56 953	10 227	0,1796	734,80
Écart relatif			**+30,3%**	**+7,1%**

Les résultats révèlent une double asymétrie. D'une part, les hommes affichent une fréquence de **0,1796** contre **0,1378** pour les femmes (soit 4 sinistres de plus pour 100 contrats-années). D'autre part, la sévérité moyenne est également supérieure chez les conducteurs masculins (+7,1 %).

Validation statistique de l'influence du genre

Sur la fréquence : Pour vérifier si l'écart de fréquence entre un homme et une femme est structurel, nous testons l'hypothèse nulle H_0 (indépendance/égalité) contre l'hypothèse alternative H_1 (influence du genre) :

- **Test du χ^2 d'indépendance :** *(H_0 : Le genre et la survenance d'un sinistres sont indépendants).* Le test rejette massivement H_0 ($\chi^2 = 128,34$, $p < 2,2 \times 10^{-16}$), prouvant que la probabilité de sinistre est liée au sexe de l'assuré.
- **Test de Welch sur les fréquences :** *($H_0 : \mu_F = \mu_H$).* En analysant la fréquence annualisée individuelle, le test confirme une différence de moyenne irréfutable ($t = -13,47$, $p < 2,2 \times 10^{-16}$) que nous avons pu aussi observer dans la Table 2.6.

Sur la sévérité : L'étude des coûts ne porte que sur les sinistrés. Nous cherchons à savoir si la sévérité du risque est identique (H_0) ou hétérogène (H_1) :

- **Test de Fisher (Variances) :** *($H_0 : \sigma_F^2 = \sigma_H^2$).* Le test rejette l'homoscédasticité ($F = 0,82$, $p \approx 6,18 \times 10^{-13}$). La variance des coûts féminins est significativement plus faible, traduisant une sinistralité masculine plus volatile et sujette à des sinistres plus graves.
- **Test de Welch (Moyennes) :** *($H_0 : \mu_F = \mu_H$).* En corrigeant le biais de variance, le test confirme que le surcoût moyen masculin est statistiquement significatif ($t = -5,92$, $p \approx 3.2 \times 10^{-9}$), avec une moyenne de 900,73 [1] pour les hommes contre 792,46 pour les femmes au niveau des assurés sinistrés.

Le Genre est-il remplaçable ? (Mesure par le V de Cramer)

S'il est établi que le genre influence le risque, une question cruciale se pose : cette information est-elle unique ou peut-elle être "devinée" via d'autres variables (comme la Profession ou le Type de véhicule) ? Si le genre était fortement corrélé à une autre variable, cette dernière pourrait servir de *proxy* (substitut) pour maintenir la précision du tarif après la réforme.

Pour mesurer cette force d'association, nous utilisons le **V de Cramer** (V). Contrairement au test du χ^2 qui indique seulement si un lien existe, le V de Cramer mesure l'intensité de ce lien sur une échelle de 0 à 1 :

- $V \approx 0$: Les variables sont indépendantes (aucune ressemblance).
- $V > 0,30$: Il existe un lien réel (une variable peut partiellement en remplacer une autre).
- $V \approx 1$: Les variables sont des "clones" (l'une remplace parfaitement l'autre).

1. Les moyennes du test de Welch sont calculées par assuré sinistré, tandis que celles du Tableau 2.6 sont calculées par sinistre. Cette différence, liée aux assurés ayant déclaré plusieurs sinistres sur la période, explique les valeurs plus élevées observées ici.

Les tests effectués sur notre portefeuille révèlent des scores extrêmement faibles :
— **Genre / Profession** : $V = 0,0446$
— **Genre / Type de véhicule** : $V = 0,0053$

Ces résultats démontrent une indépendance quasi totale. Le genre apporte une information **singulière** que ni le métier ni le véhicule ne possèdent. Supprimer le genre revient donc à supprimer une donnée irremplaçable, ce qui dégradera inévitablement la segmentation du tarif et créera un risque d'**antisélection**.

2.2.5 Analyse des variables explicatives clés

Après avoir établi l'influence du genre sur la sinistralité, il convient d'examiner les autres variables explicatives retenues dans notre modélisation. Pour chacune d'elles, l'objectif est double : vérifier qu'elle exerce bien un effet significatif sur la fréquence et le coût moyen des sinistres, et identifier la nature de cet effet ; linéaire ou non.

L'âge : une non-linéarité marquée sur la fréquence

L'âge du conducteur est l'une des variables les plus structurantes du portefeuille. L'analyse du Tableau 2.7 met en évidence deux comportements distincts selon qu'on s'intéresse à la fréquence ou au coût moyen.

TABLE 2.7 – Indicateurs de sinistralité TPPD par tranche d'âge

Tranche d'âge	Exposition	Nb sinistres	Fréquence	Coût moyen
18–25 ans	13 795	4 797	0,348	873 €
26–35 ans	21 451	4 204	0,196	668 €
36–45 ans	22 405	2 853	0,127	600 €
46–55 ans	16 298	1 718	0,105	628 €
56–65 ans	9 477	733	0,077	657 €
65 ans et +	6 342	443	0,070	780 €

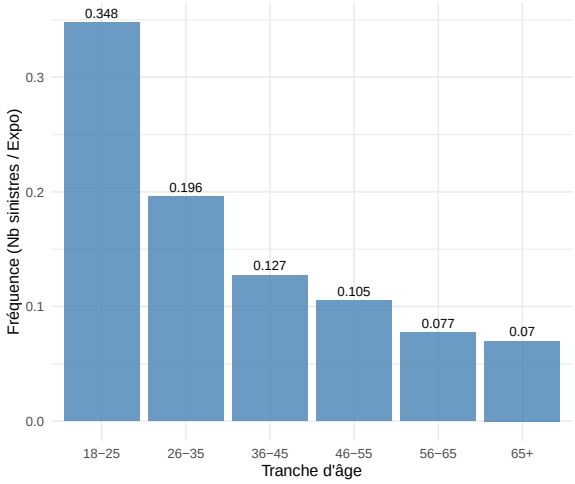


FIGURE 2.6 – Fréquence de sinistres par tranche d'âge

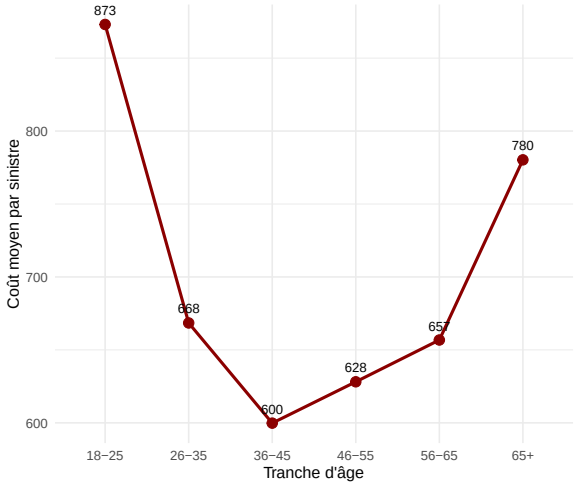


FIGURE 2.7 – Coût moyen par tranche d'âge

Sur la **fréquence**, la relation est monotone décroissante et fortement non linéaire. Les conducteurs de 18–25 ans affichent une fréquence de 0,348, soit cinq fois supérieure à celle des 65 ans et plus. La chute est particulièrement brutale entre 18 et 35 ans ; la fréquence est divisée par presque deux en une seule tranche, avant de se stabiliser progressivement à partir de 36 ans.

Sur le **coût moyen**, le comportement est en revanche en forme de U. Il décroît de 873 € chez les 18–25 ans jusqu'à son minimum de 600 € chez les 36–45 ans, puis remonte régulièrement pour atteindre 780 € chez les 65 ans et plus (Figure 2.7). Ce rebond chez les seniors est un résultat intéressant : si l'âge réduit clairement la probabilité d'avoir un accident, il n'en diminue pas la gravité une fois celui-ci survenu.

Le CRM : la mémoire du risque individuel

Le coefficient de réduction-majoration (CRM) résume l'historique sinistral de chaque assuré : un CRM faible récompense les bons conducteurs, un CRM élevé pénalise les plus accidentogènes. Le Tableau 2.8 confirme que cette variable est l'une des plus discriminantes du portefeuille.

TABLE 2.8 – Indicateurs de sinistralité TPPD par tranche de CRM

Tranche de CRM	Exposition	Nb sinistres	Fréquence
0,50	22 114	1 482	0,067
0,51–0,70	23 232	1 732	0,075
0,71–1,00	19 357	3 689	0,191
1,01–1,50	13 788	3 373	0,245
> 1,50	11 279	4 472	0,397

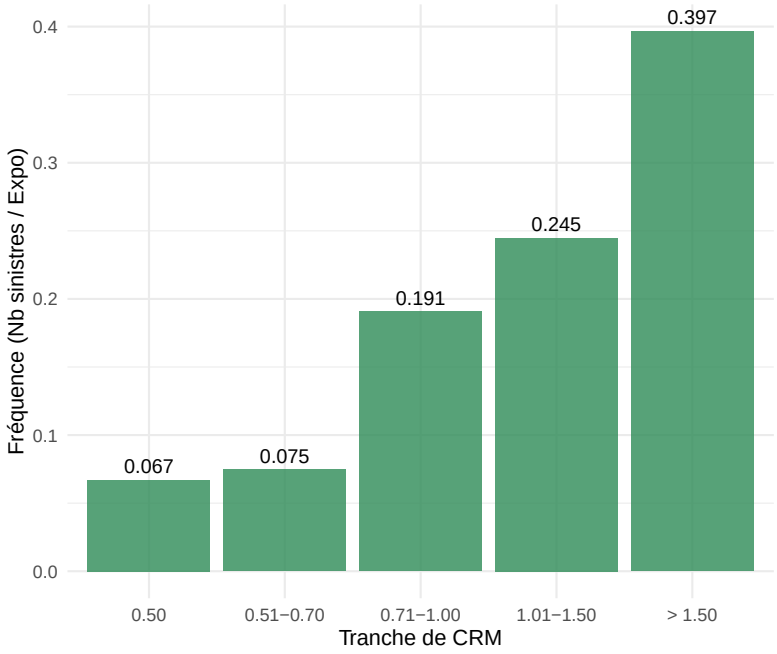


FIGURE 2.8 – Fréquence de sinistres par tranche de CRM

La relation entre le CRM et la fréquence est croissante et particulièrement marquée : les assurés au bonus maximal (CRM = 0,50) affichent une fréquence de 0,067, contre 0,397 pour ceux dont le CRM dépasse 1,50, soit près de six fois plus. La progression est de surcroît non linéaire : la fréquence reste quasi stable entre les deux premières tranches, puis s'accélère nettement à partir du seuil de 0,71. Ce saut autour du coefficient neutre, qui marque le passage du bonus au malus, traduit un changement de profil comportemental que le modèle devra capter.

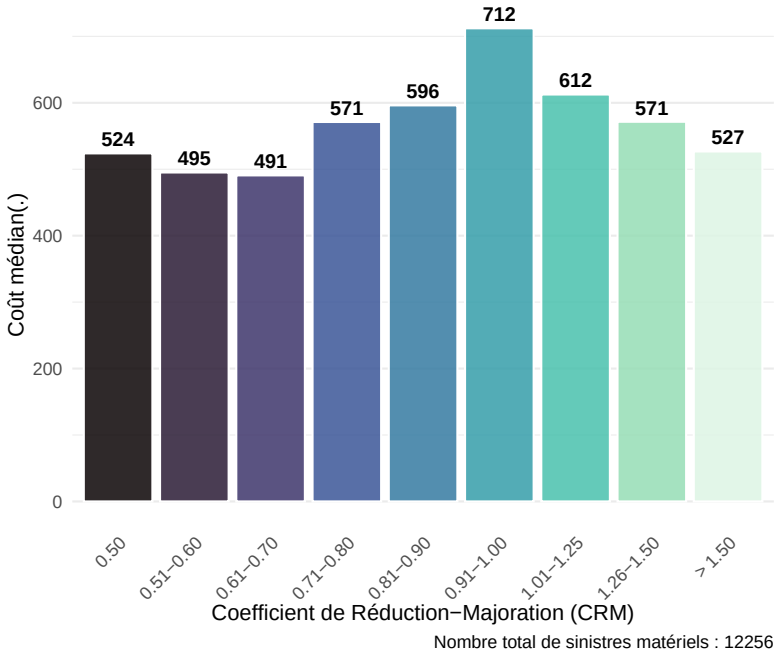


FIGURE 2.9 – Coût moyen des sinistres par tranche de CRM

L'étude de la sévérité s'appuie ici sur la médiane plutôt que sur la moyenne, cette dernière étant particulièrement sensible aux sinistres extrêmes susceptibles de déformer la distribution. La Figure 2.9 met en évidence un pic marqué sur la tranche de CRM (0,91 ;1,00) avec un coût médian de 712€, soit un surcoût de 36 % par rapport aux assurés bénéficiant du bonus maximal (524€). Paradoxalement, cette sévérité recule ensuite pour s'établir à 527€ pour les malus les plus élevés ($> 1,50$).

Ce phénomène, de prime abord contre-intuitif, s'explique par la composition naturelle des segments : alors que les très hauts malus correspondent souvent à des sinistrants fréquents dont les accidents restent de faible ampleur matérielle, la tranche pivot concentre des conducteurs novices ou des profils ayant récemment dégradé leur bonus. Pour ces derniers, l'inexpérience ou une baisse de vigilance ponctuelle se traduit par des accidents certes plus rares, mais nettement plus sévères. Malgré cette singularité, la tendance globale de la sévérité reste cohérente avec l'évolution du CRM, justifiant ainsi un traitement linéaire de cette variable dans la phase de modélisation de la sévérité.

La densité de population : un effet régulier sur la fréquence et la sévérité

La densité de population capte l'intensité du trafic et la complexité de l'environnement de conduite. Le Tableau 2.9 et les figures associées montrent que cette variable agit de manière cohérente sur les deux composantes du risque.

TABLE 2.9 – Indicateurs de sinistralité TPPD par tranche de densité

Tranche de densité (hab./km²)	**Exposition**	**Nb sinistres**	**Fréquence**	**Coût moyen**
< 50	21 778	2 384	0,109	650 €
50–100	25 203	3 185	0,126	665 €
100–200	24 171	4 316	0,179	724 €
200–500	18 617	4 863	0,261	786 €

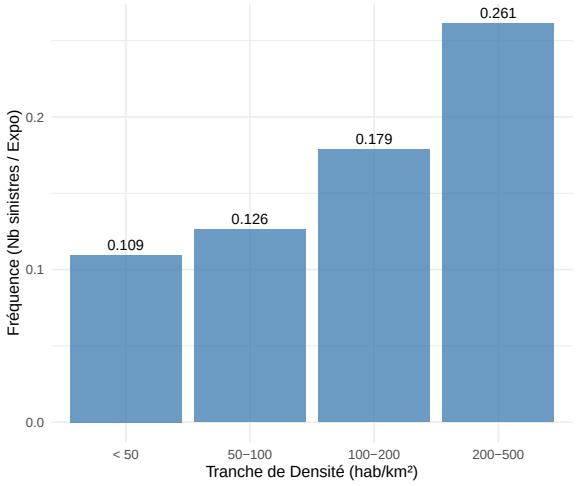


FIGURE 2.10 – Fréquence de sinistres par tranche de densité

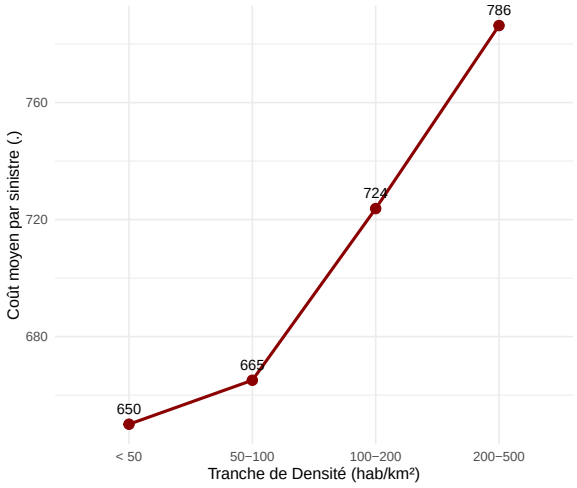


FIGURE 2.11 – Coût moyen par tranche de densité

Sur la **fréquence**, la relation est croissante et régulière : elle passe de 0,109 en zone rurale (< 50 hab./km²) à 0,261 en zone dense (200–500 hab./km²), soit plus de 2 fois plus. La progression est relativement stable d'une tranche à l'autre, ce qui suggère une relation quasi linéaire contrairement à l'âge ou au CRM. Ce comportement est cohérent avec l'intuition : plus le trafic est dense, plus la probabilité de collision est élevée.

Sur le **coût moyen**, la densité se distingue des autres variables par une relation elle aussi croissante et plutôt régulière : le coût passe de 650 € en zone rurale à 786 € en zone très dense. Ce résultat est interprétable directement : en milieu urbain, les sinistres impliquent davantage de véhicules tiers, de mobilier urbain et de piétons, ce qui alourdit mécaniquement leur coût.

L'occupation : des profils de risque contrastés

La profession de l'assuré reflète indirectement son exposition au risque : ses habitudes de mobilité, la fréquence et le type de trajets effectués, ou encore son rapport au risque. Le Tableau 2.10 révèle des disparités importantes entre les cinq catégories du portefeuille.

TABLE 2.10 – Indicateurs de sinistralité TPPD par catégorie professionnelle

Occupation	**Exposition**	**Nb sinistres**	**Fréquence**	**Coût moyen**
Sans emploi	13 759	3 111	0,226	875 €
Au foyer	17 948	3 564	0,199	569 €
Employé	27 937	5 163	0,185	704 €
Indépendant	18 316	2 419	0,132	717 €
Retraité	11 808	491	0,042	1 013 €

L'analyse croisée de la fréquence et du coût moyen révèle des comportements distincts selon les catégories.

Sur le plan de la **fréquence**, l'écart entre extrêmes est saisissant : les personnes sans emploi affichent le taux le plus élevée (0,226), soit plus de cinq fois celui des retraités (0,042). Les indépendants se distinguent par une sinistralité fréquentielle modérée (0,132), cohérente avec une conduite probablement plus occasionnelle et maîtrisée du fait d'enjeux professionnels.

Sur le plan du **coût moyen**, deux profils se distinguent particulièrement. Les retraités enregistrent le coût unitaire le plus élevé du portefeuille (1 013 €) malgré leur fréquence très faible, confirmant une tendance déjà observée dans l'analyse par âge : les conducteurs seniors ont moins d'accidents, mais ceux-ci sont en moyenne plus graves. À l'opposé, les personnes au foyer présentent le profil caractéristique d'une sinistralité de proximité : fréquente (0,199) mais peu sévère (569 €), probablement liée à des trajets courts en milieu urbain ou périurbain. Les personnes sans emploi constituent la catégorie la plus coûteuse pour l'assureur, combinant la fréquence la plus élevée et un coût moyen parmi les plus importants (875 €).

Ces disparités, bien que significatives, ne sauraient se substituer à l'information apportée par le genre dans la segmentation tarifaire. Le V de Cramer calculé précédemment ($V = 0{,}045$) a démontré une quasi-indépendance entre les deux variables : l'occupation capte un mode de vie et un type de trajets, là où le genre reflète des comportements de conduite distincts. Un assuré "au foyer" n'est pas statistiquement assimilable à une assurée femme, les données le confirment. L'occupation enrichit ainsi la segmentation sans pour autant la remplacer.

Absence de multicolinéarité entre les variables

Préalablement à la phase de modélisation, il est important de s'assurer de l'absence de corrélations excessives entre les prédicteurs. En effet, lorsque deux variables explicatives sont quasi redondantes, le modèle aura du mal à dissocier leurs contributions respectives. Ce phénomène, appelé **multicolinéarité** engendre une instabilité des coefficients et complexifie l'interprétation finale des résultats.

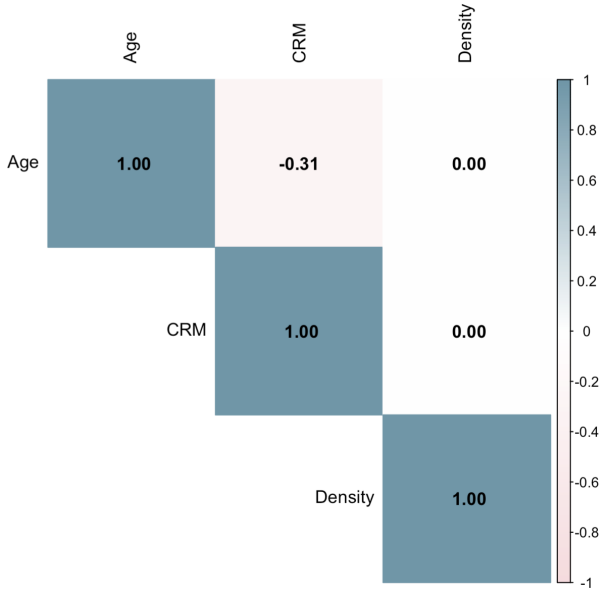


FIGURE 2.12 – Matrice de corrélation entre les variables continues

La matrice de corrélation (Figure 2.12) est rassurante. La corrélation la plus notable est celle entre l'âge et le CRM($-0{,}31$), traduisant une tendance où les conducteurs plus âgés présentent un historique de sinistralité plus favorable, et donc un CRM plus faible. Bien que ce soit la corrélation la plus marquée, sa valeur reste modérée et ne compromet pas la capacité du modèle à isoler l'effet propre de chaque variable. Enfin, la densité est indépendante de l'ensemble des autres variables. Ensemble, ces résultats valident l'inclusion simultanée de toutes ces variables dans les modèles sans risque de biais lié à la multicolinéarité.

2.2.6 Synthèse

L'analyse de la base de données révèle une sinistralité matérielle caractérisée par une forte proportion de "zéro-sinistre" et une surdispersion. Ce constat impose l'usage d'une loi Binomiale Négative plutôt qu'une loi Poisson pour la modélisation de la fréquence, ainsi que l'intégration d'un offset pour l'exposition.

Concernant les déterminants du risque, l'analyse met en évidence le rôle prédominant du CRM et de l'âge, si ce dernier présente une décroissance non linéaire de la fréquence et un coût moyen en "U", le CRM s'impose comme le prédicteur le plus discriminant avec une fréquence multipliée par six entre les profils extrêmes. Par ailleurs, le genre induit un écart de fréquence structurel en faveur des hommes, sans que cette information ne puisse être substituée par la profession ou le véhicule au vu des faibles scores du V de Cramer. Enfin, la densité de population et la catégorie professionnelle complètent ce tableau en influençant linéairement le risque pour la première, et en révélant des profils de sévérité atypiques pour la seconde, notamment chez les retraités.

L'absence de multicolinéarité critique entre ces variables, combinée à l'identification de relations non linéaires marquées, valide méthodologiquement la transition d'une structure GLM classique vers une approche GAM par fonction de lissage.

Chapitre 3

Modélisation actuarielle et impacts tarifaires

3.1 Création des modèles

L'analyse descriptive menée dans la section précédente a permis d'identifier les variables les plus pertinentes et de caractériser la structure du risque au sein du portefeuille. Nous passons à présent à l'étape de modélisation, dont l'objectif est de traduire ces relations empiriques en un tarif technique rigoureux. Deux modèles sont construits en parallèle : un modèle genré, qui sert de référence technique, et un modèle unisexe, conforme aux exigences réglementaires de la Gender Directive.

Conformément à la pratique actuarielle standard, la prime pure est décomposée en deux composantes modélisées séparément : la **fréquence** (probabilité de survenance d'un sinistre) et la **sévérité** (coût moyen conditionnel à la survenance). Cette décomposition permet d'identifier précisément sur quelle composante la suppression du genre exerce le plus d'impact.

Validation statistique de la loi de distribution

Le choix de la loi de probabilité conditionne directement la précision du tarif final. Comme mis en évidence lors de l'analyse descriptive, la distribution du nombre de sinistres présente un ratio de dispersion : $\hat{V}/\hat{E} = 1{,}29$, révélant une surdispersion structurelle du portefeuille.

Ce constat exclut l'usage de la loi de Poisson, dont l'hypothèse d'équidispersion ($\mathbb{E}(Y) = \mathbb{V}(Y)$) n'est pas respectée ici. Retenir malgré tout cette loi conduirait à sous-estimer la volatilité du risque.

Nous retenons donc la loi **Binomiale Négative**, qui introduit un paramètre de dispersion θ permettant d'ajuster la variance indépendamment de la moyenne selon la relation :

$$\mathbb{V}[N] = \mathbb{E}[N] + \frac{\mathbb{E}[N]^2}{\theta}$$

Ce choix garantit une représentation fidèle de l'hétérogénéité des risques au sein du portefeuille, condition nécessaire à la robustesse des modèles qui suivent.

Vérification de la multicolinéarité (Test VIF)

Avant de valider nos modèles, nous avons testé l'indépendance des variables explicatives à l'aide du test GVIF (*Generalized Variance Inflation Factor*). Ce test est crucial pour s'assurer qu'aucune variable n'est une combinaison linéaire d'une autre, ce qui rendrait les coefficients instables.

TABLE 3.1 – Analyse de la colinéarité (Indice GVIF)

Variable	**GVIF**	**Df**	**GVIF**$^{1/(2\times Df)}$
Gender	1,005	1	1,002
Age	1,577	1	1,256
CRM	1,048	1	1,024
Density	1,000	1	1,000
Occupation	1,530	4	1,054

L'ensemble des valeurs de la colonne corrigée est extrêmement proche de 1. En règle générale, un indice supérieur à 5 indiquerait une colinéarité problématique. Ces résultats confirment que chaque prédicteur apporte une information propre au modèle. Notamment, le GVIF très faible du **genre** (1,005) démontre que cette variable est totalement indépendante des autres prédicteurs. Cela renforce la pertinence de notre comparaison entre les modèles G et U : la suppression du genre dans le modèle unisexe ne risque pas de biaiser les coefficients des variables restantes.

3.1.1 Modèle de fréquence (GLM)

La fréquence de sinistres est modélisée à partir des variables retenues lors de l'analyse descriptive : l'âge, le CRM, la densité de population, le genre et la catégorie socioprofessionnelle. L'exposition en années est intégrée sous forme d'un offset, de façon à ramener les prédictions à une fréquence annualisée. Nous développons simultanément deux modèles fondés sur une structure log-linéaire ; l'impact de chaque variable explicative est ainsi modélisé par un coefficient multiplicateur constant appliqué à la fréquence de sinistres espérée :

— **Le modèle G (Genré)** : intégrant le genre, il sert de base technique pour quantifier le risque observé.
— **Le modèle U (Unisexe)** : excluant le genre, il simule l'impact de la contrainte réglementaire sur la structure tarifaire.

Le Modèle G (Genré)

Cette première spécification mobilise l'intégralité des variables explicatives retenues. En incluant le genre, ce modèle reflète la structure réelle de la sinistralité du portefeuille avant l'application des contraintes de la *Gender Directive*.

TABLE 3.2 – Résultats du modèle de fréquence Genré (Binomiale Négative)

Variable	**Estimation**	**Erreur Type**	**t-value**	**Pr(>|t|)**
(Intercept)	−2,564	0,040	−63,75	$< 2 \times 10^{-16}$
Gender (Male)	+0,335	0,019	17,87	$< 2 \times 10^{-16}$
Age	−0,031	0,001	−36,62	$< 2 \times 10^{-16}$
CRM	+0,999	0,015	68,65	$< 2 \times 10^{-16}$
Density	+0,004	0,000	41,04	$< 2 \times 10^{-16}$
Occ. (Housewife)	+0,263	0,023	11,25	$< 2 \times 10^{-16}$
Occ. (Retired)	−0,476	0,053	−8,97	$< 2 \times 10^{-16}$
Occ. (Self-employed)	−0,144	0,026	−5,54	$3{,}01 \times 10^{-8}$
Occ. (Unemployed)	+0,195	0,024	8,07	$7{,}10 \times 10^{-16}$
AIC	77 744			
BIC	77 840			
Theta (θ)	2,564			
Déviance résiduelle	46 940 (sur 100 012 degrés de liberté)			

Toutes les variables sont hautement significatives au seuil 0,1%, ce qui valide *a posteriori* les choix de modélisation opérés lors de l'analyse descriptive.

Interprétation des coefficients du Modèle G

L'âge exerce un effet protecteur régulier : chaque année supplémentaire réduit la fréquence d'un facteur $\exp(-0{,}031) \approx 0{,}970$, soit une baisse de **3% par an**. Sur dix ans, cela représente une diminution cumulée de près de 26% du risque, ce qui confirme l'importance de l'expérience de conduite dans la structuration du portefeuille.

Le genre masculin est associé à une fréquence supérieure d'un facteur $\exp(0{,}335) \approx 1{,}398$, soit environ **40% de sinistres supplémentaires** par rapport aux femmes, à profil identique. Avec une t-value de 17,87, c'est l'un des coefficients les plus robustes du modèle. C'est précisément ce coefficient que le passage au modèle unisexe va supprimer, forçant le modèle à redistribuer cet écart sur les autres variables.

Le **CRM** s'impose comme la variable la plus prédictive du modèle. Mathématiquement, son coefficient proche de 1 indique une relation presque directe entre le malus et la sinistralité. Concrètement, chaque point de CRM supplémentaire multiplie la fréquence d'accident par environ 2,72, soit $\exp(0{,}999)$. À titre d'exemple, un conducteur ayant un CRM de 2,0 (fort malus) présente une fréquence d'accident plus de deux fois supérieure à celle d'un conducteur avec un CRM de 1,0. Le CRM demeure ainsi le levier principal pour segmenter le risque au sein de ce portefeuille.

L'effet de **la densité** est positif et constant sur l'ensemble de la distribution. Le modèle estime qu'une augmentation d'une unité de densité se traduit par un facteur multiplicatif de 1,004 (soit +0,4 % par habitant/km^2). À l'échelle du spectre de variation des données,

cette variable possède un fort pouvoir discriminant, capable de multiplier par deux la fréquence espérée entre les zones les moins peuplées et les centres urbains denses.

L'occupation confirme les disparités observées en analyse descriptive. Les retraités bénéficient de la fréquence la plus basse ($\exp(-0{,}476) \approx 0{,}621$), soit -38% par rapport à la catégorie de référence (Employés), tandis que les personnes au foyer et les sans-emploi présentent respectivement un sur-risque de $+30\%$ et $+22\%$.

Le Modèle U (Unisexe)

Le modèle **U** est estimé en excluant la variable genre, conformément aux exigences de la *Gender Directive*. L'enjeu ici n'est pas d'améliorer la performance statistique (une dégradation de la précision étant attendue par construction) mais de quantifier rigoureusement le coût de cette contrainte réglementaire. Il s'agit d'analyser la résilience du modèle face à l'absence d'une variable aussi structurante et d'observer les mécanismes de report du risque sur les autres variables explicatives.

Table 3.3 – Résultats du modèle de fréquence Unisexe (Binomiale Négative)

Variable	**Estimation**	**Erreur Type**	**t-value**	**Pr(>|t|)**
(Intercept)	$-2{,}364$	0,039	$-61{,}24$	$< 2 \times 10^{-16}$
Age	$-0{,}030$	0,001	$-35{,}74$	$< 2 \times 10^{-16}$
CRM	$+0{,}998$	0,015	68,22	$< 2 \times 10^{-16}$
Density	$+0{,}004$	0,000	40,88	$< 2 \times 10^{-16}$
Occ. (Housewife)	$+0{,}261$	0,023	11,10	$< 2 \times 10^{-16}$
Occ. (Retired)	$-0{,}475$	0,053	$-8{,}93$	$< 2 \times 10^{-16}$
Occ. (Self-employed)	$-0{,}146$	0,026	$-5{,}57$	$2{,}58 \times 10^{-8}$
Occ. (Unemployed)	$+0{,}193$	0,024	7,95	$1{,}81 \times 10^{-15}$
AIC		78 070		
BIC		78 156		
Theta (θ)		2,314		
Déviance résiduelle		46 820 (sur 100 013 degrés de liberté)		

La première observation est la **remarquable stabilité des coefficients** : l'âge, le CRM, la densité et l'occupation conservent des valeurs quasi identiques à celles du modèle G. Ce résultat n'est pas anodin, il confirme que le genre est totalement indépendant des autres variables, comme l'avait suggéré le test GVIF. Sa suppression ne crée pas de biais sur les autres estimateurs : elle se traduit uniquement par une hausse de la constante (qui passe de $-2{,}564$ à $-2{,}364$, soit $+0{,}2$), qui absorbe mécaniquement le risque moyen non capté en l'absence de distinction homme/femme.

On observe également une légère baisse du paramètre de dispersion θ, qui passe de 2,564 à 2,314. Cela indique que le modèle unisexe rencontre une plus grande difficulté à expliquer les différences entre les assurés, car il ne peut plus s'appuyer sur le genre pour distinguer les profils. Cette augmentation du "hasard" dans les résultats est la conséquence directe de la suppression d'une variable aussi efficace. En résumé, si la précision globale du modèle diminue légèrement, le reste de sa structure demeure solide et n'est pas faussé par ce changement.

3.1.2 Modèle de sévérité (GLM)

Le modèle de sévérité est estimé sur la base restreinte aux contrats ayant déclaré au moins un sinistre et un coût strictement positif, soit **12 256 contrats** après exclusion des sinistres déclarés sans indemnisation.

La variable à expliquer est le coût moyen par sinistre :

$$\hat{\mu}_i = \frac{\texttt{Indtppd}_i}{\texttt{Numtppd}_i}$$

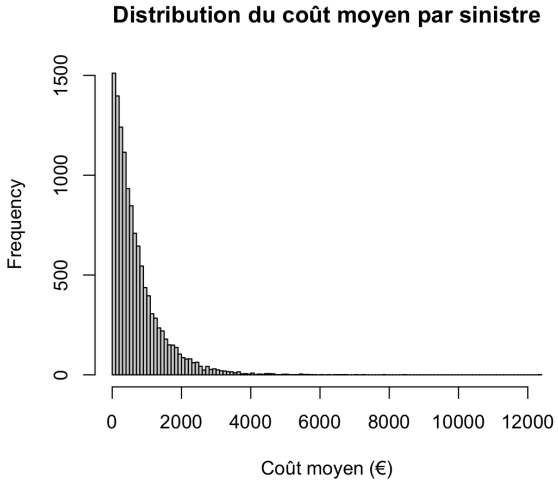


FIGURE 3.1 – Distribution du coût moyen par sinistre

La distribution du coût moyen présente une forte asymétrie à droite caractéristique des coûts de sinistres en assurance automobile : la médiane (494€) est nettement inférieure à la moyenne (714€), et la queue de distribution s'étend jusqu'à 12 325€. Cette forme oriente naturellement vers l'utilisation d'une **loi Gamma** avec fonction de lien logarithmique, qui présente deux propriétés adaptées à notre contexte : elle est définie sur $\mathbb{R}^+$, garantissant des prédictions strictement positives, et elle accommode naturellement l'asymétrie à droite observée.

Résultats et comparaison des modèles

Nous comparons à nouveau un modèle de sévérité genré (G) et un sévérité modèle unisexe (U) via un GLM de loi Gamma à lien logarithmique.

TABLE 3.4 – Résultats du modèle de sévérité (Loi Gamma)

	Modèle G (Genré)		**Modèle U (Unisexe)**	
Variable	**Estimateur**	**t-value**	**Estimateur**	**t-value**
(Intercept)	6,883	171,54	6,936	185,86
Gender (Male)	+0,071	3,75	—	—
Age	−0,01	−13,04	−0,01	−13,07
CRM	−0,17	−11,13	−0,172	−11,23
Density	+0,001	7,98	+0,001	7,88
Occ. (Housewife)	−0,156	−6,56	−0,157	−6,6
Occ. (Retired)	+0,654	12,43	+0,653	12,41
Occ. (Self-employed)	+0,082	3,12	+0,08	3,02
Occ. (Unemployed)	+0,207	8,44	+0,205	8,35
AIC	185 042		185 054	
BIC	185 116		185 121	
Déviance résiduelle	13 092		13 105	

Interprétation des coefficients L'interprétation des coefficients s'effectue selon la même logique que celle appliquée aux modèles de fréquence. Afin de garantir la concision de l'analyse, nous ne détaillerons pas systématiquement chaque estimation pour l'ensemble des modèles présentés ; nous nous attacherons toutefois à commenter les résultats les plus significatifs une ou deux fois, afin de démontrer la bonne compréhension des mécanismes à l'œuvre.

L'effet paradoxal du CRM : contrairement à la fréquence, le coefficient du CRM est négatif (−0,170). Cela signifie qu'à chaque point de malus supplémentaire, le coût moyen du sinistre diminue d'un facteur $\exp(-0{,}170) \approx 0{,}844$, soit une baisse de **16%**. Ce phénomène, classique en actuariat, suggère que les conducteurs avec un fort malus ont des accidents plus fréquents, mais souvent moins graves (petits chocs urbains), tandis que les « bons » conducteurs ont des accidents rares mais potentiellement plus coûteux.

Le profil des retraités : alors qu'ils affichaient la fréquence la plus basse, les retraités présentent ici le coût moyen le plus élevé ($\exp(0{,}654) \approx 1{,}923$, soit +92% par rapport à la catégorie de référence : Employed). Un sinistre impliquant un retraité coûte en moyenne près du double d'un sinistre de référence, illustrant parfaitement la dissociation entre fréquence et sévérité qui justifie leur modélisation séparée.

L'impact du genre : le genre masculin reste un facteur aggravant, mais de manière beaucoup moins marquée que pour la fréquence. Un homme présente une sévérité supérieure de $\exp(0{,}071) \approx 1{,}074$, soit +7% par rapport à une femme à profil identique. Le coefficient reste significatif, mais sa contribution à la discrimination tarifaire est nettement plus limitée.

L'âge et la densité : l'âge conserve son effet protecteur avec une baisse de 1% par an sur le coût moyen, et la densité accroît légèrement la sévérité de 0,08% par unité.

Ces variations, bien que minimes lorsqu'elles sont prises isolément, s'avèrent hautement significatives une fois cumulées sur toute l'étendue des données.

Conclusion sur les modèles de sévérité : le modèle genré demeure statistiquement supérieur (AIC inférieur de 12 points, BIC inférieur de 5 points). Toutefois, cet écart est négligeable par rapport à celui observé pour la fréquence. La variable genre s'avère donc être un prédicteur nettement moins puissant pour le coût moyen que pour la probabilité d'accident.

3.1.3 Comparaison statistique des modèles G et U

Avant d'examiner les impacts tarifaires, il est nécessaire de déterminer si le retrait du genre occasionne une perte d'information statistique significative. Pour cela, nous comparons les modèles à l'aide de deux indicateurs complémentaires : l'AIC et le BIC. Ces deux critères mesurent la qualité d'un modèle en pénalisant sa complexité ; le BIC étant plus sévère que l'AIC, et donc mieux adapté aux grands échantillons.

Analyse de la perte d'information (Fréquence)

TABLE 3.5 – Comparaison des performances : Fréquence (Binomiale Négative)

Modèle	**AIC**	**BIC**	**Déviance Résiduelle**	**Degrés de liberté**
Modèle G (Genré)	77 744	77 840	46 940	100 012
Modèle U (Unisexe)	78 070	78 156	46 820	100 013
Écart (Δ)	**+326**	**+316**	**−120**	**+1**

L'AIC augmente de 326 points dans le modèle unisexe, et le BIC confirme cette conclusion (+316 points). En statistiques, une hausse de l'AIC supérieure à 10 points est généralement considérée comme une dégradation considérable de la qualité prédictive. L'ampleur de l'écart observé ici confirme sans ambiguïté que le genre est un segmentateur de risque « pur » dans ce portefeuille : l'information qu'il porte n'est pas substituable par les autres variables disponibles.

La légère baisse de la déviance résiduelle dans le modèle U (-120 points) peut paraître contre-intuitive. Elle s'explique par la diminution du paramètre θ (2,564 $\rightarrow$ 2,314) : en l'absence du genre, le modèle autorise une variance résiduelle plus importante, ce qui lui permet d'absorber une part de l'hétérogénéité non expliquée via la structure de dispersion plutôt que via les coefficients. Ce mécanisme illustre le compromis biais-variance inhérent à toute contrainte imposée sur un modèle.

Analyse de la perte d'information (Sévérité)

TABLE 3.6 – Comparaison des performances : Sévérité (Loi Gamma)

Modèle	**AIC**	**BIC**	**Déviance Résiduelle**	**Degrés de liberté**
Modèle G (Genré)	185 042	185 116	13 092	12 247
Modèle U (Unisexe)	185 054	185 121	13 105	12 248
Écart (Δ)	**+12**	**+5**	**+13**	**+1**

Contrairement à la fréquence, la perte d'information sur la sévérité est quasi négligeable (ΔAIC = +12, ΔBIC = +5). Ces écarts, bien que statistiquement significatifs, sont sans commune mesure avec ceux observés pour la fréquence. Cela démontre que le genre influence principalement la probabilité de survenance d'un accident, mais très peu le montant des dommages une fois le sinistre survenu.

Synthèse

TABLE 3.7 – Impact comparé du genre sur la fréquence et la sévérité

Composante	**Coefficient**	**Effet multiplicatif**	**ΔAIC**	**Significativité**
Fréquence	+0,335	$\times$ 1,398 (+39,8%)	+326	$< 2 \times 10^{-16}$
Sévérité	+0,071	$\times$ 1,074 (+7,4%)	+12	$1{,}81 \times 10^{-4}$

Le genre agit de manière très asymétrique selon la composante considérée : son effet sur la fréquence est **environ cinq fois plus élevé** que sur la sévérité. Ce résultat s'inscrit dans la lignée de la littérature actuarielle, qui montre que les différences de comportement entre genres se traduisent avant tout dans la propension à être impliqué dans un accident, plutôt que dans la gravité des dommages une fois le sinistre survenu.

Cette asymétrie se reflète clairement dans la dégradation de l'ajustement : la suppression du genre entraîne une perte d'information bien plus limitée pour le modèle de sévérité (ΔAIC = +12) que pour le modèle de fréquence (ΔAIC = +326), même si elle demeure statistiquement significative dans les deux cas.

Ce constat fonde techniquement la suite de l'analyse : le passage à une tarification unisexe affectera principalement la structure de la fréquence, et c'est donc à ce niveau que se concentrera l'essentiel de l'impact tarifaire.

3.1.4 Tests liés aux modèles

Test de lien

Le test de lien vérifie que la fonction de lien choisie (ici logarithmique) est bien adaptée à la structure des données. Il consiste à régresser la variable réponse sur les valeurs ajustées $\hat{y}$ et leur carré $\hat{y}^2$: si le coefficient associé à $\hat{y}^2$ est non significatif, le lien est correctement spécifié.

TABLE 3.8 – Résultats du test de lien

Modèle	**p-valeur ($\hat{y}^2$)**	**Conclusion**
Fréquence (avec genre)	0,089	Lien correct
Fréquence (sans genre)	0,0001	Lien mal spécifié
Sévérité (avec genre)	0,763	Lien correct
Sévérité (sans genre)	0,768	Lien correct

Les modèles de sévérité et le modèle de fréquence avec genre valident tous le lien logarithmique ($p > 0{,}05$). En revanche, le modèle de fréquence sans genre échoue au test ($p = 0,0001$), indiquant que la suppression du genre introduit une mauvaise spécification du lien. Ce résultat constitue un argument supplémentaire en faveur de l'inclusion du genre dans la modélisation.

Test d'hétéroscédasticité

En GLM, le test ARCH n'étant pas applicable, l'hétéroscédasticité est détectée manuellement en régressant les résidus de Pearson au carré sur les valeurs ajustées. Un coefficient significatif traduirait une variance des résidus croissante avec le niveau prédit, en contradiction avec les hypothèses du modèle.

TABLE 3.9 – Résultats du test d'hétéroscédasticité

Modèle	**p-valeur ($\hat{y}$)**	**Conclusion**
Fréquence (avec genre)	0,050	Acceptable
Fréquence (sans genre)	0,160	Homoscédasticité
Sévérité (avec genre)	0,156	Homoscédasticité
Sévérité (sans genre)	0,149	Homoscédasticité

Les quatre modèles ne présentent pas d'hétéroscédasticité significative. Le modèle de fréquence avec genre affiche une p-valeur limite (0,050), mais reste dans les bornes acceptables. Ces résultats confirment que la structure de variance imposée par les lois Binomiale Négative et Gamma est cohérente avec les données.

3.2 Optimisation des modèles et comparaison

Apport du GAM

Motivation et présentation du modèle

Le modèle GLM repose sur une hypothèse forte : la relation entre chaque variable explicative et le logarithme de la variable à expliquer est supposée **linéaire**. Or, rien ne garantit *a priori* que l'effet de l'âge, du CRM ou de la densité sur la sinistralité suive une progression strictement linéaire dans les données. Le modèle additif généralisé (*Generalized Additive Model*, GAM) relâche cette contrainte en remplaçant les effets linéaires par des **fonctions non paramétriques** estimées à partir des données, appelées splines de lissage, dont la forme est déterminée par les observations elles-mêmes plutôt que par une hypothèse paramétrique préalable.

Pour le modèle de fréquence, le GAM s'écrit :

$$\log(\hat{\lambda}_i) = \alpha + f_1(\text{Âge}_i) + \beta \cdot \mathbf{1}_{\text{Homme}} + f_2(\text{CRM}_i) + f_3(\text{Densité}_i) + \beta_{\text{Occupation}} + \log(\text{expo}_i)$$

et pour le modèle unisexe :

$$\log(\hat{\lambda}_i) = \alpha + f_1(\text{Âge}_i) + f_2(\text{CRM}_i) + f_3(\text{Densité}_i) + \beta_{\text{Occupation}} + \log(\text{expo}_i)$$

où f_1, f_2 et f_3 sont des fonctions de lissage estimées librement par pénalisation REML. Pour le modèle de sévérité, seul l'âge est modélisé via une spline, les variables CRM et densité étant conservées sous forme linéaire, conformément à l'hypothèse que leur relation avec le coût moyen est suffisamment régulière pour ne pas nécessiter de flexibilité supplémentaire.

3.2.1 Modèle de fréquence (GAM)

TABLE 3.10 – Résultats des GAM de fréquence (Binomiale Négative)

	Modèle genré	**Modèle unisexe**
Termes paramétriques		
Constante	−2,366	−2,141
Genre (Homme)	+0,333	—
Occ. (Housewife)	+0,26	+0,257
Occ. (Retired)	−0,958	−0,958
Occ. (Self-employed)	−0,139	−0,14
Occ. (Unemployed)	+0,185	+0,183
Termes non paramétriques (edf)		
s(Âge)	7,710	7,711
s(CRM)	4,924	4,988
s(Densité)	8,289	8,270
AIC	76 649	76 975
BIC	76 928	77 245
Déviance expliquée	19,8%	19,3%
R^2 ajusté	0,15	0,14
Tous les termes sont significatifs au seuil 0,1% *(***).*		

La non-linéarité est marquée et concerne les trois variables continues. Les edf sont considérablements supérieurs à 1 pour l'âge, le CRM et la densité, signalant que la relation entre ces variables et la fréquence est donc bien non linéaire. Cette observation invalide alors l'hypothèse de linéarité du GLM sur ces trois dimensions et justifie pleinement le recours au GAM.

Les edf sont quasi identiques entre les modèles genré et unisexe. Pour les trois fonctions de lissage, les degrés de liberté effectifs diffèrent à peine entre les deux modèles. La suppression du genre ne modifie pas la forme des relations non linéaires estimées pour les autres variables, confirmant une nouvelle fois l'indépendance du genre aux autres variables.

Le coefficient du genre reste hautement significatif et stable. Dans le GAM genré, $\beta_{\text{Genre}} = 0{,}333$, quasi identique au coefficient obtenu dans le GLM (0,335). Ce résultat est important : il démontre que l'effet genre mesuré par le GLM n'était pas le simple produit de la contrainte de linéarité. Même en laissant les autres variables s'exprimer librement, le genre conserve une contribution propre et irréductible à la discrimination du risque.

Enfin, l'AIC et le BIC confirment tous deux la supériorité statistique du modèle genré ($\Delta\text{AIC} = 326$, $\Delta\text{BIC} = 317$). Le critère BIC, qui pénalise plus sévèrement la complexité sur de grands échantillons, aboutit à la même conclusion. Ce résultat est crucial car il permet d'écarter l'idée que la performance du modèle genré s'expliquerait par un simple avantage lié à sa parcimonie ; il démontre au contraire que l'ajout du genre apporte un gain d'information réel qui justifie mathématiquement la structure du modèle.

3.2.2 Modèle de sévérité (GAM)

TABLE 3.11 – Résultats des modèles GAM de sévérité (Gamma)

	Modèle genré		**Modèle unisexe**	
Variable	**Coeff.**	**p-value**	**Coeff.**	**p-value**
Termes paramétriques				
Constante	6,521	$< 2 \times 10^{-16}$	6,569	$< 2 \times 10^{-16}$
Genre (Homme)	+0,066	$5{,}14 \times 10^{-4}$	—	—
CRM	−0,147	$< 2 \times 10^{-16}$	−0,148	$< 2 \times 10^{-16}$
Densité	+0,001	$1{,}16 \times 10^{-15}$	+0,001	$2{,}50 \times 10^{-15}$
Occ. (Housewife)	−0,157	$3{,}29 \times 10^{-11}$	−0,159	$2{,}49 \times 10^{-11}$
Occ. (Retired)	+0,546	$< 2 \times 10^{-16}$	+0,542	$< 2 \times 10^{-16}$
Occ. (Self-employed)	+0,082	$1{,}86 \times 10^{-3}$	+0,079	$2{,}55 \times 10^{-3}$
Occ. (Unemployed)	+0,204	$< 2 \times 10^{-16}$	+0,202	$< 2 \times 10^{-16}$
Terme non paramétrique (edf)				
s(Âge)	4,166		4,182	
AIC	184 851		184 862	
BIC	184 952		184 954	
Déviance expliquée	5,30%		5,22%	
R^2 ajusté	0,057		0,056	

Le profil de non-linéarité est très différent de celui observé pour la fréquence.

Seul l'âge présente une non-linéarité significative confirmant que la relation entre l'âge et le coût moyen ne se réduit pas à une simple tendance linéaire. Ce résultat est distinct de celui observé sur la fréquence et justifie pleinement la modélisation séparée des deux composantes : les non-linéarités ne se manifestent pas de la même façon, ni avec la même intensité, sur la probabilité d'accident et sur la gravité des dommages.

Le CRM et la densité sont traités de façon linéaire dans les GAM de sévérité, conformément à la spécification retenue. Cette modélisation s'avère cohérente avec les conclusions des GAM de fréquence, où ces deux variables, bien que non linéaires pour la fréquence, présentent des profils suffisamment réguliers pour être approchés linéairement sur la sévérité.

Le genre reste significatif dans le GAM de sévérité, confirmant que son effet sur le coût moyen n'est pas un produit de la linéarité imposée par le GLM. Toutefois, son coefficient est plus faible que celui observé pour la fréquence, et sa suppression dans le modèle unisexe n'entraîne qu'une dégradation limitée.

3.2.3 Synthèse et comparaison GAM vs GLM

TABLE 3.12 – Synthèse des gains d'AIC du GAM sur le GLM

	Fréquence		**Sévérité**	
Modèle	**AIC**	**ΔAIC vs GLM**	**AIC**	**ΔAIC vs GLM**
GLM genré	77 744	—	185 042	—
GAM genré	**76 649**	**−1 095**	**184 851**	**−191**
GLM unisexe	78 070	—	185 054	—
GAM unisexe	**76 975**	**−1 095**	**184 862**	**−192**
ΔAIC genré vs unisexe	326		11	

Le GAM améliore considérablement l'ajustement pour les deux composantes. Le gain est particulièrement important pour la fréquence ($\Delta\text{AIC} \approx -1\,095$), où les trois variables continues présentent des non-linéarités marquées que le GLM ne pouvait pas capturer. Le gain est plus modéré pour la sévérité ($\Delta\text{AIC} \approx -191$), où seule la spline d'âge contribue à la flexibilité supplémentaire.

Deux conclusions se dégagent de cette comparaison. D'une part, **la supériorité du GAM sur le GLM est significative** : elle est confirmée sur les quatre spécifications (genré et unisexe, fréquence et sévérité) et par les deux critères AIC et BIC. D'autre part, **l'écart entre modèle genré et unisexe reste parfaitement stable** quelle que soit la spécification retenue : 326 points pour la fréquence et 11 points pour la sévérité, en parfait accord avec les conclusions des GLM. La perte d'information liée à la suppression du genre est donc une caractéristique structurelle du portefeuille, indépendante du choix de la famille de modèles.

3.2.4 Visualisation des effets partiels : confirmation graphique de la supériorité du GAM

Afin de compléter la comparaison statistique fondée sur les critères AIC et BIC, nous représentons graphiquement les effets partiels estimés par le GLM et le GAM pour chaque variable continue. Cette approche permet de visualiser directement ce que les degrés de liberté effectifs (edf) quantifient de manière abstraite : la nature et l'intensité des non-linéarités captées par le modèle flexible.

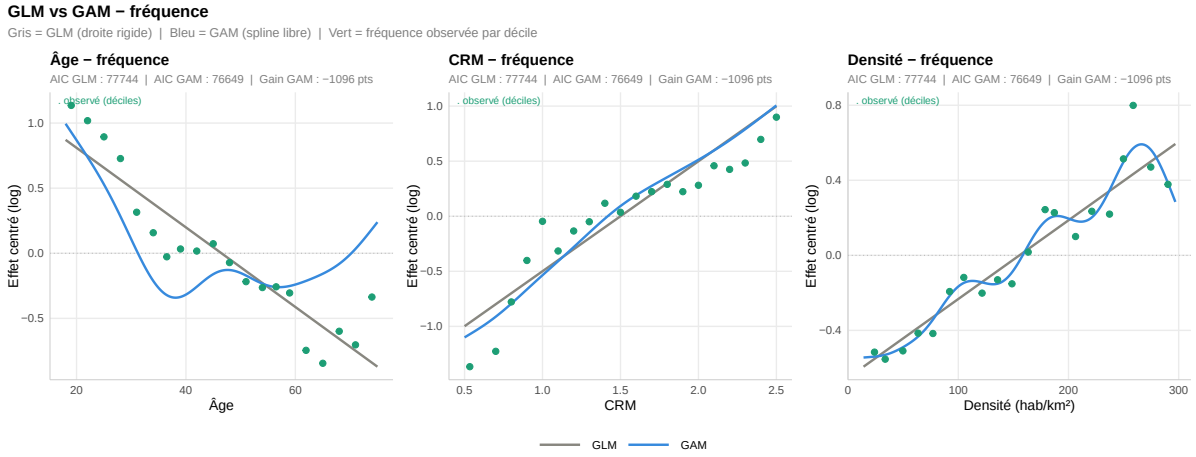


FIGURE 3.2 – Effets partiels estimés — Fréquence

Fréquence des sinistres : La Figure 3.2 superpose, pour chaque variable, la droite rigide du GLM (gris) et la spline libre du GAM (bleu), ainsi que la fréquence empirique observée par décile (points verts), qui constitue la référence à expliquer.

Sur la variable **âge**, l'écart entre les deux modèles est le plus saisissant. Le GLM contraint l'effet à une droite décroissante régulière. Le GAM, en revanche, révèle une structure en deux temps : une chute brutale de la fréquence entre 18 et 35 ans, suivie d'un palier progressif au-delà de 40 ans, avec une légère remontée en fin de distribution. Les points empiriques s'alignent nettement sur la courbe GAM et s'écartent systématiquement de la droite GLM, particulièrement aux deux extrémités de la distribution. Ce résultat confirme que la contrainte de linéarité imposée par le GLM constitue une approximation structurellement incorrecte pour cette variable.

Sur la variable **CRM**, les deux courbes sont proches sur la plage centrale mais divergent aux extrêmes. Le GAM capte une légère inflexion autour de la valeur 1,0, qui marque le passage du bonus au malus : la progression de la sinistralité s'accélère à ce niveau, de manière plus marquée que ne le prédit la droite du GLM. Les points empiriques confirment cette discontinuité relative, cohérente avec l'interprétation économique d'un changement de profil de conduite autour du CRM neutre.

Sur la variable **densité**, l'examen du graphique montre que l'utilisation d'une fonction de lissage est pleinement justifiée. Contrairement à une simple approche log-linéaire, le modèle GAM capture des fluctuations locales essentielles, notamment des paliers de croissance et un net décrochage de l'effet aux densités les plus élevées (au-delà de 250 hab/km^2). Ce gain de flexibilité permet de coller au plus près des observations réelles là où le GLM simplifie excessivement la tendance.

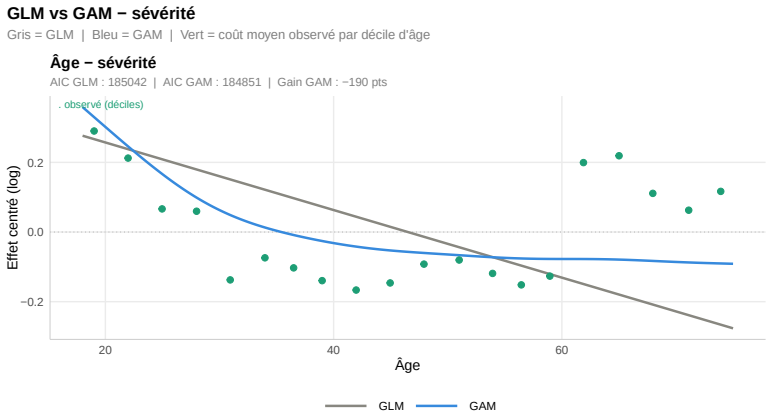


FIGURE 3.3 – Effets partiels estimés — modèle de sévérité

Coût moyen des sinistres : La Figure 3.3 présente le même exercice pour le modèle de sévérité, où seul l'âge est modélisé via une spline, le CRM et la densité ayant été conservés sous forme linéaire conformément à leur comportement exploratoire.

Le GLM estime une relation monotone décroissante entre l'âge et le coût moyen : plus le conducteur est âgé, moins ses sinistres seraient coûteux. Cette représentation est incomplète. Le GAM révèle une structure différente : la baisse du coût moyen est effectivement marquée jusqu'à 40 ans environ, mais elle se stabilise ensuite, avant de remonter légèrement pour les conducteurs les plus âgés. Ce rebond, bien que modéré, est cohérent avec les observations empiriques (points verts) qui s'élèvent au-dessus de la courbe GLM après 60 ans, et confirme le résultat déjà identifié dans l'analyse descriptive : si l'âge réduit la probabilité d'accident, il n'en réduit pas la gravité une fois le sinistre survenu. Les conducteurs seniors ont des accidents rares mais plus sévères, un phénomène que le GLM ne peut reproduire sans recourir à une segmentation artificielle par tranche d'âge.

Synthèse : Ces visualisations permettent de traduire en termes concrets le gain de $\Delta\text{AIC} \approx -1\,095$ points enregistré par le GAM sur le modèle de fréquence : ce gain ne reflète pas une complexification artificielle du modèle, mais la captation de non-linéarités structurelles confirmées par les données empiriques. L'âge et le CRM concentrent l'essentiel de ce gain, tandis que la densité se révèle déjà bien captée par une relation linéaire. Pour la sévérité, le gain plus modéré ($\Delta\text{AIC} \approx -191$ points) est principalement porté par la correction du profil en U de l'âge.

Il convient toutefois de souligner une limite de cette représentation : les effets partiels sont tracés toutes autres variables fixées à leur valeur médiane. Ils ne reflètent donc pas les interactions éventuelles entre prédicteurs, et doivent être interprétés comme des effets marginaux conditionnels plutôt que comme des effets globaux.

3.2.5 Tests liés au modèles

Test de lien

Le test de lien est reconduit sur les modèles GAM selon la même méthodologie que pour les GLM.

TABLE 3.13 – Résultats du test de lien — modèles GAM

Modèle	**p-valeur ($\hat{y}^2$)**	**Conclusion**
Fréquence (avec genre)	$< 0,001$	Lien mal spécifié
Fréquence (sans genre)	$0,001$	Lien mal spécifié
Sévérité (avec genre)	$0,972$	Lien correct
Sévérité (sans genre)	$0,563$	Lien correct

Les modèles de sévérité valident le lien logarithmique (p > 0,05). En revanche, les deux modèles de fréquence échouent au test. Ce résultat s'explique vraisemblablement par un problème lié à la flexibilité des splines : avec des degrés de liberté effectifs élevés, les splines captent l'essentiel de la non-linéarité et induisent une colinéarité avec le terme $\hat{y}^2$ du test, biaisant ainsi ses conclusions. Ce phénomène étant connu dans la littérature GAM, nous ne remettons pas en cause la spécification du lien logarithmique pour les modèles de fréquence.

Test d'hétéroscédasticité

TABLE 3.14 – Résultats du test d'hétéroscédasticité — modèles GAM

Modèle	**p-valeur ($\hat{y}$)**	**Conclusion**
Fréquence (avec genre)	$0,689$	Homoscédasticité
Fréquence (sans genre)	$0,771$	Homoscédasticité
Sévérité (avec genre)	$0,356$	Homoscédasticité
Sévérité (sans genre)	$0,337$	Homoscédasticité

L'ensemble des modèles GAM valide l'homoscédasticité (p > 0,05), avec des p-valeurs nettement supérieures à celles obtenues sur les GLM correspondants. La structure de variance imposée par les lois Binomiale Négative et Gamma est donc bien respectée.

Degrés de liberté effectifs des splines (EDF)

L'un des apports spécifiques du GAM est la possibilité de quantifier la non-linéarité de chaque effet via les degrés de liberté effectifs (EDF).

TABLE 3.15 – Degrés de liberté effectifs des splines

Modèle	**s(Age)**	**s(CRM)**	**s(Density)**
Fréquence (avec genre)	7,71	4,92	8,29
Fréquence (sans genre)	7,71	4,99	8,27
Sévérité (avec genre)	4,17	—	—
Sévérité (sans genre)	4,18	—	—

Les EDF sont significativement supérieurs à 1 pour l'ensemble des splines, confirmant la pertinence du recours au GAM. Pour les modèles de fréquence, l'âge (EDF $\approx$ 7,7), le CRM (EDF $\approx$ 4,9) et la densité (EDF $\approx$ 8,3) présentent tous une non-linéarité marquée que le GLM ne pouvait pas capturer. Pour les modèles de sévérité, l'âge conserve un effet non linéaire significatif (EDF $\approx$ 4,2), tandis que le CRM et la densité, dont les EDF étaient proches de 1 en phase exploratoire, ont été intégrés en effet linéaire.

L'ensemble de ces diagnostics valide la spécification des modèles GAM retenus. L'hétéroscédasticité est absente sur les quatre modèles, le lien logarithmique est confirmé pour la sévérité, et les EDF justifient pleinement l'usage des splines pour capturer les effets non linéaires de l'âge, du CRM et de la densité.

3.3 Impact tarifaire de la suppression du genre

L'analyse statistique établit que le genre est un prédicteur majeur du risque, son influence s'exerçant principalement sur la fréquence des sinistres. Nous quantifions à présent les conséquences concrètes de sa suppression sur le niveau des primes pures, en comparant les primes issues des modèles G et U sur les deux échantillons : le jeu d'entraînement (*training*) et le jeu de tarification (*pricing*) pour des contrats en 2011.

La prime pure ($\hat{\pi}$) est calculée, pour chaque assuré i, comme le produit de la fréquence prédite ($\hat{\lambda}$) et de la sévérité prédite ($\hat{\mu}$) :

$$\hat{\pi}_i = \hat{\lambda}_i \times \hat{\mu}_i$$

L'impact tarifaire par genre est ensuite obtenu en comparant, au sein de chaque groupe, la prime moyenne issue du modèle unisexe à celle issue du modèle genré :

$$\Delta_g = \frac{\bar{\pi}_g^U}{\bar{\pi}_g^G} - 1$$

Note sur l'évaluation out-of-sample. Le jeu *pricing* (`pg15pricing`), distinct du jeu d'estimation *training*, ne contient ni variable d'exposition ni variables de sinistralité (`Numtppd`, `Indtppd`).

Les modèles de fréquence, calibrés exclusivement sur *training* avec l'exposition en offset, sont appliqués à *pricing* en fixant l'exposition à 1, ce qui annualise les primes pures prédites.

Cette approche *out-of-sample* reflète le cadre opérationnel standard de tarification : évaluation d'un nouveau portefeuille sans historique sinistral, sur base d'un modèle estimé préalablement sur l'exposition réelle disponible dans *training*. Les primes ainsi obtenues témoignent de la robustesse des modèles sur des données externes.

3.3.1 Tarification sur le GLM

Table 3.16 – Impact tarifaire du passage au modèle unisexe — GLM

Échantillon	Genre	Prime G (€)	Prime U (€)	Variation (%)
Training	Femme	84,52	110,47	$+30,71\%$
	Homme	117,01	101,99	$-12,84\%$
Pricing	Femme	94,08	122,97	$+30,71\%$
	Homme	130,73	113,94	$-12,84\%$

Les résultats sont frappants par leur cohérence. Le passage au tarif unisexe entraîne une **hausse de prime de** $+30,7\%$ pour les femmes et une **baisse de** $-12,8\%$ pour les hommes, et ce de façon quasi identique sur les deux échantillons (l'écart entre training et pricing est inférieur à $0,01$ point de pourcentage). Cette stabilité confirme la robustesse du signal tarifaire : l'impact mesuré n'est pas un produit de l'échantillon d'estimation, il reflète une propriété structurelle du portefeuille.

L'asymétrie des variations mérite une attention particulière. La hausse subie par les femmes est nettement supérieure en valeur absolue à la baisse accordée aux hommes. Cet écart s'explique par la composition du portefeuille : les hommes étant plus nombreux et portant une sinistralité plus élevée, la prime unisexe s'établit à un niveau intermédiaire qui pénalise davantage les femmes, dont la prime de référence est plus basse, qu'elle ne soulage les hommes.

3.3.2 Tarification sur le GAM

TABLE 3.17 – Impact tarifaire du passage au modèle unisexe — GAM

Échantillon	**Genre**	**Prime G (€)**	**Prime U (€)**	**Variation (%)**
Training	Femme	85,69	111,39	$+30,00\%$
	Homme	117,13	102,33	$-12,63\%$
Pricing	Femme	95,14	123,69	$+30,00\%$
	Homme	131,07	114,52	$-12,63\%$

Le GAM confirme les conclusions du GLM avec une remarquable précision. Les variations tarifaires sont légèrement atténuées mais restent d'un ordre de grandeur strictement comparable. La prise en compte des non-linéarités ne modifie donc pas la nature ni l'ampleur de l'impact tarifaire de la Gender Directive : elle en affine marginalement l'estimation sans en changer les conclusions.

3.3.3 Synthèse et interprétation

TABLE 3.18 – Synthèse de l'impact tarifaire — GLM et GAM

	GLM		**GAM**	
Genre	**Training**	**Pricing**	**Training**	**Pricing**
Femme	$+30,71\%$	$+30,71\%$	$+30,00\%$	$+30,00\%$
Homme	$-12,84\%$	$-12,84\%$	$-12,63\%$	$-12,63\%$

Trois conclusions se dégagent de cette analyse.

L'impact est massif et défavorable aux femmes. Une hausse de prime de l'ordre de $+30\%$ constitue un choc tarifaire significatif. Elle est la conséquence directe du fait que le genre agissait, dans le modèle de référence, comme un segmentateur à fort pouvoir discriminant : les femmes bénéficiaient d'une prime structurellement plus basse, reflétant leur sinistralité réelle. Le tarif unisexe les prive de cet avantage.

La robustesse inter-échantillons est totale. L'écart entre training et pricing est nul au niveau de précision affiché, ce qui écarte tout risque de surapprentissage et garantit que les estimations sont directement transposables à la tarification effective.

La robustesse inter-modèles est forte. L'écart entre GLM et GAM est inférieur à 1 point de pourcentage sur les deux genres. La quantification de l'impact tarifaire de la

Gender Directive est donc indépendante du choix de spécification : qu'on retienne un modèle linéaire ou un modèle flexible, le passage à l'unisexe se traduit par une redistribution tarifaire d'environ +30% pour les femmes et −13% pour les hommes.

Ces résultats doivent toutefois être interprétés avec prudence, dans la mesure où ils reposent sur une structure de portefeuille supposée stable, hypothèse rarement vérifiée en pratique.

3.4 Évaluation du pouvoir discriminant des modèles : coefficient de Gini et Lift chart

Principe du coefficient de Gini en actuariat

L'AIC et le BIC, utilisés jusqu'ici, mesurent la qualité d'ajustement d'un modèle à ses données d'estimation. Ils ne renseignent pas directement sur sa capacité à *classer* les assurés selon leur niveau de risque réel, ce qui est pourtant l'objectif central de la tarification. Le coefficient de Gini actuariel répond à cette question complémentaire.

Son principe est le suivant : les assurés sont triés par ordre croissant de prime pure prédite, puis on observe la concentration des sinistres effectivement observés le long de cette distribution. Cette relation est représentée par la courbe de Lorenz, qui trace la part cumulée des sinistres en fonction de la part cumulée des assurés. Dans cette convention, une courbe située **en dessous** de la première bissectrice traduit une concentration des primes sur une fraction réduite des assurés les plus risqués : plus la courbe s'éloigne de la diagonale vers le bas, plus le modèle est discriminant. À l'inverse, une courbe confondue avec la bissectrice correspondrait à un modèle sans pouvoir de segmentation, attribuant la même prime à tous les assurés. Le coefficient de Gini mesure l'aire entre ces deux situations ; il vaut 0 en l'absence de discrimination et 1 dans le cas idéal. En assurance non-vie, un coefficient supérieur à 0,5 est généralement considéré comme le seuil d'un modèle discriminant satisfaisant.

Il convient de souligner la complémentarité de cet indicateur avec l'AIC : un modèle peut présenter un excellent classement des risques tout en étant imparfaitement calibré en niveau, et inversement. Associer les deux perspectives offre une évaluation plus complète de la qualité tarifaire.

Résultats

Le Tableau ci-dessous présente les coefficients de Gini obtenus pour les quatre modèles retenus.

Modèle	**Coefficient de Gini**
GLM Genré	0,4850
GLM Unisexe	0,4762
GAM Genré	0,5217
GAM Unisexe	0,5149

Table 3.19 – Coefficients de Gini des différents modèles

Trois enseignements se dégagent de ces résultats.

En premier lieu, les modèles GAM franchissent le seuil de référence de 0,5, tandis que les GLM s'en approchent sans l'atteindre. Ce résultat est cohérent avec les conclusions tirées de l'AIC : la flexibilité des splines permet de capturer des effets non linéaires que le GLM lisse artificiellement, améliorant ainsi non seulement l'ajustement statistique mais aussi la qualité du classement des risques. Il confirme également que le recours au GAM est justifié non seulement sur le plan de la vraisemblance, mais aussi sur celui de la performance discriminante.

En second lieu, les modèles GAM surpassent systématiquement les GLM correspondants, avec un gain de l'ordre de 0,037 points de Gini. Cet écart traduit une amélioration réelle de la segmentation du portefeuille grâce à la modélisation non linéaire de l'âge, du CRM et de la densité.

Le troisième enseignement est le plus instructif au regard de notre problématique. L'écart entre modèles genrés et unisexes est très faible et les courbes de Lorenz associées sont quasi superposées (Figure 3.4). Ce résultat est visuellement frappant : les quatre courbes se distinguent à peine, les GAM dominant légèrement les GLM, tandis que les versions genrées et unisexes d'un même modèle restent pratiquement indiscernables.

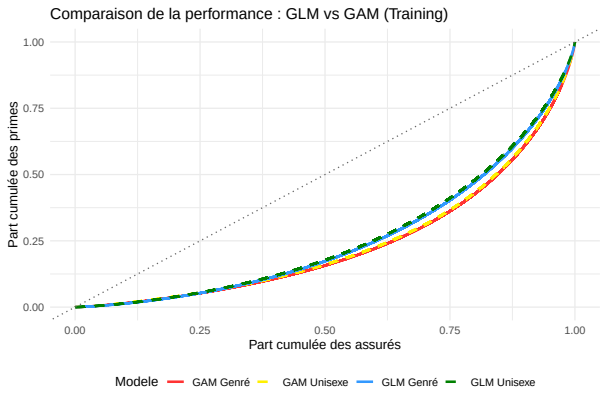


FIGURE 3.4 – Courbe de Lorenz — Comparaison des modèles (Training)

Ce résultat mérite une interprétation fine. Il ne suggère pas que le genre soit une variable inutile : la hausse de l'AIC lors de sa suppression a bien montrait une perte d'information notable, et les variations de prime restent significatives. Le Gini, en revanche, indique quelque chose de plus subtil : le genre n'affecte pas l'ordre des risques au sein du portefeuille, mais plutôt le niveau moyen des primes appliquées à chaque groupe. Autrement dit, le classement du risque (qui est plus ou moins exposé) dépend surtout du CRM, de l'âge et de la densité. Le genre intervient seulement comme un coefficient d'ajustement global, sans modifier le positionnement relatif des groupes. C'est pourquoi sa suppression détériore l'AIC sans entraîner de baisse significative du Gini.

Cette distinction est importante pour les assureurs. Elle suggère que le passage à la tarification unisexe ne compromet pas la capacité à identifier et à tarifer correctement les profils très risqués, mais qu'il génère en revanche des transferts horizontaux significatifs entre groupes de risque comparables. C'est à ce niveau que se situe la menace d'antisélection décrite dans le chapitre suivant.

Analyse du Lift Chart

Principe et construction

Le coefficient de Gini et la courbe de Lorenz évaluent la qualité du *classement* des risques, mais ne renseignent pas sur la *calibration* des primes en niveau absolu. Le Lift Chart complète cette analyse en confrontant directement les primes pures prédites par le modèle à la sinistralité effectivement observée, décile par décile.

Sa construction repose sur trois étapes. Les assurés sont d'abord triés par ordre croissant de prime pure estimée, puis regroupés en dix déciles d'effectif égal. Le premier décile rassemble ainsi les 10 % d'assurés jugés les moins risqués par le modèle, et le dixième les 10 % les plus risqués. Pour chaque décile, on calcule d'une part la prime pure moyenne prédite par le modèle (*courbe rouge*), et d'autre part le coût moyen réellement observé, défini comme le produit du nombre de sinistres par leur coût moyen (*points bleus*). La superposition de ces deux séries permet d'évaluer simultanément le pouvoir de segmentation du modèle et la précision de sa calibration.

Résultats et interprétation

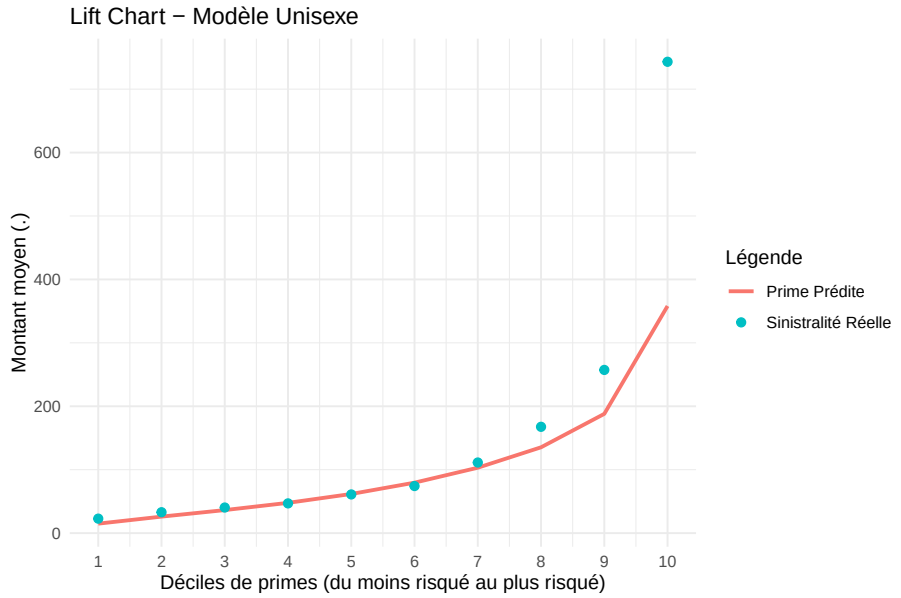


FIGURE 3.5 – Lift Chart — Modèle unisexe (GAM)

Pouvoir de segmentation : La courbe prédite présente une pente monotone croissante, allant d'environ 20 € pour le premier décile à 350 € pour le dixième. Ce gradient confirme que le modèle unisexe conserve une forte capacité de segmentation malgré l'absence de la variable genre : il discrimine nettement les profils à faible sinistralité attendue des profils à forte sinistralité, ce qui constitue la condition minimale d'utilité d'un modèle de tarification.

Calibration sur la majorité du portefeuille : Sur les sept premiers déciles, représentant 70 % des assurés, les sinistres observés s'alignent étroitement sur les primes prédites. Cette adéquation quasi parfaite entre le prédit et le réel valide la calibration du modèle pour la grande majorité du portefeuille : les primes calculées reflètent fidèlement le risque

moyen de ces profils, ce qui constitue le scénario attendu pour un modèle correctement spécifié.

Sous-tarification du dernier décile : C'est sur le dixième décile que le graphique livre son enseignement le plus pertinent au regard de notre problématique. On y observe un décrochage significatif entre la prime prédite ($\approx 350\,€$) et la sinistralité réelle ($\approx 750\,€$). Ce dixième décile regroupe les profils les plus extrêmes du portefeuille pour lesquels l'information véhiculée par le genre était la plus discriminante.

Ce résultat complète et nuance les conclusions tirées du coefficient de Gini. Si la hiérarchie des risques est préservée comme l'attestait la quasi-superposition des courbes de Lorenz entre modèles genré et unisexe, la calibration en niveau se dégrade précisément là où l'enjeu financier est le plus important. Ce sont en effet les profils du dernier décile qui concentrent la sinistralité la plus coûteuse et qui présentent le risque d'antisélection le plus critique : sous-tarifés par le modèle unisexe, ils sont paradoxalement les moins susceptibles de quitter le portefeuille, ce qui aggrave le déséquilibre de composition décrit dans le chapitre suivant.

Chapitre 4

Enjeux stratégiques et Conclusion

4.1 Enjeux stratégiques et recommandations

4.1.1 Le risque d'antisélection

Analyse théorique

L'antisélection, ou sélection adverse, désigne un désalignement entre le risque individuel et la prime proposée, susceptible d'influencer les comportements de souscription des assurés. Elle apparaît lorsque la tarification ne reflète plus correctement l'hétérogénéité des risques au sein du portefeuille.

La Gender Directive crée précisément cette situation en imposant une tarification unisexe à des profils de risque différents. Elle conduit ainsi à une sur-tarification de certains assurés et une sous-tarification d'autres, modifiant les incitations économiques des individus.

Toutefois, dans un marché concurrentiel et régulé, ce mécanisme doit être nuancé. Contrairement au cadre théorique de Rothschild et Stiglitz, 1976, les assureurs sont soumis aux mêmes contraintes réglementaires et ne peuvent pas proposer de tarification différenciée fondée sur le genre. L'antisélection ne se traduit donc pas nécessairement par une accumulation unilatérale de « mauvais risques », mais plutôt par des entrées et sorties simultanées d'assurés selon leur perception du tarif.

Par ailleurs, les assureurs disposent de leviers de gestion du risque, notamment à travers le système de bonus-malus (CRM), qui permet d'ajuster les primes en fonction de l'historique individuel de sinistralité. Ces mécanismes contribuent à limiter les effets d'une sélection adverse pure.

Dès lors, le principal enjeu réside moins dans une spirale d'antisélection au sens strict que dans une déformation progressive de la structure du portefeuille. La tarification unisexe introduit un mécanisme de **subvention croisée** entre assurés, dans lequel certains profils paient une prime supérieure à leur risque actuariel afin de compenser la sous-tarification d'autres profils.

Nos résultats empiriques ne permettent pas d'observer directement ces dynamiques comportementales, mais ils en suggèrent les conditions d'existence à travers les transferts de primes identifiés. L'antisélection doit ainsi être comprise ici comme un risque potentiel de recomposition du portefeuille, plutôt que comme une dynamique mécanique d'aggravation du risque moyen.

Analyse empirique

Afin de compléter l'analyse théorique, une approche empirique a été mise en œuvre afin d'évaluer les effets concrets de la suppression du genre sur la structure du portefeuille.

Les résultats montrent que la neutralité globale des primes masque des effets redistributifs importants. Si la prime moyenne reste stable (Section 3.3), la suppression du genre entraîne une hausse significative des primes pour les femmes (+30%) et une baisse pour les hommes (-12%). Ce transfert traduit un désalignement entre le risque individuel et la tarification.

L'analyse de la distribution des hausses tarifaires chez les femmes met en évidence un phénomène à la fois massif et homogène : l'ensemble des assurées subit une augmentation comprise entre 28,23% et 35,16%, avec une médiane de 30,33%. Cette faible dispersion indique que la suppression du genre réduit fortement la capacité du modèle à différencier les profils de risque au sein de ce groupe.

Dans ce contexte, les incitations économiques des assurés sont modifiées. Les profils les moins risqués, confrontés à une prime supérieure à leur risque actuariel, peuvent être incités à ajuster leur comportement, que ce soit en recherchant des offres alternatives, en modifiant leur niveau de couverture ou en arbitrant entre assureurs sur la base d'autres critères tarifaires.

Afin d'illustrer ces mécanismes, un scénario de stress simplifié a été simulé : sous l'hypothèse d'une recomposition partielle du portefeuille, si les 10% d'assurées présentant le niveau de risque le plus faible venaient à quitter le portefeuille, la fréquence moyenne de sinistres augmenterait de 3,23%. Bien que ce scénario repose sur des hypothèses simplificatrices, il permet d'illustrer l'ordre de grandeur des effets potentiels associés à une modification de la composition du portefeuille.

Ces résultats ne permettent pas de conclure à l'existence d'une dynamique d'antisélection au sens strict, mais mettent en évidence les conditions sous lesquelles une recomposition du portefeuille pourrait se produire. Ils confirment ainsi que la suppression du genre ne se limite pas à une perte de performance statistique, mais peut également avoir des implications économiques sur l'équilibre du portefeuille.

4.1.2 Éthique et algorithmes

La suppression réglementaire du genre crée une incitation à recourir à des modèles plus complexes, capables de reconstituer indirectement l'information perdue. Cette évolution soulève des enjeux éthiques importants.

Comme le montrent Xin et Huang, 2023, il convient de distinguer la discrimination directe, consistant à utiliser explicitement le genre, et la discrimination indirecte, utilisant des variables corrélées au genre, reconstituant partiellement son effet. Dans notre analyse, les faibles scores du V de Cramer obtenus entre le genre et les autres variables, indiquent une quasi-indépendance entre ces prédicteurs. Ce résultat suggère que le risque de discrimination indirecte reste limité dans le cadre de notre spécification, dans la mesure où les variables retenues ne constituent pas des substituts significatifs au genre.

Dans le modèle GLM, cette indépendance se traduit par une stabilité remarquable des coefficients lors du passage au modèle unisexe : la suppression du genre affecte principalement la constante, sans modifier les estimations associées aux autres variables. Toutefois,

ce résultat reste dépendant du modèle et du portefeuille analysé : des approches plus flexibles pourraient capter des interactions complexes et reconstruire implicitement un effet du genre.

Le GAM constitue à cet égard une alternative intermédiaire intéressante. Il permet d'introduire des effets non linéaires tout en conservant une certaine interprétabilité. Dans nos résultats (Tableau 3.10), la suppression du genre ne modifie pas la forme des relations estimées pour des variables comme l'âge, le CRM ou la densité, ce qui suggère qu'il capte des effets réels sans compenser artificiellement l'absence du genre.

Au-delà des aspects techniques, la tarification repose sur une relation de confiance entre l'assureur et l'assuré. L'utilisation de variables perçues comme indirectement discriminantes peut être mal comprise, même si elle respecte formellement la réglementation. Comme le soulignent Xin et Huang, 2023, le choix entre différents critères d'équité ne relève pas uniquement de la statistique, mais implique également un arbitrage qui engage la responsabilité de l'actuaire.

4.1.3 Recommandations finales

Au terme de cette étude, trois recommandations peuvent être formulées à destination des assureurs soumis à la Gender Directive.

Privilégier le GAM comme modèle de tarification. Les résultats (Section 3.2) montrent que le GAM unisexe surpasse le GLM unisexe sur l'ensemble des critères retenus. Il présente notamment un AIC plus faible, tant en fréquence qu'en sévérité. En capturant les non-linéarités de variables comme l'âge, le CRM ou la densité, il permet de récupérer une partie de la précision perdue liée à la suppression du genre, sans recourir à des variables de substitution discutables. Par ailleurs, il reste suffisamment interprétable pour être justifié auprès d'un régulateur ou d'un assuré. Il constitue ainsi un bon compromis entre performance et transparence.

Utiliser des modèles plus flexibles à des fins de surveillance interne. Des modèles plus flexibles peuvent être mobilisés en complément du modèle de tarification, à condition de limiter leur usage au pilotage interne. Leur intérêt réside dans leur capacité à détecter des structures complexes dans les données, notamment des segments de portefeuille pour lesquels le modèle principal prédit mal le risque. Une telle approche permet d'améliorer le suivi du portefeuille sans introduire directement ces modèles dans la tarification, ce qui limiterait les risques en matière de transparence et de conformité réglementaire.

Anticiper et gérer le risque d'antisélection. La hausse significative des primes pour certains profils, en particulier les femmes à faible sinistralité, constitue un risque pour l'équilibre du portefeuille. Elle peut en effet inciter les assurés les moins risqués à quitter l'assureur. Plusieurs leviers peuvent être mobilisés. D'une part, une stratégie de fidélisation ciblée peut limiter les résiliations, notamment via des services ou garanties complémentaires. D'autre part, le suivi de la composition du portefeuille reste essentiel pour détecter d'éventuels déséquilibres. Enfin, développement de données comportementales, notamment issues de la télématique (kilométrage, habitudes de conduite), offre la perspective d'une tarification plus individualisée. À terme, cette approche pourrait réduire l'importance des variables sociodémographiques comme le genre, en fondant la tarification sur le comportement réel des assurés.

4.2 Conclusion

4.2.1 Synthèses des résultats

Ce mémoire s'est attaché à répondre à la question suivante : **dans quelle mesure la suppression d'une variable dans un modèle de tarification automobile affecte-t-elle sa qualité prédictive et la structure des primes ?**

Les résultats mettent en évidence un constat clair : le genre constitue un facteur de risque significatif, qui ne peut être pleinement capté par les autres variables du modèle. L'écart de fréquence entre hommes et femmes est important et persistant, quelque soient l'âge ou le CRM, confirmant qu'il ne s'agit pas d'un effet aléatoire. Sa suppression revient donc à perdre une information que les autres variables ne compensent pas.

Cette perte se manifeste à deux niveaux. D'une part, sur le plan statistique, la qualité du modèle se dégrade, en particulier pour la fréquence des sinistres, ce qui montre que la variable genre joue un rôle central dans la modélisation du risque. D'autre part, sur le plan tarifaire, cette dégradation se traduit par une redistribution des primes : les femmes subissent une hausse, tandis que les hommes bénéficient d'une baisse, de manière relativement homogène au sein de chaque groupe.

Face à cette perte, le GAM apparaît comme une réponse pertinente. En intégrant des effets non linéaires, notamment pour l'âge et le CRM, il permet de récupérer une partie de la précision perdue tout en conservant une bonne interprétabilité. À l'inverse, des modèles plus flexibles peuvent présenter des problèmes de calibration et de robustesse, ce qui limite leur utilisation dans un cadre de tarification.

Enfin, la suppression du genre ne se limite pas à un enjeu de performance statistique. Elle modifie également les incitations des assurés et peut entraîner une dégradation progressive du portefeuille. La hausse de prime pour les profils les moins risqués crée un risque **d'antisélection**, susceptible d'affecter durablement l'équilibre du portefeuille. Cette dimension dynamique échappe aux indicateurs classiques comme l'AIC, mais constitue un enjeu central pour les assureurs.

4.2.2 Limites de l'étude et perspectives

Les limites de l'étude

Plusieurs limites doivent être soulignées afin de nuancer la portée des résultats obtenus.

La premiè concerne les données utilisées. La base pg15training, bien que riche de 100 021 contrats, porte uniquement sur les années 2009-2010, dans un contexte qui ne reflète pas nécessairement celui du marché actuel. De plus, pour des raisons de confidentialité, certaines variables catégorielles ne sont pas entièrement documentées, ce qui limite l'interprétation de certains effets. Enfin, l'analyse se concentre exclusivement sur les sinistres matériels et ne prend pas en compte les sinistres corporels, qui présentent des caractéristiques spécifiques, notamment en termes de sévérité.

La deuxième limite tient au choix de modélisation. L'étude repose sur un modèle volontairement parcimonieux, fondé sur un nombre restreint de variables. Certaines informations disponibles, comme le type ou la valeur du véhicule, n'ont pas été intégrées dans les modèles finaux. Or, ces variables pourraient en partie capter des effets liés au genre.

Leur prise en compte pourrait donc modifier l'ampleur des effets observés et mérité d'être approfondie.

Enfin, une dernière limite réside dans l'approche adoptée. Les transferts de primes sont estimés en supposant une composition stable du portefeuille. Or, cette hypothèse est forte : en pratique, les modifications tarifaires peuvent influencer le comportement des assurés et entraîner des phénomènes d'antisélection. Les résultats obtenus doivent donc être interprétés comme des effets statistiques, susceptibles de sous-estimer les évolutions réelles du portefeuille à plus long terme.

Les perspectives

Ces limites ouvrent plusieurs pistes de recherche et d'amélioration.

La première concerne l'intégration de variables comportementales issues de la télématique. Les données de type Pay How You Drive (kilométrage, horaires de conduite, comportement de freinage) permettent d'envisager une tarification plus individualisée. En captant directement les comportements de conduite, elles pourraient réduire le rôle des variables sociodémographiques comme le genre, tout en améliorant la précision du modèle.

La deuxième perspective est d'ordre réglementaire. La Gender Directive pourrait constituer une première étape vers une remise en question plus large de certaines variables tarifaires, comme l'âge. Les méthodes mobilisées dans cette étude (mesure de perte d'information, analyse des transferts de primes) peuvent être réutilisées pour évaluer l'impact de futures évolutions réglementaires. Elles offrent ainsi un cadre d'analyse utile pour anticiper ces changements.

La troisième piste concerne l'amélioration des modèles utilisés. L'exploration de spécifications plus riches, intégrant davantage de variables ou de interactions, pourrait permettre de mieux capter l'hétérogénéité du risque sans recourir à des variables potentiellement sensibles. Cela constitue une extension naturelle du travail réalisé dans ce mémoire.

Enfin, une quatrième perspective, d'ordre sociétal, mérite d'être soulevée. Ce mémoire s'est concentré sur l'assurance automobile, où la Gender Directive se traduit par une hausse significative des primes féminines. Cette conclusion, rigoureusement établie, gagnerait toutefois à être replacée dans un cadre plus large. En effet, si les femmes sont perdantes dans le secteur automobile, la réforme leur est en revanche favorable dans d'autres branches : en assurance vie ou en assurance santé, la suppression de la tarification genrée peut s'être traduite par une baisse de leurs primes. Une analyse de l'effet net à l'échelle de l'ensemble du portefeuille assurantiel d'un individu, toutes branches confondues, constituerait ainsi une perspective de recherche particulièrement intéressante : il est possible que le solde global de la réforme soit neutre, voire favorable aux femmes, nuançant ainsi le constat établi dans ce mémoire.

4.2.3 Conclusion générale

L'ambition de ce mémoire était de mesurer l'impact de la suppression du genre dans un modèle de tarification automobile. Les résultats obtenus permettent de répondre clairement à cette problématique et de valider les hypothèses formulées en introduction. Le genre apparaît ainsi comme un déterminant important du risque, dont l'absence entraîne une perte significative de précision dans la capacité du modèle à discriminer les assurés.

Cette perte se traduit directement par une redistribution des primes au sein du portefeuille : les profils les moins risqués voient leur prime augmenter, tandis que les plus risqués bénéficient d'une baisse. Le passage à un modèle unisexe induit ainsi des transferts significatifs entre assurés, confirmant l'existence d'un désalignement entre risque individuel et tarification.

Si des modèles plus flexibles comme le GAM permettent d'en atténuer partiellement les effets, ils ne compensent pas totalement la perte d'information liée à la suppression du genre. Ce résultat confirme que l'amélioration de la spécification du modèle ne suffit pas à remplacer une variable fortement discriminante.

Ces résultats mettent en évidence une tension fondamentale entre les objectifs de précision actuarielle et les exigences réglementaires d'égalité de traitement. La tarification ne relève ainsi pas uniquement d'un problème technique : elle implique également des arbitrages qui engagent la responsabilité de l'actuaire face aux enjeux d'équité et de gestion du risque.

Ces conclusions ouvrent des perspectives méthodologiques importantes. Dans un contexte où les contraintes réglementaires limitent les variables utilisables, le recours à des méthodes d'apprentissage automatique, telles que les forêts aléatoires (**Random Forests**) ou le gradient boosting (**XGBoost**), pourrait constituer une piste d'amélioration significative. Des approches plus flexibles, capables de capter des non-linéarités ou des interactions entre variables, pourraient ainsi permettre de mieux compenser la perte d'information liée à la suppression du genre. Toutefois, ces méthodes soulèvent des défis en matière d'interprétabilité et de conformité réglementaire, particulièrement importants en assurance. L'équilibre entre performance prédictive, transparence des modèles et respect des exigences de non-discrimination apparaît ainsi comme un enjeu central pour l'actuariat.

Ces pistes, qu'il s'agisse du recours à des méthodes d'apprentissage automatique (Random Forest ou XGBoost) ou de l'intégration de données télématiques issues du Pay How You Drive, constituent des prolongements naturels de ce travail, dont l'exploration approfondie pourrait faire l'objet d'un mémoire de Master 2 en actuariat ou en data science appliquée à l'assurance.

Bibliographie

Ouvrages académiques

Charpentier, Arthur (2014). *Computational Actuarial Science with R*. Jeux de données pg15training et pg15pricing fournis par l'auteur. Boca Raton : CRC Press.

Denuit, Michel et al. (2007). *Actuarial Modelling of Claim Counts : Risk Classification, Credibility and Bonus-Malus Systems*. Chichester : Wiley.

McCullagh, Peter et John Ashworth Nelder (1989). *Generalized Linear Models*. 2e éd. London : Chapman et Hall.

Articles de revues

Boucher, Jean-Philippe, Sophie Côté et Montserrat Guillén (2017). « Exposure as Duration and Distance in Telematics Motor Insurance Using Generalized Additive Models ». In : *Insurance : Mathematics and Economics* 74, p. 77-85.

Fagart, Marie-Cécile et Bidénam Kambia-Chopin (2003). « Aléa moral et sélection adverse sur le marché de l'assurance ». In : *INSEE-CREST Working Paper* 2003-39. URL : http://crest.science/RePEc/wpstorage/2003-39.pdf.

Hastie, Trevor et Robert Tibshirani (1986). « Generalized additive models ». In : *Statistical Science* 1.3, p. 297-310.

Nelder, John Ashworth et Robert William Maclagan Wedderburn (1972). « Generalized Linear Models ». In : *Journal of the Royal Statistical Society. Series A (General)* 135.3, p. 370-384. DOI : 10.2307/2344614. URL : https://www.jstor.org/stable/2344614 (visité le 17/03/2026).

Pernagallo, Giuseppe, Antonio Punzo et Benedetto Torrisi (2023). « Women and insurance pricing policies : a gender-based analysis with GAMLSS on two actuarial datasets ». In : *Scientific Reports* 13.1, p. 15143.

Rothschild, Michael et Joseph E. Stiglitz (1976). « Equilibrium in Competitive Insurance Markets : An Essay on the Economics of Imperfect Information ». In : *Quarterly Journal of Economics* 90.4, p. 629-649.

Schmeiser, Störmer et Wagner (2014). « Unisex insurance pricing : consumers' perception and market implications ». In : *The Geneva Papers on Risk and Insurance – Issues and Practice* 39.3, p. 322-350.

Xin, Xian et Fei Huang (2023). « Antidiscrimination Insurance Pricing : Regulations, Fairness Criteria, and Models ». In : *North American Actuarial Journal* 27.2, p. 238-265. DOI : 10.1080/10920277.2023.2190528.

Sources institutionnelles et juridiques

Assemblée nationale (2014). *Loi n°2014-344 du 17 mars 2014 relative à la consommation, dite loi Hamon*. Journal officiel de la République française. Entrée en vigueur le 18 mars 2014. URL : https://www.legifrance.gouv.fr/loda/id/JORFTEXT000028738036.

Cour de justice de l'Union européenne (1er mars 2011). *Arrêt Test-Achats (Association belge des consommateurs Test-Achats ASBL e.a. c/ Conseil des ministres), aff. C-236/09*. Invalidation de l'article 5(2) de la directive 2004/113/CE, effet au 21 décembre 2012.

Observatoire national interministériel de la sécurité routière (ONISR) (mai 2025). *Bilan 2024 de la sécurité routière*. URL : https://www.onisr.securite-routiere.gouv.fr/etat-de-linsecurite-routiere/bilans-annuels-de-la-securite-routiere/bilan-2024-de-la-securite-routiere.

Sécurité routière (juin 2025). *Bilan définitif 2024*. URL : https://www.securite-routiere.gouv.fr/actualites/bilan-definitif-2024.

Union européenne (2004). *Directive 2004/113/CE du 13 décembre 2004*. Égalité de traitement entre hommes et femmes dans l'accès aux biens et services.

Logiciels utilisés

- **RStudio** : logiciel avancé pour les analyses statistiques
- **Overleaf** : écriture du mémoire en format LateX

Annexes

Liste des tableaux

2.1 Lois de probabilité utilisées en tarification automobile 16
2.2 Description des variables de la base pg15training 20
2.3 Statistiques descriptives des variables numériques 22
2.4 Répartition des variables catégorielles 23
2.5 Statistiques globales de sinistralité 24
2.6 Indicateurs de sinistralité TPPD selon le genre 25
2.7 Indicateurs de sinistralité TPPD par tranche d'âge 27
2.8 Indicateurs de sinistralité TPPD par tranche de CRM 28
2.9 Indicateurs de sinistralité TPPD par tranche de densité 30
2.10 Indicateurs de sinistralité TPPD par catégorie professionnelle 31

3.1 Analyse de la colinéarité (Indice GVIF) 35
3.2 Résultats du modèle de fréquence Genré (Binomiale Négative) 36
3.3 Résultats du modèle de fréquence Unisexe (Binomiale Négative) 37
3.4 Résultats du modèle de sévérité (Loi Gamma) 39
3.5 Comparaison des performances : Fréquence (Binomiale Négative) 40
3.6 Comparaison des performances : Sévérité (Loi Gamma) 41
3.7 Impact comparé du genre sur la fréquence et la sévérité 41
3.8 Résultats du test de lien 42
3.9 Résultats du test d'hétéroscédasticité 42
3.10 Résultats des GAM de fréquence (Binomiale Négative) 44
3.11 Résultats des modèles GAM de sévérité (Gamma) 45
3.12 Synthèse des gains d'AIC du GAM sur le GLM 46
3.13 Résultats du test de lien — modèles GAM 49
3.14 Résultats du test d'hétéroscédasticité — modèles GAM 49
3.15 Degrés de liberté effectifs des splines 50
3.16 Impact tarifaire du passage au modèle unisexe — GLM 51
3.17 Impact tarifaire du passage au modèle unisexe — GAM 52
3.18 Synthèse de l'impact tarifaire — GLM et GAM 52
3.19 Coefficients de Gini des différents modèles 53

Table des figures

1.1 Accidentalité routière en 2024 7

2.1 Répartition du portefeuille par genre 21
2.2 Analyse des distributions continues du portefeuille (Âge et CRM) 22
2.3 Structure du portefeuille par variables catégorielles 23
2.4 Distribution de l'âge par genre 24
2.5 Distribution des sinistres matériels. 25
2.6 Fréquence de sinistres par tranche d'âge 27
2.7 Coût moyen par tranche d'âge 27
2.8 Fréquence de sinistres par tranche de CRM 28
2.9 Coût moyen des sinistres par tranche de CRM 29
2.10 Fréquence de sinistres par tranche de densité 30
2.11 Coût moyen par tranche de densité 30
2.12 Matrice de corrélation entre les variables continues 32

3.1 Distribution du coût moyen par sinistre 38
3.2 Effets partiels estimés — Fréquence 47
3.3 Effets partiels estimés — modèle de sévérité 48
3.4 Courbe de Lorenz — Comparaison des modèles (Training) 54
3.5 Lift Chart — Modèle unisexe (GAM) 55

Liste des Codes R

```
> summary(pg15training[, c("Age", "Bonus", "Poldur", "Value", "Density")])
      Age            Bonus             Poldur          Value          Density
 Min.   :18.00   Min.   :-50.000   Min.   : 0.000   Min.   : 1000   Min.   : 14.38
 1st Qu.:30.00   1st Qu.:-40.000   1st Qu.: 1.000   1st Qu.: 8380   1st Qu.: 50.63
 Median :40.00   Median :-30.000   Median : 4.000   Median :14610   Median : 94.36
 Mean   :41.12   Mean   : -6.922   Mean   : 5.471   Mean   :16455   Mean   :117.16
 3rd Qu.:51.00   3rd Qu.: 10.000   3rd Qu.: 9.000   3rd Qu.:22575   3rd Qu.:174.64
 Max.   :75.00   Max.   :150.000   Max.   :15.000   Max.   :49995   Max.   :297.39
```

Statistiques descriptives des variables numériques

```
> # Répartition par type de véhicule
> prop.table(table(pg15training$Type)) * 100

        A         B         C         D         E         F
27.754172 22.085362 13.859090 19.592885 11.168655  5.539837
>
> # Répartition par catégorie
> prop.table(table(pg15training$Category)) * 100

   Large   Medium    Small
35.12262 36.63631 28.24107
>
> # Répartition par occupation
> prop.table(table(pg15training$Occupation)) * 100

    Employed     Housewife       Retired Self-employed    Unemployed
    31.14346      20.00580      13.16424      20.36772      15.31878
```

Repartition par catégorie

```
> cat("Fréquence globale TPPD :", round(freq_globale, 4))
Fréquence globale TPPD : 0.1643
> sum(pg15training$Numtppd)
[1] 14748
> sum(pg15training$Numtpbi)
[1] 4680
> sum(pg15training$Exppdays) / 365  # exposition totale en années
[1] 89768.99
> nrow(pg15training)
[1] 100021
```

Statistiques globales de sinistralité

```
> moyenne_empirique <- mean(pg15training$Numtppd)
> variance_empirique <- var(pg15training$Numtppd)
>
> cat("Moyenne (E) :", round(moyenne_empirique, 4), "\n")
Moyenne (E) : 0.1474
> cat("Variance (V) :", round(variance_empirique, 4), "\n")
Variance (V) : 0.1909
> cat("Ratio V/E :", round(variance_empirique / moyenne_empirique, 2), "\n")
Ratio V/E : 1.29
```

Ratio de dispersion

```
> # Affichage du résultat
> print(tableau_complet)
# A tibble: 2 × 6
  Gender Nb_contrats Exposition Nb_sinistres Frequence Cout_Moyen
  <fct>        <int>      <dbl>        <int>     <dbl>      <dbl>
1 Female       36578     32816.         4521     0.138       686.
2 Male         63443     56953.        10227     0.180       735.
>
```

Sinistralité par Genre

```
> table_chi2 <- table(pg15training$Gender, pg15training$Numtppd > 0)
> test_chi2 <- chisq.test(table_chi2)
> print(test_chi2)

        Pearson's Chi-squared test with Yates' continuity correction

data:  table_chi2
X-squared = 128.34, df = 1, p-value < 2.2e-16
```

Test du Chi2 d'indépendance

```
> test_welch_freq <- t.test((Numtppd/expo_an) ~ Gender, data = pg15training)
> print(test_welch_freq)

        Welch Two Sample t-test

data:  (Numtppd/expo_an) by Gender
t = -13.473, df = 87299, p-value < 2.2e-16
alternative hypothesis: true difference in means between group Female and group Male is not equal to 0
95 percent confidence interval:
 -0.04835735 -0.03607484
sample estimates:
mean in group Female   mean in group Male
           0.1377002            0.1799163
```

Test de Welch sur les fréquences

```
> test_variance <- var.test(Indtppd ~ Gender, data = pg15training_sin)
> print(test_variance)

        F test to compare two variances

data:  Indtppd by Gender
F = 0.81935, num df = 3912, denom df = 8342, p-value = 7.19e-13
alternative hypothesis: true ratio of variances is not equal to 1
95 percent confidence interval:
 0.7767007 0.8647935
sample estimates:
ratio of variances
         0.8193477
```

Test de Fisher

```
> test_welch_cout <- t.test(Indtppd ~ Gender, data = pg15training_sin)
> print(test_welch_cout)

        Welch Two Sample t-test

data:  Indtppd by Gender
t = -5.9272, df = 8384.2, p-value = 3.204e-09
alternative hypothesis: true difference in means between group Female and group Male is not equal to 0
95 percent confidence interval:
 -144.07773  -72.46287
sample estimates:
mean in group Female   mean in group Male
            792.4633             900.7336
```

Test de Welch sur la sévérité

```
> vars_to_test <- c("Type", "Occupation")
>
> test_proxy_gender <- function(data, var_name) {
+
+     tab <- table(data[[var_name]], data$Gender)
+
+   v_cramer <- cramer.v(tab)
+   return(data.frame(
+     Variable = var_name,
+     V_Cramer = v_cramer
+   ))
+ }
>
> results <- lapply(vars_to_test, function(v) test_proxy_gender(pg15training, v))
> print(results_df)
    Variable    V_Cramer
1       Type 0.005276283
2 Occupation 0.044551217
```

Test du V de Cramer

```
> stats_age_comp <- pg15training %>%
+   group_by(tranche_age) %>%
+   summarise(
+     Exposition = sum(expo_an, na.rm = TRUE),
+     Nb_Sinistres = sum(Numtppd, na.rm = TRUE),
+     Frequence = Nb_Sinistres / Exposition,
+     Cout_Moyen = ifelse(Nb_Sinistres > 0, sum(Indtppd, na.rm = TRUE) / Nb_Sinistres, 0)
+   )
>
> print(stats_age_comp)
# A tibble: 6 × 5
  tranche_age Exposition Nb_Sinistres Frequence Cout_Moyen
  <fct>            <dbl>        <int>     <dbl>      <dbl>
1 18-25           13795.         4797    0.348       873.
2 26-35           21451.         4204    0.196       668.
3 36-45           22405.         2853    0.127       600.
4 46-55           16298.         1718    0.105       628.
5 56-65            9477.          733    0.0773      657.
6 65+              6342.          443    0.0699      780.
```

Sinistralité par tranche d'âge

```
> stats_crm_comp <- pg15training %>%
+   mutate(tranche_crm = cut(CRM,
+                            breaks = c(0.49, 0.50, 0.70, 1.00, 1.50, 5),
+                            labels = c("0.50", "0.51-0.70", "0.71-1.00", "1.01-1.50", "> 1.50"))) %>%
+   group_by(tranche_crm) %>%
+   summarise(
+     Exposition = sum(expo_an, na.rm = TRUE),
+     Nb_Sinistres = sum(Numtppd, na.rm = TRUE),
+     Frequence = Nb_Sinistres / Exposition,
+   )
>
> print(stats_crm_comp)
# A tibble: 5 × 4
  tranche_crm Exposition Nb_Sinistres Frequence
  <fct>            <dbl>        <int>     <dbl>
1 0.50            22114.         1482    0.0670
2 0.51-0.70       23232.         1732    0.0746
3 0.71-1.00       19357.         3689    0.191
4 1.01-1.50       13788.         3373    0.245
5 > 1.50          11279.         4472    0.397
```

Sinistres par tranche de CRM

```
> stats_occupation <- pg15training %>%
+   group_by(Occupation) %>%
+   summarise(
+     Exposition = sum(expo_an, na.rm = TRUE),
+     Nb_Sinistres = sum(Numtppd, na.rm = TRUE),
+     Frequence = Nb_Sinistres / Exposition,
+     Cout_Moyen = ifelse(Nb_Sinistres > 0, sum(Indtppd, na.rm = TRUE) / Nb_Sinistres, 0),
+   ) %>%
+   arrange(desc(Frequence))
>
> print(stats_occupation)
# A tibble: 5 × 5
  Occupation    Exposition Nb_Sinistres Frequence Cout_Moyen
  <fct>              <dbl>        <int>     <dbl>      <dbl>
1 Unemployed        13759.         3111    0.226       875.
2 Housewife         17948.         3564    0.199       569.
3 Employed          27937.         5163    0.185       704.
4 Self-employed     18316.         2419    0.132       717.
5 Retired           11808.          491    0.0416     1013.
```

Sinistralité par Occupation

```
> mod_vif <- lm(as.numeric(Numtppd) ~ Gender + Age + CRM + Density + Occupation,
+               data = pg15training)
> vif_results <- vif(mod_vif)
> print(vif_results)
               GVIF Df GVIF^(1/(2*Df))
Gender     1.005098  1        1.002546
Age        1.577712  1        1.256070
CRM        1.048592  1        1.024008
Density    1.000158  1        1.000079
Occupation 1.530088  4        1.054604
```

Test du GVIF

```
> AIC(mod_sev_g, mod_sev_u)
          df      AIC
mod_sev_g 10 185041.9
mod_sev_u  9 185054.3
> BIC(mod_sev_g, mod_sev_u)
          df    BIC
mod_sev_g 10 185116
mod_sev_u  9 185121
```

Critères AIC/BIC Sévérité (GLM)

```
> # MODÈLE U BINOMIALE NÉGATIVE
> mod_freq_u <- glm.nb(Numtppd ~ Age + CRM + Density + Occupation
+                      + offset(log(expo_an)),
+                      data = pg15training)
> summary(mod_freq_u)

Call:
glm.nb(formula = Numtppd ~ Age + CRM + Density + Occupation +
    offset(log(expo_an)), data = pg15training, init.theta = 2.314179824,
    link = log)

Coefficients:
                           Estimate Std. Error z value Pr(>|z|)
(Intercept)              -2.3643270  0.0386096 -61.237  < 2e-16 ***
Age                      -0.0298954  0.0008365 -35.738  < 2e-16 ***
CRM                       0.9976386  0.0146236  68.221  < 2e-16 ***
Density                   0.0041964  0.0001027  40.876  < 2e-16 ***
OccupationHousewife       0.2605393  0.0234657  11.103  < 2e-16 ***
OccupationRetired        -0.4745257  0.0531123  -8.934  < 2e-16 ***
OccupationSelf-employed -0.1455966  0.0261505  -5.568 2.58e-08 ***
OccupationUnemployed      0.1926483  0.0242215   7.954 1.81e-15 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Negative Binomial(2.3142) family taken to be 1)

    Null deviance: 56664  on 100020  degrees of freedom
Residual deviance: 46820  on 100013  degrees of freedom
AIC: 78070

Number of Fisher Scoring iterations: 1


              Theta:  2.314
          Std. Err.:  0.157

 2 x log-likelihood:  -78052.303
```

Modèle Fréq. Unisexe (GLM)

```
> # MODÈLE G BINOMIALE NÉGATIVE
> mod_freq_g <- glm.nb(Numtppd ~ Gender + Age + CRM + Density + Occupation
+                      + offset(log(expo_an)),
+                      data = pg15training)
> summary(mod_freq_g)

Call:
glm.nb(formula = Numtppd ~ Gender + Age + CRM + Density + Occupation +
    offset(log(expo_an)), data = pg15training, init.theta = 2.564486126,
    link = log)

Coefficients:
                           Estimate Std. Error z value Pr(>|z|)
(Intercept)              -2.5636585  0.0402140 -63.750  < 2e-16 ***
GenderMale                0.3353955  0.0187687  17.870  < 2e-16 ***
Age                      -0.0305655  0.0008347 -36.617  < 2e-16 ***
CRM                       0.9985690  0.0145466  68.646  < 2e-16 ***
Density                   0.0041949  0.0001022  41.038  < 2e-16 ***
OccupationHousewife       0.2628734  0.0233695  11.249  < 2e-16 ***
OccupationRetired        -0.4756297  0.0530180  -8.971  < 2e-16 ***
OccupationSelf-employed -0.1443843  0.0260579  -5.541 3.01e-08 ***
OccupationUnemployed      0.1946170  0.0241195   8.069 7.10e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Negative Binomial(2.5645) family taken to be 1)

    Null deviance: 57191  on 100020  degrees of freedom
Residual deviance: 46940  on 100012  degrees of freedom
AIC: 77744

Number of Fisher Scoring iterations: 1


              Theta:  2.564
          Std. Err.:  0.186

 2 x log-likelihood:  -77724.404
```

Modèle de fréquence Genré (GLM)

```
> # Modèle  de sévérité U GLM
> mod_sev_u <- glm(cout_moyen ~ Age + CRM + Density + Occupation,
+                  family = Gamma(link = "log"),
+                  data = pg15training_sin)
>
> summary(mod_sev_u)

Call:
glm(formula = cout_moyen ~ Age + CRM + Density + Occupation,
    family = Gamma(link = "log"), data = pg15training_sin)

Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)              6.9363642  0.0373205 185.860  < 2e-16 ***
Age                     -0.0097185  0.0007439 -13.065  < 2e-16 ***
CRM                     -0.1717498  0.0153009 -11.225  < 2e-16 ***
Density                  0.0008245  0.0001047   7.875 3.69e-15 ***
OccupationHousewife     -0.1569369  0.0237748  -6.601 4.25e-11 ***
OccupationRetired        0.6525008  0.0525998  12.405  < 2e-16 ***
OccupationSelf-employed  0.0795476  0.0263758   3.016  0.00257 **
OccupationUnemployed     0.2051122  0.0245612   8.351  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Gamma family taken to be 0.9497328)

    Null deviance: 13767  on 12255  degrees of freedom
Residual deviance: 13105  on 12248  degrees of freedom
AIC: 185054

Number of Fisher Scoring iterations: 6
```

Modèle Sévérité Unisexe (GLM)

```
> mod_sev_g <- glm(cout_moyen ~ Gender + Age + CRM + Density + Occupation,
+                  family = Gamma(link = "log"),
+                  data = pg15training_sin)
>
> summary(mod_sev_g)

Call:
glm(formula = cout_moyen ~ Gender + Age + CRM + Density + Occupation,
    family = Gamma(link = "log"), data = pg15training_sin)

Coefficients:
                           Estimate Std. Error t value Pr(>|t|)
(Intercept)              6.8826165  0.0401236 171.535  < 2e-16 ***
GenderMale               0.0707908  0.0189010   3.745 0.000181 ***
Age                     -0.0097040  0.0007440 -13.043  < 2e-16 ***
CRM                     -0.1703085  0.0152989 -11.132  < 2e-16 ***
Density                  0.0008356  0.0001047   7.983 1.56e-15 ***
OccupationHousewife     -0.1558510  0.0237643  -6.558 5.66e-11 ***
OccupationRetired        0.6535556  0.0525770  12.430  < 2e-16 ***
OccupationSelf-employed  0.0821495  0.0263666   3.116 0.001840 **
OccupationUnemployed     0.2073349  0.0245539   8.444  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for Gamma family taken to be 0.9488402)

    Null deviance: 13767  on 12255  degrees of freedom
Residual deviance: 13092  on 12247  degrees of freedom
AIC: 185042

Number of Fisher Scoring iterations: 6
```

Modèle Sévérité Genré (GLM)

```
Family: Negative Binomial(3.431)
Link function: log

Formula:
Numtppd ~ Gender + s(Age) + s(CRM) + s(Density) + Occupation +
    offset(log(expo_an))

Parametric coefficients:
                       Estimate Std. Error  z value Pr(>|z|)
(Intercept)            -2.36567    0.02184 -108.307  < 2e-16 ***
GenderMale              0.33303    0.01861   17.898  < 2e-16 ***
OccupationHousewife     0.25959    0.02329   11.145  < 2e-16 ***
OccupationRetired      -0.95803    0.05637  -16.995  < 2e-16 ***
OccupationSelf-employed -0.13926    0.02596   -5.365 8.09e-08 ***
OccupationUnemployed    0.18522    0.02387    7.760 8.50e-15 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Approximate significance of smooth terms:
            edf Ref.df Chi.sq p-value
s(Age)     7.710  8.513   1929  <2e-16 ***
s(CRM)     4.924  5.999   5058  <2e-16 ***
s(Density) 8.289  8.847   1796  <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

R-sq.(adj) =   0.15   Deviance explained = 19.8%
-REML =  38366  Scale est. = 1         n = 100021
```

Fréquence Genré (GAM)

```
Family: Negative Binomial(2.983)
Link function: log

Formula:
Numtppd ~ s(Age) + s(CRM) + s(Density) + Occupation + offset(log(expo_an))

Parametric coefficients:
                       Estimate Std. Error  z value Pr(>|z|)
(Intercept)            -2.14079    0.01746 -122.611  < 2e-16 ***
OccupationHousewife     0.25720    0.02341   10.987  < 2e-16 ***
OccupationRetired      -0.95806    0.05650  -16.958  < 2e-16 ***
OccupationSelf-employed -0.14023    0.02607   -5.379 7.47e-08 ***
OccupationUnemployed    0.18267    0.02399    7.613 2.68e-14 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Approximate significance of smooth terms:
            edf Ref.df Chi.sq p-value
s(Age)     7.711  8.514   1867  <2e-16 ***
s(CRM)     4.988  6.071   4992  <2e-16 ***
s(Density) 8.270  8.840   1775  <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

R-sq.(adj) =   0.14   Deviance explained = 19.3%
-REML =  38527  Scale est. = 1         n = 100021
```

Fréquence Unisexe (GAM)

```
Family: Gamma
Link function: log

Formula:
cout_moyen ~ Gender + s(Age) + CRM + Density + Occupation

Parametric coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)            6.5206915  0.0318558 204.694  < 2e-16 ***
GenderMale             0.0655829  0.0188772   3.474 0.000514 ***
CRM                   -0.1469013  0.0155867  -9.425  < 2e-16 ***
Density                0.0008377  0.0001045   8.019 1.16e-15 ***
OccupationHousewife   -0.1574997  0.0237239  -6.639 3.29e-11 ***
OccupationRetired      0.5457767  0.0553769   9.856  < 2e-16 ***
OccupationSelf-employed 0.0819379  0.0263244   3.113 0.001859 **
OccupationUnemployed   0.2038888  0.0245166   8.316  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Approximate significance of smooth terms:
         edf Ref.df     F p-value
s(Age) 4.166  5.121 43.99  <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

R-sq.(adj) =  0.0565   Deviance explained =  5.3%
-REML =  92450  Scale est. = 0.94474   n = 12256
> AIC(mod_gam_s_g)
[1] 184851.4
> BIC(mod_gam_s_g)
[1] 184951.5
```

Sévérité Genré (GAM)

```
Family: Gamma
Link function: log

Formula:
cout_moyen ~ s(Age) + CRM + Density + Occupation

Parametric coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)            6.5694595  0.0287504 228.500  < 2e-16 ***
CRM                   -0.1477643  0.0155884  -9.479  < 2e-16 ***
Density                0.0008278  0.0001045   7.924 2.50e-15 ***
OccupationHousewife   -0.1585139  0.0237296  -6.680 2.49e-11 ***
OccupationRetired      0.5422489  0.0553942   9.789  < 2e-16 ***
OccupationSelf-employed 0.0794598  0.0263281   3.018  0.00255 **
OccupationUnemployed   0.2018197  0.0245183   8.231  < 2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Approximate significance of smooth terms:
         edf Ref.df     F p-value
s(Age) 4.182   5.14 44.38  <2e-16 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

R-sq.(adj) =  0.0563   Deviance explained = 5.22%
-REML =  92453  Scale est. = 0.94524   n = 12256
> AIC(mod_gam_s_u)
[1] 184861.5
> BIC(mod_gam_s_u)
[1] 184954.3
```

Sévérité Unisexe (GAM)

```
> # PREDICTION MODELE GLM SUR PRICING
>
> pred_f_g <- predict(mod_freq_g, newdata = pg15pricing, type = "response")
> pred_f_u <- predict(mod_freq_u, newdata = pg15pricing, type = "response")
>
> pred_s_g <- predict(mod_sev_g, newdata = pg15pricing, type = "response")
> pred_s_u <- predict(mod_sev_u, newdata = pg15pricing, type = "response")
>
> # Calcul des primes annuelles
> pg15pricing$prime_glm_g_p <- pred_f_g * pred_s_g
> pg15pricing$prime_glm_u_p <- pred_f_u * pred_s_u
>
> # Impact final
> impact_pricing_glm <- aggregate(cbind(prime_glm_g_p, prime_glm_u_p) ~ Gender, data = pg15pricing, mean)
> impact_pricing_glm$variation_pct <- (impact_pricing_glm$prime_glm_u_p / impact_pricing_glm$prime_glm_g_p - 1) * 100
>
> print(impact_pricing_glm)
  Gender prime_glm_g_p prime_glm_u_p variation_pct
1 Female      94.07796      122.9675      30.70805
2   Male     130.72814      113.9425     -12.84012
```

Prime GLM (pricing)

```
> # PREDICTION SUR LES MODÈLES GAM PRICING
> pred_f_g <- predict(mod_gam_f_g, newdata = pg15pricing, type = "response")
> pred_f_u <- predict(mod_gam_f_u, newdata = pg15pricing, type = "response")
>
> pred_s_g <- predict(mod_gam_s_g, newdata = pg15pricing, type = "response")
> pred_s_u <- predict(mod_gam_s_u, newdata = pg15pricing, type = "response")
>
> # Calcul des primes annuelles
> pg15pricing$prime_gam_g_p <- pred_f_g * pred_s_g
> pg15pricing$prime_gam_u_p <- pred_f_u * pred_s_u
>
> # Impact final
> impact_pricing_gam <- aggregate(cbind(prime_gam_g_p, prime_gam_u_p) ~ Gender, data = pg15pricing, mean)
> impact_pricing_gam$variation_pct <- (impact_pricing_gam$prime_gam_u_p / impact_pricing_gam$prime_gam_g_p - 1) * 100
>
> print(impact_pricing_gam)
  Gender prime_gam_g_p prime_gam_u_p variation_pct
1 Female      95.14291      123.6867      30.00096
2   Male     131.07315      114.5185     -12.63006
```

Prime GAM (pricing)

```
> # PREDICTION MODELE GLM SUR TRAINING
>
> pred_f_g <- predict(mod_freq_g, newdata = pg15training, type = "response")
> pred_f_u <- predict(mod_freq_u, newdata = pg15training, type = "response")
>
> pred_s_g <- predict(mod_sev_g, newdata = pg15training, type = "response")
> pred_s_u <- predict(mod_sev_u, newdata = pg15training, type = "response")
>
> # Calcul des primes annuelles
> pg15training$prime_glm_g_t <- pred_f_g * pred_s_g
> pg15training$prime_glm_u_t <- pred_f_u * pred_s_u
>
> # Impact final
> impact_training_glm <- aggregate(cbind(prime_glm_g_t, prime_glm_u_t) ~ Gender, data = pg15training, mean)
> impact_training_glm$variation_pct <- (impact_training_glm$prime_glm_u_t / impact_training_glm$prime_glm_g_t - 1) * 100
>
> print(impact_training_glm)
  Gender prime_glm_g_t prime_glm_u_t variation_pct
1 Female      84.52025      110.4731      30.70612
2   Male     117.01236      101.9857     -12.84197
```

Prime GLM (training)

```
> # PREDICTION MODELE GAM SUR TRAINING
>
> pred_f_g <- predict(mod_gam_f_g, newdata = pg15training, type = "response")
> pred_f_u <- predict(mod_gam_f_u, newdata = pg15training, type = "response")
>
> pred_s_g <- predict(mod_gam_s_g, newdata = pg15training, type = "response")
> pred_s_u <- predict(mod_gam_s_u, newdata = pg15training, type = "response")
>
> # Calcul des primes annuelles
> pg15training$prime_gam_g_t <- pred_f_g * pred_s_g
> pg15training$prime_gam_u_t <- pred_f_u * pred_s_u
>
> # Impact final
> impact_training_gam <- aggregate(cbind(prime_gam_g_t, prime_gam_u_t) ~ Gender, data = pg15training, mean)
> impact_training_gam$variation_pct <- (impact_training_gam$prime_gam_u_t / impact_training_gam$prime_gam_g_t - 1) * 100
>
> print(impact_training_gam)
  Gender prime_gam_g_t prime_gam_u_t variation_pct
1 Female      85.68842      111.3880      29.99193
2   Male     117.12737      102.3323     -12.63159
```

Prime GAM (training)

```
> link_test <- function(modele, data, reponse) {
+   yhat  <- predict(modele, type = "response")
+   yhat2 <- yhat^2
+   lt <- lm(data[[reponse]] ~ yhat + yhat2)
+   cat("=== Link Test ===\n")
+   print(summary(lt)$coefficients)
+   cat("→ Si p(yhat²) > 0.05 : lien bien spécifié\n\n")
+ }
>
> # Fréquence
> link_test(mod_freq_g, pg15training,     "Numtppd")
=== Link Test ===
               Estimate  Std. Error   t value  Pr(>|t|)
(Intercept) -0.003158964 0.002167728 -1.457269 0.1450452
yhat         1.031589881 0.016376939 62.990395 0.0000000
yhat2       -0.030789126 0.018105431 -1.700546 0.0890313
→ Si p(yhat²) > 0.05 : lien bien spécifié

> link_test(mod_freq_u, pg15training,     "Numtppd")
=== Link Test ===
               Estimate  Std. Error   t value     Pr(>|t|)
(Intercept) -0.004562869 0.002214625 -2.060335 0.0393691273
yhat         1.053993225 0.016996088 62.013873 0.0000000000
yhat2       -0.074882344 0.019473772 -3.845292 0.0001204834
→ Si p(yhat²) > 0.05 : lien bien spécifié

>
> # Sévérité
> link_test(mod_sev_g,  pg15training_sin, "cout_moyen")
=== Link Test ===
                Estimate   Std. Error    t value     Pr(>|t|)
(Intercept) -4.202253e+01 9.739801e+01 -0.4314517 6.661476e-01
yhat         1.098463e+00 2.629756e-01  4.1770519 2.973572e-05
yhat2       -5.197660e-05 1.723373e-04 -0.3015981 7.629635e-01
→ Si p(yhat²) > 0.05 : lien bien spécifié

> link_test(mod_sev_u,  pg15training_sin, "cout_moyen")
=== Link Test ===
               Estimate   Std. Error    t value     Pr(>|t|)
(Intercept) 7.350827e+00 9.956625e+01 0.07382851 0.9411480480
yhat        9.512297e-01 2.690493e-01 3.53552191 0.0004084723
yhat2       5.203649e-05 1.766071e-04 0.29464556 0.7682696467
→ Si p(yhat²) > 0.05 : lien bien spécifié
```

Test de lien pour les modèles GLM (Fréquence et Sévérité)

```
> link_test_gam <- function(modele, data, reponse) {
+   yhat  <- predict(modele, type = "response")
+   yhat2 <- yhat^2
+   lt <- lm(data[[reponse]] ~ yhat + yhat2)
+   cat("=== Link Test ===\n")
+   print(summary(lt)$coefficients)
+   cat("→ Si p(yhat²) > 0.05 : lien bien spécifié\n\n")
+ }
>
> link_test_gam(mod_gam_f_g, pg15training,     "Numtppd")
=== Link Test ===
               Estimate  Std. Error   t value     Pr(>|t|)
(Intercept) 0.003850919 0.002025345  1.901365 5.725713e-02
yhat        0.939286499 0.014773632 63.578577 0.000000e+00
yhat2       0.106755974 0.015619246  6.834899 8.253045e-12
→ Si p(yhat²) > 0.05 : lien bien spécifié

> link_test_gam(mod_gam_f_u, pg15training,     "Numtppd")
=== Link Test ===
               Estimate  Std. Error   t value     Pr(>|t|)
(Intercept) 0.002080145 0.002071523  1.004162 0.3153028599
yhat        0.967969904 0.015438128 62.699953 0.0000000000
yhat2       0.056497305 0.017040002  3.315569 0.0009148921
→ Si p(yhat²) > 0.05 : lien bien spécifié

> link_test_gam(mod_gam_s_g, pg15training_sin, "cout_moyen")
=== Link Test ===
                 Estimate   Std. Error     t value     Pr(>|t|)
(Intercept) -4.484944e+00 9.891660e+01 -0.04534067 0.9638365123
yhat         1.002223e+00 2.650291e-01  3.78155734 0.0001565907
yhat2        5.907397e-06 1.707116e-04  0.03460455 0.9723956389
→ Si p(yhat²) > 0.05 : lien bien spécifié

> link_test_gam(mod_gam_s_u, pg15training_sin, "cout_moyen")
=== Link Test ===
                Estimate   Std. Error   t value    Pr(>|t|)
(Intercept) 4.340895e+01 1.014266e+02 0.4279837 0.668670487
yhat        8.629539e-01 2.719857e-01 3.1727911 0.001513539
yhat2       1.015449e-04 1.754216e-04 0.5788619 0.562692989
→ Si p(yhat²) > 0.05 : lien bien spécifié
```

Test de lien pour les modèles GAM (Fréquence et Sévérité)

```
> hetero_test <- function(modele) {
+   res2  <- residuals(modele, type = "pearson")^2
+   yhat  <- predict(modele, type = "response")
+   ht <- lm(res2 ~ yhat)
+   cat("=== Test d'hétéroscédasticité ===\n")
+   print(summary(ht)$coefficients)
+   cat("→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée\n\n")
+ }
>
> hetero_test(mod_freq_g)
=== Test d'hétéroscédasticité ===
              Estimate Std. Error   t value   Pr(>|t|)
(Intercept)  1.0638783 0.02104180 50.560221 0.00000000
yhat        -0.1916216 0.09795021 -1.956316 0.05043068
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test(mod_freq_u)
=== Test d'hétéroscédasticité ===
              Estimate Std. Error   t value  Pr(>|t|)
(Intercept)  1.0457450 0.02070392 50.509521 0.0000000
yhat        -0.1367756 0.09742260 -1.403941 0.1603394
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test(mod_sev_g)
=== Test d'hétéroscédasticité ===
                Estimate   Std. Error  t value     Pr(>|t|)
(Intercept) 0.7915002617 0.1134291072 6.977929 3.149869e-12
yhat        0.0002193331 0.0001546942 1.417850 1.562601e-01
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test(mod_sev_u)
=== Test d'hétéroscédasticité ===
                Estimate   Std. Error  t value     Pr(>|t|)
(Intercept) 0.7875038110 0.1149637478 6.850019 7.737037e-12
yhat        0.0002263199 0.0001569124 1.442333 1.492341e-01
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée
```

Test d'hétéroscédasticité pour les modèles GLM

```
> hetero_test_gam <- function(modele) {
+   res2 <- residuals(modele, type = "pearson")^2
+   yhat <- predict(modele, type = "response")
+   ht <- lm(res2 ~ yhat)
+   cat("=== Test d'hétéroscédasticité ===\n")
+   print(summary(ht)$coefficients)
+   cat("→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée\n\n")
+ }
>
> hetero_test_gam(mod_gam_f_g)
=== Test d'hétéroscédasticité ===
              Estimate Std. Error    t value  Pr(>|t|)
(Intercept)  1.01357304 0.01885320 53.7613136 0.0000000
yhat        -0.03404313 0.08518611 -0.3996324 0.6894281
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test_gam(mod_gam_f_u)
=== Test d'hétéroscédasticité ===
             Estimate Std. Error    t value  Pr(>|t|)
(Intercept) 0.9938973 0.01853224 53.6307315 0.0000000
yhat        0.0246105 0.08463462  0.2907853 0.7712162
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test_gam(mod_gam_s_g)
=== Test d'hétéroscédasticité ===
               Estimate   Std. Error   t value     Pr(>|t|)
(Intercept) 0.8461764333 0.1088008122 7.7772989 8.000692e-15
yhat        0.0001366851 0.0001479315 0.9239757 3.555172e-01
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée

> hetero_test_gam(mod_gam_s_u)
=== Test d'hétéroscédasticité ===
               Estimate   Std. Error   t value     Pr(>|t|)
(Intercept) 0.8419959175 0.1096649071 7.6778975 1.739771e-14
yhat        0.0001433572 0.0001492086 0.9607841 3.366797e-01
→ Si p(yhat) > 0.05 : pas d'hétéroscédasticité détectée
```

Test d'hétéroscédasticité pour les modèles GAM

```
> # 1. Calcul des indices de Gini pour le GLM
> gini_g_glm <- ineq(pg15training$prime_glm_g_t, type = "Gini")
> gini_u_glm <- ineq(pg15training$prime_glm_u_t, type = "Gini")
>
> cat("Gini GLM Genré :", gini_g_glm, "\nGini GLM Unisexe :", gini_u_glm)
Gini GLM Genré : 0.4849636
Gini GLM Unisexe : 0.4762166
```

Indice de Gini - Modèle GLM

```
> # Calcul des indices de Gini
> gini_g <- ineq(pg15training$prime_gam_g_t, type = "Gini")
> gini_u <- ineq(pg15training$prime_gam_u_t, type = "Gini")
>
> cat("Gini Genré :", gini_g, "\nGini Unisexe :", gini_u)
Gini Genré : 0.5216615
Gini Unisexe : 0.5148787>
```

Indice de Gini - Modèle GAM

Table des matières

1 Introduction et fondements théoriques **6**
1.1 Introduction 6
1.2 Revue de littérature 10
1.2.1 Fondements statistiques de la tarification non-vie 10
1.2.2 Les données d'Arthur Charpentier 10
1.2.3 Réglementation anti-discrimination et fairness tarifaire 11
1.2.4 Antisélection et équilibre du portefeuille 12
1.2.5 Genre et distribution des sinistres 12
1.2.6 Vers une tarification comportementale 13
1.2.7 Synthèse et positionnement de l'étude 13

2 Méthodologie et Analyse des données **14**
2.1 Méthodologie 14
2.1.1 Le GLM : le modèle de référence actuariel 15
2.1.2 Le GAM : quand le GLM ne suffit plus 17
2.2 Analyse descriptive des données 19
2.2.1 Présentation des données et des variables 19
2.2.2 Statistiques descriptives 21
2.2.3 Analyse de la sinistralité globale 24
2.2.4 Le rôle du genre : une preuve empirique 25
2.2.5 Analyse des variables explicatives clés 27
2.2.6 Synthèse 33

3 Modélisation actuarielle et impacts tarifaires **34**
3.1 Création des modèles 34
3.1.1 Modèle de fréquence (GLM) 35
3.1.2 Modèle de sévérité (GLM) 38
3.1.3 Comparaison statistique des modèles G et U 40
3.1.4 Tests liés aux modèles 42
3.2 Optimisation des modèles et comparaison 43
3.2.1 Modèle de fréquence (GAM) 44
3.2.2 Modèle de sévérité (GAM) 45
3.2.3 Synthèse et comparaison GAM vs GLM 46
3.2.4 Visualisation des effets partiels : confirmation graphique de la supériorité du GAM 47
3.2.5 Tests liés au modèles 49
3.3 Impact tarifaire de la suppression du genre 51
3.3.1 Tarification sur le GLM 51

3.3.2 Tarification sur le GAM 52
3.3.3 Synthèse et interprétation 52
3.4 Évaluation du pouvoir discriminant des modèles : coefficient de Gini et Lift chart 53

4 Enjeux stratégiques et Conclusion **57**
4.1 Enjeux stratégiques et recommandations 57
4.1.1 Le risque d'antisélection 57
4.1.2 Éthique et algorithmes 58
4.1.3 Recommandations finales 59
4.2 Conclusion 60
4.2.1 Synthèses des résultats 60
4.2.2 Limites de l'étude et perspectives 60
4.2.3 Conclusion générale 62

Bibliographie **63**
Annexes 65
Table des matières 78