Master 1 Monnaie Banque Finance Assurance

Parcours Actuariat

Année scolaire 2025-2026

Analyse des paramètres influençant la performance en Formule 1 : Étude du Grand Prix de France 2021

Rapport par :

Dorian Soubie et Anissa Saidani

Novembre 2025

Résumé

Ce projet vise à analyser les facteurs déterminants de la performance en Formule 1 lors du Grand Prix de France 2021, en identifiant les éléments influençant les variations du temps au tour au cours d'une course. Basée sur un échantillon de 1 007 tours, la base de données intègre des informations issues des systèmes officiels de télémétrie FastF1, telles que le numéro de tour, l'identifiant du pilote, l'usure des pneus, le type de composé ainsi que diverses conditions météorologiques. L'étude mobilise une régression linéaire multiple afin de mesurer l'effet propre de chaque variable explicative sur la performance, tout en tenant compte de la structure colinéaire des données, notamment entre pilotes et écuries.

Plusieurs tests économétriques viennent compléter l'analyse afin d'en garantir la robustesse. La significativité globale et individuelle des coefficients est évaluée grâce aux tests F et t, tandis que la présence d'hétéroscédasticité est examinée via les tests de Breusch-Pagan et de White. Le diagnostic de multicolinéarité, effectué à l'aide du VIF, met en évidence des corrélations fortes entre certaines variables, comme les températures ou les composés pneumatiques, conduisant à une simplification du modèle. La spécification finale retient ainsi les variables les plus pertinentes ; LapNumber, DriverCode, IsPersonalBest, TyreLife centrée et son carré, permettant d'expliquer près de 70 % de la variance du temps au tour.

Cette approche améliore la stabilité statistique du modèle tout en conservant sa capacité explicative. Ce projet offre ainsi une lecture quantitative des mécanismes de performance en Formule 1, tout en soulignant les limites liées à l'analyse d'un seul Grand Prix et à l'impossibilité de mobiliser des modèles de panel.

1. Introduction

1.1. Contexte : La quête de la performance en F1

La Formule 1 représente l'apogée du sport automobile, une discipline où l'ingénierie de pointe et le talent humain convergent dans une quête incessante de performance. Dans cet environnement ultra-compétitif, la victoire ou la défaite se joue souvent à la milliseconde. Le temps au tour est l'indicateur de performance le plus direct et le plus crucial, reflétant l'efficacité d'un ensemble complexe : le pilote, la machine et la stratégie.

Comprendre ce qui influence ce temps au tour n'est pas seulement une question de curiosité sportive ; c'est un enjeu stratégique majeur pour les écuries qui investissent des centaines de millions d'euros pour gagner quelques dixièmes de seconde.

D'un point de vue méthodologique, il convient de préciser que bien que la structure de nos données s'apparente techniquement à un panel, nous considérerons dans cette étude qu'il s'agit de données en coupes instantanées, conformément à l'accord validé par notre professeur pour ce projet.

La Problématique

Si le talent du pilote est indéniable, il est loin d'être le seul facteur. Un même pilote, dans la même voiture, réalisera des temps au tour très différents tout au long d'une course. La performance brute est constamment médiatisée par une multitude de variables dynamiques : le pneu s'use-t-il ? La piste se réchauffe-t-elle ? Le réservoir s'allège-t-il ?

L'idée de ce projet est de dépasser l'analyse de surface pour quantifier l'impact de ces différents facteurs. La problématique centrale est donc la suivante :

Dans quelle mesure les variations du temps au tour observées lors du Grand Prix de France 2021 peuvent-elles être attribuées à des choix stratégiques, à des conditions météorologiques et à des facteurs individuels ?

1.2. Objectif de l'étude

Pour répondre à cette problématique, ce projet a pour objectif de modéliser et d'analyser les déterminants de la performance en F1.

En nous concentrant sur l'étude de cas du Grand Prix de France 2021, nous chercherons à expliquer pourquoi certains tours sont plus rapides que d'autres. L'analyse s'appuiera sur les données de télémétrie et de chronométrage (issues de FastF1) pour isoler et mesurer l'influence de variables clés telles que le composé de pneumatiques, l'âge des pneus, la charge de carburant (estimée via le numéro de tour) ou encore les conditions de piste, tout en contrôlant les effets fixes liés aux pilotes ou aux écuries.

2. Données économiques utilisées

2.1. Variable expliquée

LapTimeSec : Le temps au tour, mesuré en secondes. C'est l'indicateur principal de performance que nous cherchons à expliquer.

2.2. Variables explicatives

2.2.1. Stratégie et usure

LapNumber : Numéro du tour, sert de proxy pour la charge de carburant. On attend intuitivement un coefficient négatif car au fil de la course, les pilotes se dispersent plus ce qui réduit généralement les temps.

TyreLife : « Âge » du pneu, mesuré en nombre de tours effectués avec le train de pneus actuel.

CompoundCode : Type de gomme (1 = Soft, 2 = Medium, 3 = Hard).

2.2.2. Facteurs Individuels

DriverCode : Numéro du pilote (de 1 à 20).

TeamCode : Numéro des écuries (de 1 à 10).

Remarque : Les variables Driver et Team ne seront jamais utilisées simultanément dans nos estimations économétriques. En effet, chaque pilote est contractuellement lié à une seule écurie pour la durée de la course. Cette structure de données crée une colinéarité parfaite : connaître le pilote revient à connaître l'écurie avec certitude. L'introduction simultanée de ces deux variables rendrait l'estimation des coefficients impossible.

NbFranceGP_before2021 : Nombre de participations antérieures du pilote au GP de France.
Position : Position du pilote en course au moment du tour.

IsPersonalBest : 1 si le pilote réalise son meilleur temps personnel, 0 sinon. On attend aussi un coefficient négatif parce que cette variable capture un gain de performance par rapport à un tour normal. En termes simples, quand IsPersonalBest = 1, le temps au tour est réduit, ce qui se traduit économétriquement par un coefficient négatif.

2.2.3. Conditions météorologiques

TemperaturePiste : Température de la surface de la piste (°C).

TemperatureAir : Température ambiante de l'air (°C)

VitesseVent : Vitesse du vent (km/h)

3. Analyse des Statistiques Descriptives

3.1. Distribution du temps au tour

	LapTimeSec
Moyenne	99,957
Erreur-type	0,048
Médiane	99,898
Écart-type	1,513
Kurstosis	4,099
Coefficient d'asymétrie	0,487
Minimum	96,404
Maximum	107,603
Nombre d'échantillons	1007,000

Notre échantillon comprend 1007 tours analysés lors du Grand Prix de France 2021, après exclusion des premiers tours de chaque pilote et des tours d'arrêt au stand. Le temps au tour moyen s'établit à 99,96 secondes avec un écart-type de 1,51 seconde, soit une variabilité de 1,5 % témoignant de la précision des performances en F1. Les temps vont de 96,40 à 107,60 secondes, représentant un écart maximal de 11,2 secondes qui reflète l'hétérogénéité des situations de course. (Table 1)

La distribution présente une asymétrie positive modérée (skewness = 0,49) avec une concentration vers les temps rapides et une légère traîne vers les temps lents, s'expliquant par des événements ponctuels comme le trafic ou les incidents. (Graphe 1)

3.2. Analyses des corrélations bivariées

	LapTimeSec	*LapNumber*	*TyreLife*	*TemperatureAir*	*TemperaturePiste*	*VitesseVent*	*Position*
LapTimeSec	1,0000						
LapNumber	-0,5529	1,0000					
TyreLife	-0,1936	0,5878	1,0000				
TemperatureAir	0,4866	-0,8726	-0,4779	1,0000			
TemperaturePiste	0,5032	-0,8928	-0,5023	0,9751	1,0000		
VitesseVent	0,0110	-0,0005	-0,0680	0,0209	0,0162	1,0000	
Position	0,4983	-0,0111	-0,2096	-0,0102	-0,0080	0,0275	1,0000

L'examen de la matrice de corrélation révèle plusieurs relations significatives. Le numéro de tour présente une forte corrélation négative (-0,55) avec le temps au tour, reflétant l'allègement progressif du carburant. La durée de vie des pneus affiche une corrélation négative plus faible (-0,19), suggérant que les pneumatiques atteignent leur performance optimale après quelques tours de chauffe, compensant partiellement leur usure.

Les températures de l'air et de la piste présentent des corrélations positives modérées (0,49 et 0,50), indiquant que la chaleur ralentit les temps via la dégradation des pneus et la réduction de l'appui aérodynamique. La position en course montre également une corrélation positive (0,50), les pilotes en fin de classement réalisent des temps plus lents en raison des différences de performance et du trafic.

Un problème majeur de multicolinéarité apparaît entre la température de l'air et celle de la piste (corrélation de 0,98). Nous avons choisi de retenir uniquement la température de la piste dans nos modèles, car elle exerce un effet direct sur l'adhérence et la dégradation des pneumatiques. De plus, elle capte indirectement l'effet de la température de l'air qui influence la température de la piste. Enfin, le numéro de tour est fortement corrélé aux températures (-0,87 et -0,89), compliquant l'identification séparée de l'effet du carburant et des conditions thermiques. (Table 2)

3.3. Analyse des composés pneumatiques

Composé	Variable	Obs	Moyenne	écart-type	min	max
Soft	LaptimeSec	19	98,73137	0,97228	97,828	102,25
Medium	LaptimeSec	360	100,1159	1,55828	96,404	107,603
Hard	LaptimeSec	628	99,90241	1,480223	96,693	107,121

Le Grand Prix de France 2021 a été disputé avec les trois composés Pirelli (Soft, Medium et Hard), ce qui permet d'évaluer leur influence sur la performance au tour. Les statistiques descriptives montrent un temps moyen de 98,73 secondes pour les Soft (19 tours), 100,12 secondes pour les Medium (360 tours) et 99,90 secondes pour les Hard (628 tours), avec des écarts-types compris entre 0,97 et 1,56 seconde.

Ces résultats confirment en partie la hiérarchie attendue : les Soft sont les plus rapides, avec environ 1,4 seconde d'avance sur les Medium. Les Hard apparaissent légèrement plus rapides que les Medium, mais cette différence s'explique par leur utilisation majoritaire en fin de course, dans des conditions plus favorables (carburant plus faible, piste optimisée). À l'inverse, les Medium ont été utilisés surtout en début de relais, dans un contexte moins performant. (Table 3)

L'interprétation des Soft doit toutefois rester prudente, car l'échantillon est très limité et provient d'un seul pilote. Un test F montre que l'effet du composé est significatif, confirmant que le type de gomme influence le temps au tour. Cette analyse justifie l'intégration, dans le modèle économétrique, du composé, du numéro de tour et de l'usure des pneus afin d'isoler l'effet propre de chaque facteur. (Table 4)

4. Stratégie de modélisation

4.1. Création de variable centrée

Dans notre modèle, la variable d'usure des pneumatiques TyreLife a été recentrée autour de sa moyenne, puis élevée au carré afin de prendre en compte un éventuel effet non linéaire sur le temps au tour. Le recentrage réduit la multicolinéarité entre le terme linéaire et le terme quadratique, améliorant ainsi la stabilité numérique de l'estimation et facilitant l'interprétation des coefficients, notamment autour du niveau moyen d'usure. Cette transformation n'affecte pas la qualité globale de l'ajustement : le coefficient de détermination R^2 reste identique, seules l'échelle et l'interprétation des coefficients de TyreLife et de son carré sont modifiées.

4.2. Modèle de référence : l'effet du carburant

Avant d'introduire un modèle complet, nous avons estimé une régression simple du temps au tour sur le numéro du tour :

$$LapTimeSec_i = \boldsymbol{\beta_0} + \boldsymbol{\beta_1} LapNumber_i + \boldsymbol{\varepsilon_i}$$

	Coefficients	*Erreur-type*	*Statistique t*	*Probabilité*
Constante	101,4818	0,0827	1227,3152	0,0000
LapNumber	-0,0557	0,0026	-21,0338	0,0000
	F	*Valeur critique de F*	R-squared	Adj R-Squared
	442,4193	0,0000	0,3057	0,3050

On utilise le numéro du tour comme proxy pour la quantité de carburant restante. En effet, plus la course progresse, plus la voiture s'allège, ce qui devrait réduire le temps au tour. Les résultats de cette estimation confirment pleinement cette intuition : le coefficient associé à la variable LapNumber est bien négatif et statistiquement significatif au seuil de 0,1%. 1 tour de plus diminue, *toutes choses égales par ailleurs,* le temps au tour d'environ 0,056 seconde. Le R^2 de ce modèle simple s'élève à 0,30. Cela signifie qu'environ 30 % de la variance totale du temps au tour s'explique par la seule réduction du poids du carburant. Cette première modélisation permet ainsi d'établir un ordre de grandeur de l'impact d'un des principaux déterminants de la performance et servira de référence pour évaluer l'apport explicatif des autres variables dans les prochains modèles. Cet effet de carburant est aussi visible grâce au graphe 2 où l'on observe une décroissance du temps au tour à mesure qu'on avance dans la course.

4.3. Choix entre effet pilote ou effet écurie

$$LapTimeSec_i = \boldsymbol{\beta_0} + \boldsymbol{\beta_1} DriverCode_i + \boldsymbol{\varepsilon_i}$$

VS

$$LapTimeSec_i = \boldsymbol{\beta_0} + \boldsymbol{\beta_1} TeamCode_i + \boldsymbol{\varepsilon_i}$$

En ce qui concerne le choix entre l'effet pilote et l'effet écurie, la colinéarité parfaite entre ces deux ensembles de variables nous contraint à n'en retenir qu'un seul dans nos modèles. Pour guider ce choix, nous avons comparé empiriquement la capacité explicative de chacun. L'estimation d'un modèle incluant uniquement l'identifiant de l'écurie (TeamCode) donne un R^2 de 0,33, tandis que le modèle utilisant l'identifiant du pilote (DriverCode) présente un R^2 légèrement supérieur, à 0,34. Sur cette base, et considérant que DriverCode permet de capturer des nuances de talent individuel tout en offrant une estimation plus fine (20 pilotes contre 10 écuries), nous avons choisi de l'inclure dans nos modèles finaux. (Table 6 et Table 7)

Il convient toutefois de souligner que le talent individuel reste inobservable : dans cette spécification, le coefficient estimé pour chaque pilote reflète à la fois son habileté propre et la performance intrinsèque de sa monoplace. Cette approche reste cohérente avec la structure fortement imbriquée des données en Formule 1, où le pilote et l'écurie sont étroitement liés.

5. Estimation et résultat

5.1. Modèle complet

Dans un premier temps, nous estimons un modèle complet intégrant l'ensemble des variables explicatives sélectionnées, à savoir :

$$\begin{aligned} \boldsymbol{LapTimeSec}_i &= \boldsymbol{\beta_0} + \boldsymbol{\beta_1 LapNumber_i} + \boldsymbol{\beta_2 Driver_i} + \boldsymbol{\beta_3 Position_i} + \boldsymbol{\beta_4 IsPersonalBest_i} \\ &+ \boldsymbol{\beta_5 CompoundCode_i} + \boldsymbol{\beta_6 TyreLife_c_i} + \boldsymbol{\beta_7 TyreLife2_c_i} \\ &+ \boldsymbol{\beta_8 TemperatureAir_i} + \boldsymbol{\beta_9 TemperaturePiste_i} + \boldsymbol{\beta_{10} VitesseVent_i} + \boldsymbol{\varepsilon_i} \end{aligned}$$

Les résultats de cette première estimation sont les suivants (Table 8). Le test F global de la régression indique que celle-ci est statistiquement significative ($p < 0{,}001$), et le coefficient de détermination R^2 atteint 0,7065, ce qui suggère que l'ensemble des variables retenues explique environ 70 % de la variabilité du temps au tour. Plusieurs coefficients apparaissent significatifs aux seuils conventionnels (5 %).

Toutefois, cette spécification initiale révèle plusieurs problèmes susceptibles d'affecter la robustesse des inférences.

5.2. Problèmes détectés

5.2.1. Hétéroscédasticité

Les tests diagnostiques mettent en évidence une violation de l'hypothèse d'homoscédasticité des résidus. Le test de Breusch-Pagan (BP=44.50 > chi2(1)) rejette l'hypothèse nulle d'homoscédasticité ($p < 0{,}05$), et ce résultat est confirmé par le test de White (White = 269,32 > chi2(132)) ($p < 0{,}05$). En conséquence, les écarts-types estimés sous l'hypothèse d'homoscédasticité sont biaisés, ce qui invalide les tests t et F standards et nécessite l'emploi d'écarts-types robustes pour une inférence fiable. (Table 9)

5.2.2. Multi colinéarité

L'analyse du VIF met en évidence des valeurs particulièrement élevées pour certaines variables, indiquant une multi colinéarité préoccupante au sein du modèle initial. Ce phénomène est notamment marqué pour les variables de température de l'air et de température de piste**,** dont la corrélation atteint 0,98**,** rendant leur présence simultanée dans la régression économétriquement non viable. Une situation similaire apparaît entre le numéro de tour et les variables thermiques, ce qui contribue également à l'inflation de leurs VIF. (Table 10)

Les indicatrices correspondant aux différents composés de pneumatiques présentent des VIF très élevés, ce qui indique une multicolinéarité importante dans le modèle. Cela peut être dû à leur faible variabilité dans l'échantillon ou à leur prévisibilité à partir des autres variables explicatives. Un VIF élevé rend les coefficients moins stables et plus difficiles à interpréter. Pour limiter ce problème et améliorer la robustesse du modèle, nous avons donc choisi de retirer ces composés de la régression finale.

Enfin, concernant les variables liées à l'âge des pneus**,** leur multicolinéarité est structurellement élevée : la variable TyreLife et son carré sont mécaniquement corrélés. C'est précisément pour cette raison que nous avons centré ces variables, afin de réduire leur corrélation interne et d'obtenir des estimations plus stables et interprétables. Cette démarche permet de conserver l'effet non linéaire essentiel de l'usure des pneus tout en maîtrisant l'impact de la multicolinéarité sur la variance des coefficients.

5.2.3. Non significativité

Par ailleurs, certaines variables ne présentent pas de contribution statistiquement significative dans ce modèle complet robuste (Table 11). C'est notamment le cas de la variable TemperaturePiste et VitesseVent.

Ces différents éléments justifient une révision de la spécification du modèle et l'adoption de corrections appropriées, en particulier le recours à des estimateurs robustes à l'hétéroscédasticité et une sélection rigoureuse des variables retenues afin d'améliorer la validité et l'interprétabilité des résultats.

6. Corrections et modèle final

6.1. Comparaison du modèle complet et du modèle final

Après avoir estimé un premier modèle complet intégrant l'ensemble des variables disponibles, nous avons construit un modèle final plus épuré et économétriquement robuste. L'objectif était de conserver uniquement les déterminants significatifs et non redondants, tout en maintenant un pouvoir explicatif élevé. Les variables finalement retenues dans la spécification sont :

$$\begin{aligned} \boldsymbol{LapTimeSec_i} &= \boldsymbol{\beta_0 + \beta_1 LapNumber_i + \beta_2 Driver_i + \beta_3 IsPersonalBest_i} \\ &\quad \boldsymbol{+ \beta_4 TyreLife_c_i + \beta_5 TyreLife2_c_i + \varepsilon_i} \end{aligned}$$

LapTimeSec	Coef	Écart-type robuste	P critique
LapNumber	-0.0716	0.0021742	0.000
DriverCode			
2	-1.23168	0.1568853	0.000
3	-0.04831	0.1281355	0.706
4	0.7883	0.1549108	0.000
5	-1.3476	0.1408514	0.000
6	0.86486	0.1613542	0.000
7	0.54549	0.1989292	0.006
8	1.67693	0.1937336	0.000
9	1.316686	0.2278895	0.000
10	-0.28769	0.1350421	0.033
11	0.68138	0.1656911	0.000
12	-1.22856	0.1309689	0.000
13	0.764257	0.1538064	0.000
14	-0.05458	0.1243732	0.661
15	0.55795	0.1439091	0.000
16	0.356359	0.1476927	0.016
17	0.26637	0.1318417	0.044
18	0.44567	0.1572971	0.005
19	-1.60545	0.1323136	0.000
20	0.05228	0.1453033	0.719
IsPersonalBest	-0.72147	0.0726575	0.000
TyreLife_c	0.02384	0.0055466	0.000
TyreLife2_c	0.0018	0.0004631	0.000
_cons	101.8064	0.1224309	0.000
	Test F	**R-Squared**	
	120.59	0.6968	

Un point fondamental de cette simplification concerne également la gestion de l'endogénéité. La variable Position, initialement incluse dans le modèle complet, s'est révélée incompatible avec une estimation par moindres carrés ordinaires. En effet, la position en course influence directement le temps au tour (trajectoires perturbées, trafic, aspiration), mais le temps au tour influence aussi la position, ce qui crée un phénomène de causalité circulaire. Cette relation implique que la variable Position est corrélée avec le terme d'erreur du modèle, créant un biais d'endogénéité et rendant son coefficient impossible à interpréter. Pour garantir la validité des résultats et éviter un biais systématique, Position a donc été retirée dans la version finale du modèle. Cette correction améliore considérablement la cohérence économétrique de l'estimation.

Le modèle final présente un R^2 de 0,6968, contre 0,7065 pour le modèle complet. La perte explicative est donc inférieure à 1 %, ce qui montre que la suppression des variables non pertinentes n'a pas altéré la capacité prédictive du modèle.

Un élément particulièrement intéressant concerne la statistique F, qui passe d'environ 111 dans le modèle complet à 120,59 dans le modèle final. Cette hausse indique une meilleure efficacité globale, c'est-à-dire que le modèle final parvient à expliquer pratiquement autant de variance que le modèle complet, mais avec moins de paramètres. Cette augmentation du F reflète donc une spécification plus parcimonieuse et mieux adaptée aux données.

Une simplification importante concerne les variables liées à la température et au type de pneus. Les températures de l'air et de la piste présentaient une corrélation extrêmement forte, ce qui rendait leur effet difficile à identifier séparément. Leur inclusion conjointe ne fournissait donc pas d'information supplémentaire utile. De même, les composés de pneumatiques ne se révélaient pas significatifs une fois contrôlé l'effet réel qui importe, à savoir l'usure effective du pneu au fil des tours. Ils ont donc été retirés, d'autant que leur présence ne modifiait pas la qualité prédictive du modèle.

Interprétation :

Effet du numéro de tour ; coefficient : –0.0716 ($p < 0.001$)

Le coefficient associé au LapNumber est négatif et hautement significatif. Cela signifie que, toutes choses égales par ailleurs, chaque tour supplémentaire réduit le temps au tour d'environ 0,072 seconde.

Les pilotes deviennent plus rapides au fil de la course. Ce résultat capture notamment la diminution du carburant, la prise de rythme, et l'amélioration progressive de la température des pneus. Cet effet est conforme à la dynamique classique observée en Formule 1.

Effet du driver :

Les coefficients associés aux DriverCode sont interprétés relativement à la catégorie de référence (Driver 1 : ALONSO : 8e en fin de course).
Un coefficient négatif signifie que le pilote est plus rapide que le pilote de référence, un coefficient positif signifie qu'il est plus lent.

Exemple :

Driver 2 (BOTTAS : 4e en fin de course) : –1.2317 ($p < 0.001$)
Ce pilote est en moyenne 1,23 seconde plus rapide par tour que le pilote de référence.

Driver 4 (GIOVINNAZI : 15e en fin de course): +0.7883 ($p < 0.001$)
Ce pilote est en moyenne 0,79 seconde plus lent que le pilote de référence.

Driver 19 (VERSTAPPEN : est arrivé en première position à la fin de la course) : –1.6055 ($p < 0.001$)
Pilote très performant : 1,61 seconde plus rapide que la référence.

L'hétérogénéité des performances est très marquée et statistiquement significative pour la grande majorité des pilotes. Cela montre que l'effet pilote est un déterminant majeur des performances en Formule 1, ce qui est cohérent : talent, style de pilotage, prise de risque et maîtrise technique jouent un rôle essentiel.

6.2. Calcul du point optimal : TyreLife_max

LapTimeSec	Coef.	écart-type	t	P>|t|	[95% conf. interval]	
TyreLife_max	8,633838	2,978407	2,9	0.004	2,789071	14,4786

Le point TyreLife_max représente le niveau d'usure du pneumatique pour lequel le temps au tour est minimisé selon la forme quadratique estimée. Ce point optimal correspond au sommet de la parabole définie par les coefficients de TyreLife et TyreLife2 et permet d'identifier le seuil à partir duquel l'usure commence à dégrader fortement les performances.

Il est important de préciser que ce calcul doit être réalisé sur la variable TyreLife non centrée. En effet, lorsque le calcul est effectué à partir de la variable centrée, le point optimal obtenu apparaît négatif, ce qui n'a pas de sens économique puisqu'un niveau d'usure ne peut être inférieur à zéro. Un « optimal négatif » n'est donc pas interprétable **:** il reflète simplement le fait que le centrage a déplacé la variable d'origine, de sorte que le point optimal, exprimé dans l'espace centré, peut se situer en dehors de la plage réelle des données.

En revanche, lorsque le calcul est réalisé sur la version non centrée de *TyreLife*, le point optimal TyreLife_max est cohérent et correspond bien à un niveau d'usure réel. Le coefficient estimé associé à TyreLife_max (8,63, $p = 0,004$) indique que lorsque le pneu atteint ce niveau critique d'usure, le temps au tour augmente de manière substantielle, avec un impact moyen de +8,63 secondes. L'intervalle de confiance [2,79 ; 14,48] confirme que cette dégradation est systématique et toujours significative.

Ainsi, TyreLife_max constitue le seuil à partir duquel la performance se détériore de manière marquée, ce qui en fait un indicateur stratégique essentiel pour déterminer le moment optimal de changement de pneumatiques. Le résultat négatif obtenu à partir de la version centrée ne remet pas en cause l'existence du point optimal : il témoigne simplement de la transformation mathématique opérée par le centrage et doit être reconverti dans l'échelle originale pour être interprété correctement. (Table 13)

Dans sa forme finale, le modèle fournit ainsi une représentation économiquement pertinente de la performance en Formule 1. Il conserve près de 70 % de variance expliquée, reflète fidèlement les mécanismes techniques, notamment la dynamique d'usure des pneus, et supprime les sources

majeures d'instabilité ou de biais. Par son équilibre entre simplicité, robustesse et interprétabilité, ce modèle constitue la spécification la plus fiable pour analyser les déterminants du temps au tour lors du Grand Prix de France 2021.

7. Conclusion générale et limites

7.1. Synthèse des résultats

Cette étude a permis d'identifier et de quantifier les déterminants majeurs de la performance en Formule 1 lors du Grand Prix de France 2021. Le modèle final retenu, expliquant environ 70 % de la variance du temps au tour, met en évidence plusieurs facteurs clés. Le numéro de tour, proxy de la charge de carburant, s'affirme comme le principal levier de performance, avec un coefficient significatif traduisant l'amélioration mécanique liée à l'allègement progressif de la voiture. L'effet du talent individuel du pilote, capturé par les variables indicatrices, constitue également un déterminant fondamental et non négligeable. L'usure des pneumatiques, modélisée de manière non linéaire, révèle une dynamique technique cruciale : les pneus atteignent leur performance optimale après environ 8,63 tours avant de se dégrader, conformément aux caractéristiques réelles des composés Pirelli utilisés en compétition.

Cette architecture du modèle offre une représentation cohérente et économétriquement robuste de la réalité sportive. Les corrections apportées (suppression des variables endogènes, retrait des éléments souffrant d'une multicolinéarité excessive, utilisation d'écarts-types robustes) garantissent la validité inférentielle des résultats et leur interprétabilité.

7.2. Limites de l'étude

Cependant, cette recherche s'inscrit dans un périmètre délibérément restreint qui commande une lecture prudente de ses conclusions.

Limites méthodologiques et de données

D'abord, bien que la structure de nos données s'apparente techniquement à un panel (observations répétées de plusieurs pilotes et écuries sur plusieurs tours), nous avons traité cette étude comme une analyse en coupes instantanées, conformément à l'accord validé avec notre professeur. Cette simplification méthodologique nous a privés des outils économétriques de panel (modèles à effets fixes, effets aléatoires, ou estimateurs dynamiques) qui auraient pu améliorer le contrôle des hétérogénéités individuelles inobservables et capturer les dynamiques temporelles avec plus de précision. Une approche par données de panel aurait notamment permis de mieux isoler les effets individuels des pilotes des caractéristiques propres à leurs monoplaces, réduction d'imprécision dont aurait bénéficié l'analyse du talent individuel.

Réduction du champ d'étude

L'analyse se concentre sur une seule et unique course : le Grand Prix de France 2021. Cette restriction à un événement singulier limite fortement la généralisation de nos résultats. Les conditions météorologiques, l'état de la piste, la configuration du circuit, et même la hiérarchie des performances des écuries varient considérablement d'une course à l'autre. Les coefficients estimés risquent de refléter partiellement les spécificités du tracé du Circuit Paul Ricard ou les conditions particulières de ce dimanche de juin, plutôt que des relations structurelles valables en Formule 1. L'extensibilité de nos conclusions à d'autres Grands Prix reste donc une question ouverte et importante.

Variables exclues et sources d'endogénéité

Deux variables majeures ont dû être exclues de notre modèle final, non pas par manque de pertinence théorique, mais pour des raisons économétriques impératives.

La variable Position en course, bien qu'étroitement liée à la performance, a été écartée en raison d'une endogénéité manifeste : le temps au tour d'un pilote influence sa position, et réciproquement, la position influe sur le temps (via le trafic, les trajectoires perturbées, les opportunités d'aspiration). Cette relation circulaire rend impossible une estimation fiable par moindres carrés ordinaires. Instrumentaliser cette variable, par exemple en utilisant la position initiale en qualifications ou des variables de contexte exogènes, aurait permis de la réintroduire et d'affiner notre compréhension de l'impact du trafic et du positionnement tactique sur la performance. C'est là un axe de développement évident qui reste à explorer.

De même, les composés de pneumatiques (Soft, Medium, Hard) ont été retirés du modèle final en raison d'une multicolinéarité excessive avec l'usure réelle des pneus (TyreLife). Bien que les tests statistiques initiaux confirment que le type de gomme influence significativement le temps au tour, la colinéarité rendait l'estimation imprécise. Une transformation des composés, par exemple via une variable ordonnée, ou une interaction avec TyreLife capture l'effet spécifique de chaque gomme selon son état d'usure, pourrait dénouer ce problème et offrir des compréhensions plus fines sur le positionnement stratégique des écuries en matière de choix de pneumatiques.

7.3. Perspectives d'approfondissement

Cette étude, tout en fournissant une première analyse rigoureuse, ne constitue que la surface d'une problématique infiniment riche. L'analyse de la performance en Formule 1 mérite un traitement bien plus ambitieux.

Élargissement du périmètre temporel et spatial

L'extension la plus naturelle consisterait à reconduire cette analyse sur l'ensemble d'une saison, voire sur plusieurs saisons. Un dataset intégrant les 23 à 24 Grands Prix d'une année offrirait une robustesse statistique incomparablement supérieure, permettant de filtrer les bruits spécifiques à une course et de dégager des patterns génériques. L'approche par données de panel deviendrait non seulement

possible mais recommandée, offrant la possibilité d'estimer des modèles avec effets fixes par circuit, par saison, ou par écurie, enrichissant considérablement la compréhension des mécanismes de performance.

ANNEXE

Table 1 : Statistiques descriptives

```
. summarize LapTimeSec, detail

                        LapTimeSec
-------------------------------------------------------------
      Percentiles      Smallest
 1%       96.973          96.404
 5%       97.578          96.579
10%       97.947          96.582       Obs                1007
25%       98.952          96.693       Sum of Wgt.        1007

50%       99.898                       Mean           99.95665
                          Largest      Std. Dev.      1.512723
75%      100.992          105.277
90%      101.749           106.71      Variance       2.28833
95%      102.483          107.121      Skewness       .4864926
99%      103.792          107.603      Kurtosis       4.098773
```

Graphe 1 : Distribution du temps au tour

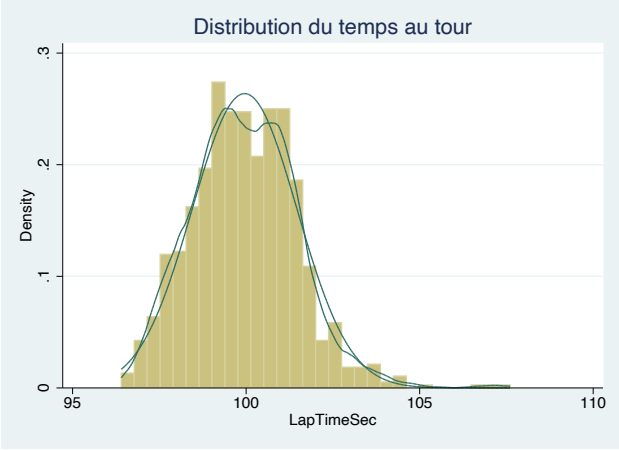


Table 2 : Matrice de corrélation

```
. pwcorr LapTimeSec LapNumber TyreLife TemperatureAir TemperaturePiste VitesseVent Position

             | LapTim~c LapNum~r TyreLife Temper~r Temper~e Vitess~t Position
-------------+------------------------------------------------------------------
 LapTimeSec  |   1.0000
  LapNumber  |  -0.5529   1.0000
   TyreLife  |  -0.1936   0.5878   1.0000
Temperatur~r |   0.4866  -0.8726  -0.4779   1.0000
Temperatur~e |   0.5032  -0.8928  -0.5023   0.9751   1.0000
VitesseVent  |   0.0110  -0.0005  -0.0680   0.0209   0.0162   1.0000
    Position |   0.4983  -0.0111  -0.2096  -0.0102  -0.0080   0.0275   1.0000
```

Table 3 : Description du composé en fonction du temps au tour

```
. summarize LapTimeSec if CompoundCode==1

    Variable |        Obs        Mean    Std. Dev.       Min        Max
-------------+---------------------------------------------------------
  LapTimeSec |         19    98.73137    .9722872      97.828     102.25

. summarize LapTimeSec if CompoundCode==2

    Variable |        Obs        Mean    Std. Dev.       Min        Max
-------------+---------------------------------------------------------
  LapTimeSec |        360    100.1159    1.558285      96.404     107.603

. summarize LapTimeSec if CompoundCode==3

    Variable |        Obs        Mean    Std. Dev.       Min        Max
-------------+---------------------------------------------------------
  LapTimeSec |        628    99.90241    1.480223      96.693     107.121
```

Table 4 : test de significativité des différents composés pneumatiques

```
. test 2.CompoundCode 3.CompoundCode

 ( 1)  2.CompoundCode = 0
 ( 2)  3.CompoundCode = 0

       F(  2,   977) =    1.56
            Prob > F =    0.2099
```

Table 5 : régression de LapTimeSec sur LapNumber

```
. regress LapTimeSec LapNumber

      Source |       SS       df       MS              Number of obs =    1007
-------------+------------------------------           F(  1,  1005) =  442.42
       Model |  703.649378     1  703.649378            Prob > F      =  0.0000
    Residual |  1598.41049  1005  1.5904582            R-squared     =  0.3057
-------------+------------------------------           Adj R-squared =  0.3050
       Total |  2302.05986  1006  2.28832989           Root MSE      =  1.2611

------------------------------------------------------------------------------
  LapTimeSec |      Coef.   Std. Err.      t    P>|t|     [95% Conf. Interval]
-------------+----------------------------------------------------------------
   LapNumber |  -.0557202   .0026491   -21.03   0.000    -.0609186   -.0505218
       _cons |   101.4818    .082686  1227.32   0.000     101.3195    101.644
------------------------------------------------------------------------------
```

Graphe 2 : effet du carburant

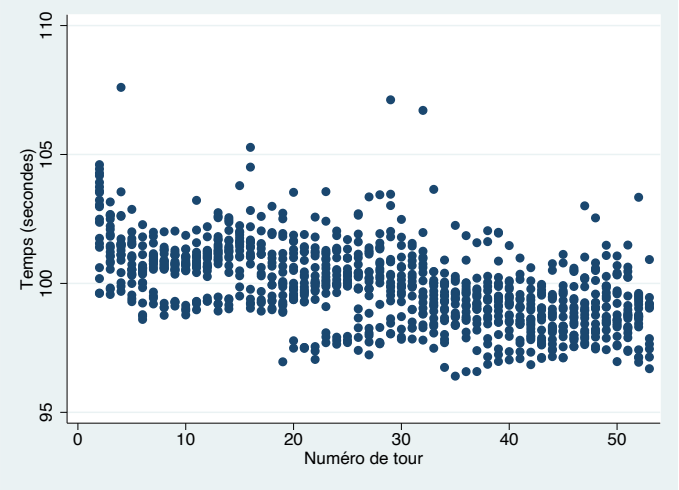


Table 6 : régression de LapTimeSec sur Driver

```
. regress LapTimeSec i.DriverCode
```

Source	SS	df	MS		
Model	785.005188	19	41.3160625	Number of obs	= 1007
Residual	1517.05468	987	1.53703615	F(19, 987)	= 26.88
				Prob > F	= 0.0000
Total	2302.05986	1006	2.28832989	R-squared	= 0.3410
				Adj R-squared	= 0.3283
				Root MSE	= 1.2398

LapTimeSec	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
DriverCode						
2	-1.112294	.2455116	-4.53	0.000	-1.594079	-.6305095
3	-.0046078	.2455116	-0.02	0.985	-.4863925	.4771768
4	.7493306	.2467361	3.04	0.002	.265143	1.233518
5	-1.294549	.2455116	-5.27	0.000	-1.776334	-.8127644
6	.8553506	.2467361	3.47	0.001	.371163	1.339538
7	.4535318	.2480041	1.83	0.068	-.0331442	.9402078
8	1.679071	.2467361	6.81	0.000	1.194883	2.163258
9	1.377531	.2467361	5.58	0.000	.893343	1.861718
10	-.3334894	.2467361	-1.35	0.177	-.817677	.1506981
11	.6845106	.2467361	2.77	0.006	.200323	1.168698
12	-1.299149	.2467361	-5.27	0.000	-1.783337	-.8149619
13	.8110706	.2467361	3.29	0.001	.326883	1.295258
14	-.0176863	.2455116	-0.07	0.943	-.4994709	.4640983
15	.5405506	.2467361	2.19	0.029	.056363	1.024738
16	.4757451	.2455116	1.94	0.053	-.0060395	.9575297
17	.2124314	.2455116	0.87	0.387	-.2693533	.694216
18	.5930906	.2467361	2.40	0.016	.108903	1.077278
19	-1.735169	.2467361	-7.03	0.000	-2.219357	-1.250982
20	.0287255	.2455116	0.12	0.907	-.4530591	.5105101
_cons	99.82653	.1736029	575.03	0.000	99.48586	100.1672

Table 7 : régression de LapTimeSec sur Team

```
. regress LapTimeSec i.TeamCode
```

Source	SS	df	MS		
Model	750.319154	9	83.3687949	Number of obs	= 1007
Residual	1551.74071	997	1.55640994	F(9, 997)	= 53.56
				Prob > F	= 0.0000
Total	2302.05986	1006	2.28832989	R-squared	= 0.3259
				Adj R-squared	= 0.3198
				Root MSE	= 1.2476

LapTimeSec	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
TeamCode						
2	-.4889181	.1759946	-2.78	0.006	-.8342805	-.1435558
3	-.441334	.1759946	-2.51	0.012	-.7866963	-.0959716
4	-.6596222	.1755649	-3.76	0.000	-1.004141	-.3151031
5	-.31534	.1764319	-1.79	0.074	-.6615604	.0308804
6	.7481	.1764319	4.24	0.000	.4018796	1.09432
7	-.954225	.1759946	-5.42	0.000	-1.299587	-.6088627
8	-1.983622	.1755649	-11.30	0.000	-2.328141	-1.639103
9	-2.29736	.1764319	-13.02	0.000	-2.64358	-1.95114
10	-.08225	.1764319	-0.47	0.641	-.4284704	.2639704
_cons	100.6067	.1247562	806.43	0.000	100.3619	100.8515

Table 8 : régression multivariée avec toutes les variables explicatives

```
. regress LapTimeSec LapNumber i.DriverCode Position IsPersonalBest i.CompoundCode TyreLife_c TyreLife2_c TemperatureAir TemperaturePiste VitesseVe
> nt
```

Source	SS	df	MS		
Model	1626.43359	29	56.0839168	Number of obs	= 1007
Residual	675.626276	977	.691531501	F(29, 977)	= 81.10
				Prob > F	= 0.0000
				R-squared	= 0.7065
				Adj R-squared	= 0.6978
Total	2302.05986	1006	2.28832989	Root MSE	= .83158

LapTimeSec	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
LapNumber	-.0812164	.0047668	-17.04	0.000	-.0905708	-.071862
DriverCode						
2	-.7973309	.2007633	-3.97	0.000	-1.191308	-.4033539
3	.0477189	.1664866	0.29	0.774	-.2789935	.3744313
4	.5741766	.1735811	3.31	0.001	.2335418	.9148113
5	-.8040433	.2176063	-3.69	0.000	-1.231073	-.3770138
6	.416526	.2024439	2.06	0.040	.019251	.8138009
7	.4867913	.1682378	2.89	0.004	.1566423	.8169403
8	1.108614	.2196173	5.05	0.000	.6776378	1.539589
9	.7241317	.2268973	3.19	0.001	.2788695	1.169394
10	-.1231841	.1720894	-0.72	0.474	-.4608915	.2145232
11	.5186914	.1698018	3.05	0.002	.1854732	.8519096
12	-.8226419	.1977992	-4.16	0.000	-1.210802	-.4344818
13	.4666418	.1811599	2.58	0.010	.1111346	.8221491
14	.0629702	.1672466	0.38	0.707	-.2652337	.3911742
15	.2413921	.1857408	1.30	0.194	-.1231048	.605889
16	.4331121	.1665461	2.60	0.009	.1062829	.7599414
17	.2148277	.1919838	1.12	0.263	-.1619205	.5915758
18	.1702275	.1802175	0.94	0.345	-.1834303	.5238854
19	-1.084694	.2240111	-4.84	0.000	-1.524292	-.6450956
20	.1738908	.1673462	1.04	0.299	-.1545087	.5022902
Position	.0634638	.016378	3.87	0.000	.0313237	.0956038
IsPersonalBest	-.797174	.0772412	-10.32	0.000	-.9487517	-.6455963
CompoundCode						
2	-.1000979	.2674577	-0.37	0.708	-.6249555	.4247596
3	-.194998	.257808	-0.76	0.450	-.700919	.3109231
TyreLife_c	.0400457	.0055542	7.21	0.000	.0291463	.0509452
TyreLife2_c	.0013549	.000366	3.70	0.000	.0006366	.0020732
TemperatureAir	-.4604569	.1254917	-3.67	0.000	-.7067212	-.2141926
TemperaturePiste	.1995454	.0706293	2.83	0.005	.0609427	.3381481
VitesseVent	.192769	.1623272	1.19	0.235	-.125781	.511319
_cons	105.9613	1.651589	64.16	0.000	102.7203	109.2024

Table 9 : test de Breusch-Pagan et test de White

```
. estat imtest, white

White's test for Ho: homoskedasticity
         against Ha: unrestricted heteroskedasticity

         chi2(132)     =    269.32
         Prob > chi2   =    0.0000

Cameron & Trivedi's decomposition of IM-test
```

Source	chi2	df	p
Heteroskedasticity	269.32	132	0.0000
Skewness	65.79	24	0.0000
Kurtosis	5.59	1	0.0181
Total	340.70	157	0.0000

```
. estat hettest

Breusch-Pagan / Cook-Weisberg test for heteroskedasticity
         Ho: Constant variance
         Variables: fitted values of LapTimeSec

         chi2(1)       =    44.50
         Prob > chi2   =    0.0000
```

Table 10 : VIF

```
. vif
```

Variable	VIF	1/VIF
LapNumber	7.45	0.134283
DriverCode		
2	2.82	0.354360
3	1.94	0.515294
4	2.07	0.483008
5	3.32	0.301627
6	2.82	0.355099
7	1.91	0.524123
8	3.31	0.301736
9	3.54	0.282684
10	2.03	0.491418
11	1.98	0.504748
12	2.69	0.371972
13	2.26	0.443441
14	1.96	0.510621
15	2.37	0.421837
16	1.94	0.514926
17	2.58	0.387511
18	2.23	0.448090
19	3.45	0.290015
20	1.96	0.510013
Position	12.88	0.077630
IsPersonal~t	1.43	0.699833
CompoundCode		
2	23.93	0.041795
3	22.72	0.044020
Temperatur~r	23.12	0.043254
Temperatur~e	25.66	0.038970
VitesseVent	1.07	0.933981
TyreLife	23.17	0.043160
Tyrelife2	19.44	0.051436
Mean VIF	7.17	

Table 11 : régression avec écart types robustes

```
. regress LapTimeSec LapNumber i.DriverCode Position IsPersonalBest i.CompoundCode TyreLife_c TyreLife2_c TemperatureAir TemperaturePiste Vites
> seVent, vce(robust)

Linear regression                               Number of obs =    1007
                                                F( 29,   977) =  111.65
                                                Prob > F      =  0.0000
                                                R-squared     =  0.7065
                                                Root MSE      =  .83158
```

LapTimeSec	Coef.	Robust Std. Err.	t	P>|t|	[95% Conf.	Interval]
LapNumber	-.0812164	.0049289	-16.48	0.000	-.0908889	-.0715439
DriverCode						
2	-.7973309	.2013759	-3.96	0.000	-1.19251	-.4021518
3	.0477189	.1307575	0.36	0.715	-.208879	.3043168
4	.5741766	.1599165	3.59	0.000	.2603572	.887996
5	-.8040433	.2051976	-3.92	0.000	-1.206722	-.4013646
6	.416526	.2072609	2.01	0.045	.0097981	.8232538
7	.4867913	.1889294	2.58	0.010	.1160372	.8575455
8	1.108614	.2818952	3.93	0.000	.5554238	1.661803
9	.7241317	.2910661	2.49	0.013	.1529451	1.295318
10	-.1231841	.1404307	-0.88	0.381	-.3987647	.1523964
11	.5186914	.1690981	3.07	0.002	.1868542	.8505285
12	-.8226419	.1729004	-4.76	0.000	-1.161941	-.4833429
13	.4666418	.1709966	2.73	0.006	.131079	.8022046
14	.0629702	.1265937	0.50	0.619	-.1854567	.3113971
15	.2413921	.1665746	1.45	0.148	-.0854931	.5682773
16	.4331121	.1502821	2.88	0.004	.1381994	.7280249
17	.2148277	.1441206	1.49	0.136	-.067994	.4976493
18	.1702275	.1698393	1.00	0.316	-.1630642	.5035193
19	-1.084694	.2127615	-5.10	0.000	-1.502216	-.6671718
20	.1738908	.1473123	1.18	0.238	-.1151941	.4629757
Position	.0634638	.0181231	3.50	0.000	.0278991	.0990284
IsPersonalBest	-.797174	.0782431	-10.19	0.000	-.9507178	-.6436302
CompoundCode						
2	-.1000979	.2472446	-0.40	0.686	-.5852895	.3850936
3	-.194998	.2253508	-0.87	0.387	-.6372253	.2472294
TyreLife_c	.0400457	.0080639	4.97	0.000	.0242212	.0558702
TyreLife2_c	.0013549	.0005528	2.45	0.014	.00027	.0024398
TemperatureAir	-.4604569	.137838	-3.34	0.001	-.7309495	-.1899643
TemperaturePiste	.1995454	.0704627	2.83	0.005	.0612698	.337821
VitesseVent	.192769	.1480787	1.30	0.193	-.0978198	.4833579
_cons	105.9613	1.792465	59.11	0.000	102.4438	109.4789

Table 12 : régression finale

```
. regress LapTimeSec LapNumber i.DriverCode IsPersonalBest TyreLife_c TyreLife2_c , vce(robust)

Linear regression                               Number of obs =    1007
                                                F( 23,   983) =  120.59
                                                Prob > F      =  0.0000
                                                R-squared     =  0.6968
                                                Root MSE      =  .84268
```

LapTimeSec	Coef.	Robust Std. Err.	t	P>|t|	[95% Conf.	Interval]
LapNumber	-.0716721	.0021742	-32.97	0.000	-.0759386	-.0674056
DriverCode						
2	-1.23168	.1568853	-7.85	0.000	-1.539548	-.923811
3	-.0483147	.1281355	-0.38	0.706	-.2997651	.2031358
4	.7883121	.1549108	5.09	0.000	.4843183	1.092306
5	-1.347643	.1408514	-9.57	0.000	-1.624047	-1.071239
6	.8648591	.1613542	5.36	0.000	.5482208	1.181497
7	.5454869	.1989292	2.74	0.006	.1551122	.9358616
8	1.676926	.1937336	8.66	0.000	1.296747	2.057105
9	1.316686	.2278895	5.78	0.000	.86948	1.763892
10	-.2876994	.1350421	-2.13	0.033	-.5527033	-.0226956
11	.681381	.1656911	4.11	0.000	.3562321	1.00653
12	-1.228562	.1309689	-9.38	0.000	-1.485572	-.971551
13	.7642569	.1538064	4.97	0.000	.4624303	1.066083
14	-.0545836	.1243732	-0.44	0.661	-.2986511	.189484
15	.5579554	.1439091	3.88	0.000	.2755511	.8403598
16	.3563596	.1476927	2.41	0.016	.0665303	.6461889
17	.2663753	.1318417	2.02	0.044	.0076518	.5250988
18	.445669	.1572971	2.83	0.005	.1369923	.7543457
19	-1.605447	.1323136	-12.13	0.000	-1.865096	-1.345797
20	.0522844	.1453033	0.36	0.719	-.2328559	.3374247
IsPersonalBest	-.7214737	.0726575	-9.93	0.000	-.8640554	-.578892
TyreLife_c	.0238445	.0055466	4.30	0.000	.0129599	.0347291
TyreLife2_c	.0017912	.0004631	3.87	0.000	.0008824	.0026999
_cons	101.8064	.1224309	831.54	0.000	101.5662	102.0467

Table 13 : Optimum de l'âge des pneus

```
. nlcom  TyreLife_max :(-_b[ TyreLife ]/(2*_b[ TyreLife2 ]))

TyreLife_max:  (-_b[ TyreLife ]/(2*_b[ TyreLife2 ]))
```

LapTimeSec	Coef.	Std. Err.	t	P>|t|	[95% Conf.	Interval]
TyreLife_max	8.633838	2.978407	2.90	0.004	2.789071	14.4786

Bibliographie et références

Sources de données et ressources officielles

FastF1 Documentation : https://docs.fastf1.dev/ (Librairie Python pour télémétrie F1)

Official FIA Formula 1 Website: https://www.fia.com/

Formula 1 Official Website. Récupéré de https://www.formula1.com

Mémoires et thèses connexes

Pasz, S. (2025). *Determinants of Lap Times in Formula 1: An Econometric Analysis of the 2019–2025 Seasons* [bachelor's Thesis, unpublished]